



## UNIDADE IV

---

### Algoritmos e Estrutura de Dados em Python

Prof. MSc. Tarcísio Peres

## Conteúdo da Unidade IV

- Algoritmos em Grafos.
- Caminhos mínimos: Dijkstra e Bellman-Ford.
- Grafos com árvores: algoritmos de Kruskal e Prim para árvores geradoras mínimas.
- Problemas de divisão e conquista: análise de exemplos como o problema da mochila.
- Programação dinâmica: introdução e resolução de problemas clássicos (como a subsequência comum mais longa).

# Caminhos mínimos


- A determinação de caminhos mínimos (single-source shortest path) em grafos constitui tema central da ciência da computação por viabilizar rotas com menor custo em mapas de tráfego rodoviário, redes de comunicação e fluxos de suprimentos.
- Em Python, duas abordagens clássicas atendem a tal demanda: o algoritmo de Dijkstra e o de Bellman-Ford.
- Ambos partem de um vértice de origem e atribuem a cada vértice adjacente um valor que representa a distância mais curta já conhecida, atualizando essas estimativas conforme as arestas são examinadas.
  - Apesar de perseguirem o mesmo objetivo, as estratégias divergem na maneira de selecionar o próximo vértice a processar, na forma de atualizar distâncias e nas hipóteses sobre os pesos das arestas.

# Dijkstra

- Dijkstra admite que todos os pesos sejam não negativos e emprega uma fila de prioridade para escolher em cada iteração o vértice cuja distância provisória já atingiu o menor valor entre os que permanecem por visitar.
- Ao retirar esse vértice da fila, a distância associada torna-se definitiva, pois nenhum caminho alternativo poderá reduzi-la, dado que todas as rotas futuras acrescentarão custo positivo.
- A estrutura de dados típica para expressar a fila de prioridade em Python é o heap binário oferecido pelo módulo heapq.
- A cada extração, o algoritmo percorre as arestas que partem do vértice recém-fixado, recalculando o custo até os seus vizinhos mediante a operação denominada relaxamento.

# Dijkstra

- Se a soma da distância definitiva com o peso da aresta reduzir a estimativa anterior do vizinho, essa estimativa é substituída, e o par atualizado retorna à fila.
- A complexidade global depende da eficiência da fila, situando-se em  $O((V + E) \log V)$  quando o heap binário gerencia tanto extrações quanto inserções resultantes dos relaxamentos.
- Em muitos problemas práticos, tal desempenho apresenta-se excelente, sobretudo em grafos esparsos, nos quais o número de arestas cresce linearmente em relação aos vértices.



# Dijkstra – Exemplo

- Imagine que você é um turista que começa sua jornada no RJ e quer visitar todas essas cidades, mas quer minimizar a distância de viagem. O algoritmo de Dijkstra é como um assistente de viagem que ajuda a escolher as rotas mais curtas.

Passo 1: Você começa no Rio de Janeiro e verifica as distâncias até as cidades mais próximas. As opções são:

- São Paulo a 430 km.
- Salvador a 900 km.
- O algoritmo escolhe São Paulo, pois está mais próxima.

Passo 2: Agora você está em São Paulo e precisa ir para a próxima cidade. As opções são:

- Brasília a 1200 km.
- Fortaleza a 2000 km.
- O algoritmo escolhe Brasília, pois está mais próxima.

# Dijkstra – Exemplo

Passo 3: Você chega em Brasília e verifica as opções de cidades próximas:

- Fortaleza a 400 km.
- O algoritmo escolhe Fortaleza, pois é a cidade mais próxima.

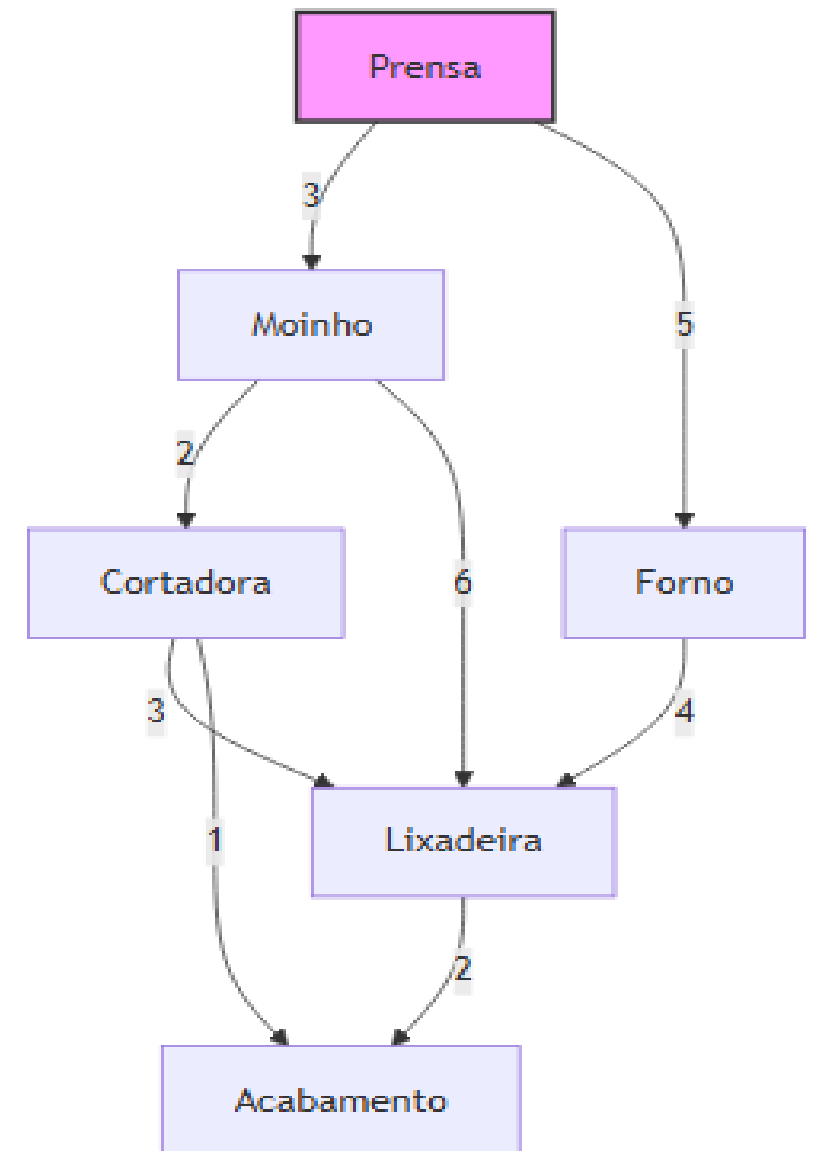
Passo 4: Agora que você está em Fortaleza, o único destino restante é Salvador, que está a 800 km de distância.

- Ao final do percurso, o algoritmo de Dijkstra terá identificado o caminho mais curto entre as cidades, minimizando a distância total percorrida.
  - O ponto fundamental é que ele sempre escolhe o caminho mais curto disponível a cada etapa, sem precisar verificar todas as possibilidades de antemão.

# Dijkstra – Exemplo fabril

O algoritmo de Dijkstra identificou a sequência mais eficiente de equipamentos para processar o material:

- Prensa → Moinho → Cortadora → Acabamento, com o menor custo total de  $3 + 2 + 1 = 6$  unidades.





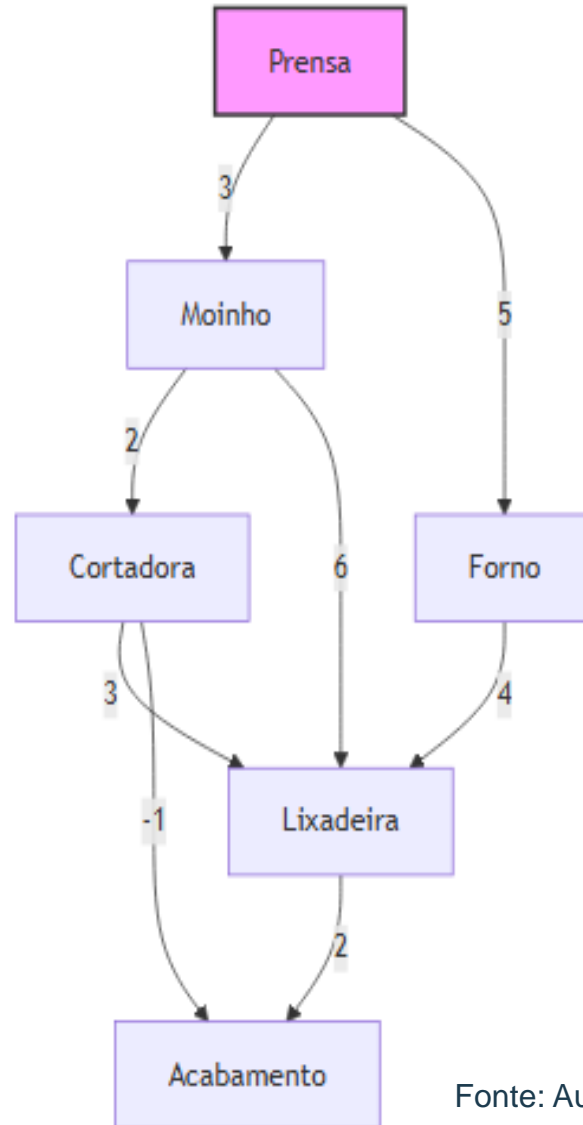
## Adaptação – Exemplo fabril

- Vamos imaginar um cenário em que o custo de utilizar determinados equipamentos na fábrica varia ao longo do tempo.

Por exemplo, durante certos períodos do dia, o custo operacional das máquinas pode ser menor devido a descontos, manutenção programada ou outros fatores. Isso cria arestas com custos negativos temporários:

- Durante certos períodos do dia, a Cortadora pode ser usada com desconto devido à manutenção preventiva, o que cria um custo negativo ao transitar para ela.
- Por outro lado, o uso do Forno pode ter custos mais elevados devido à sobrecarga de demanda.

# Adaptação – Exemplo fabril



Fonte: Autoria própria.

# Bellman-Ford

Passo 1: O processo de produção começa na Prensa. O operador tem duas opções:

- Enviar o material para o Moinho a um custo de 3 unidades.
- Enviar o material para o Forno a um custo de 5 unidades.
- O algoritmo de Bellman-Ford escolhe o Moinho, pois o custo é mais baixo.

Passo 2: Agora, o material está no Moinho. As opções de transição são:

- Enviar para a Cortadora a um custo de 2 unidades.
- Enviar para a Lixadeira a um custo de 6 unidades.
- O algoritmo escolhe a Cortadora, pois o custo é menor.

# Bellman-Ford

Passo 3: O material chega na Cortadora. Aqui, o algoritmo observa que a transição para o Acabamento tem um custo negativo de -1 unidade devido a um desconto especial. As opções de transição são:

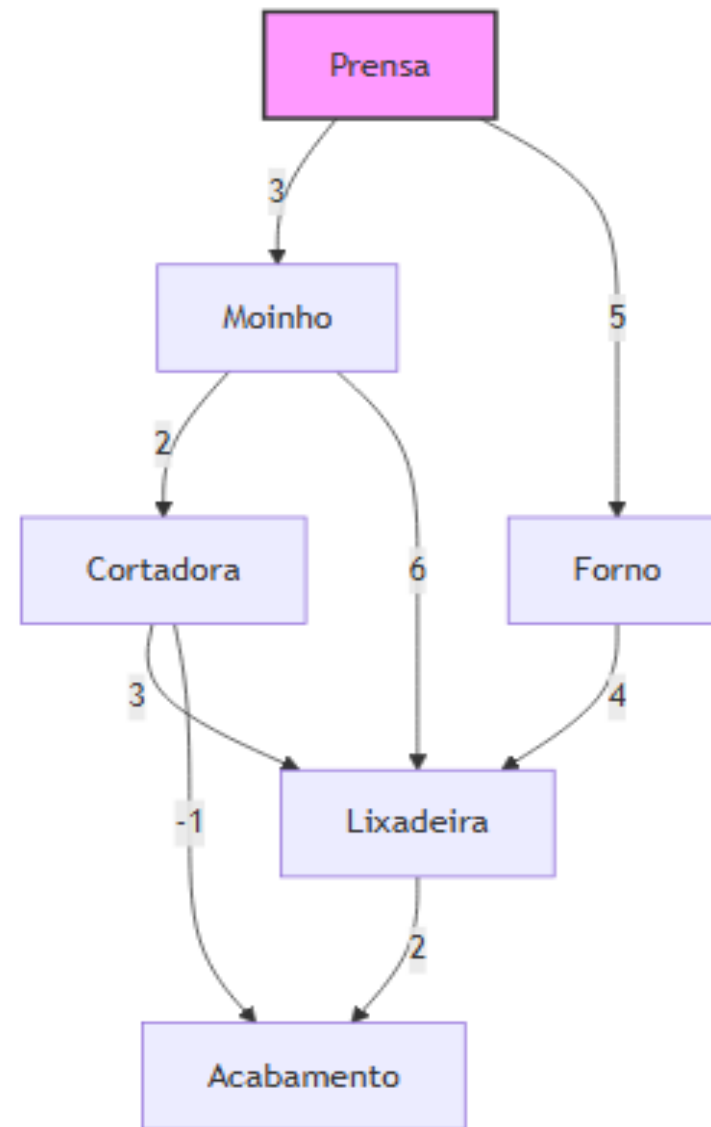
- Enviar para a Lixadeira a um custo de 3 unidades.
- Enviar para o Acabamento com um custo de -1 unidade.
- O algoritmo escolhe o Acabamento, aproveitando o custo negativo e, portanto, reduzindo o custo total.

Passo 4: O material chega diretamente ao Acabamento, finalizando o processo.

# Bellman-Ford

O algoritmo de Bellman-Ford identificou a sequência mais eficiente, considerando os custos negativos e os ajustes no custo das máquinas:

- Prensa → Moinho → Cortadora → Acabamento, com um custo total de  $3 + 2 + (-1) = 4$  unidades, que é mais eficiente devido ao uso do desconto na Cortadora.



# Comparativo

- Em cenários nos quais podem existir pesos negativos, Dijkstra perde a garantia de correção, pois a definição de um caminho definitivo não impede que um custo menor surja depois pela introdução de uma aresta negativa.
- Nessa circunstância, a escolha recai sobre Bellman-Ford, cuja lógica baseia-se em varrer todas as arestas repetidas vezes.
- A cada passagem, o algoritmo examina uma aresta e verifica se a distância até o vértice de destino pode ser melhorada pela rota que passa pela aresta de origem; quando a soma apresenta valor inferior à estimativa corrente, realiza-se o relaxamento.
  - Se o grafo contém  $V$  vértices, repetir o processo  $V - 1$  vezes assegura que qualquer caminho com até  $V - 1$  arestas terá sido considerado, contemplando todos os caminhos simples possíveis.
  - Uma passagem adicional detecta a presença de ciclos de peso negativo, pois qualquer relaxamento ainda possível após  $V - 1$  iterações indica a existência de ciclo no qual o custo total diminui indefinidamente.

# Implementação

- Em Python, listas de arestas e laços aninhados fornecem implementação direta, porém a complexidade temporal  $O(V E)$  demonstra-se mais elevada que a de Dijkstra.
- Essa característica torna Bellman-Ford apropriado apenas quando a presença potencial de pesos negativos justifica o custo adicional ou quando o número de arestas é baixo o suficiente para manter o tempo de execução aceitável.

```
from __future__ import annotations
from dataclasses import dataclass
from typing import Dict, List, Tuple
import heapq, random

    @dataclass
    class Aresta:
        destino: str
        tempo: float           # segundos
        energia: float         # kWh (pode ser negativa em
                                descida)
```

# Implementação

```
class Aresta:
    destino: str
    tempo: float          # segundos
    energia: float        # kWh (pode ser negativa em descida)

class Grafo:
    def __init__(self):
        self.adj: Dict[str, List[Aresta]] = {}

        def adicionar_aresta(self, origem: str,
                               destino: str, tempo: float, energia: float):
            self.adj.setdefault(origem,
                                 []).append(Aresta(destino, tempo, energia))
```



# Interatividade

Considerando os algoritmos de Dijkstra e Bellman-Ford para o cálculo de caminhos mínimos em grafos, analise as afirmativas a seguir e assinale a alternativa correta.

- a) O algoritmo de Dijkstra pode ser utilizado normalmente em grafos que apresentam arestas com pesos negativos, sem risco de resultados incorretos.
- b) Bellman-Ford possui a mesma complexidade temporal de Dijkstra, sendo preferível para grafos densos e sem restrições de peso nas arestas.
- c) O algoritmo de Dijkstra é eficiente em grafos com pesos não negativos e não detecta ciclos negativos, enquanto Bellman-Ford pode lidar com arestas de peso negativo e é capaz de identificar ciclos de custo negativo.
  - d) Ambos os algoritmos exigem que o grafo seja acíclico para garantir a correta obtenção dos menores caminhos entre dois vértices.
  - e) Dijkstra é sempre mais eficiente e preciso que Bellman-Ford, independentemente do tipo de grafo ou dos pesos das arestas.

# Resposta

Considerando os algoritmos de Dijkstra e Bellman-Ford para o cálculo de caminhos mínimos em grafos, analise as afirmativas a seguir e assinale a alternativa correta.

- a) O algoritmo de Dijkstra pode ser utilizado normalmente em grafos que apresentam arestas com pesos negativos, sem risco de resultados incorretos.
- b) Bellman-Ford possui a mesma complexidade temporal de Dijkstra, sendo preferível para grafos densos e sem restrições de peso nas arestas.
- c) O algoritmo de Dijkstra é eficiente em grafos com pesos não negativos e não detecta ciclos negativos, enquanto Bellman-Ford pode lidar com arestas de peso negativo e é capaz de identificar ciclos de custo negativo.
- d) Ambos os algoritmos exigem que o grafo seja acíclico para garantir a correta obtenção dos menores caminhos entre dois vértices.
- e) Dijkstra é sempre mais eficiente e preciso que Bellman-Ford, independentemente do tipo de grafo ou dos pesos das arestas.

# Definição e importância das árvores geradoras mínimas

- Árvores geradoras mínimas (MST, do inglês *Minimum Spanning Tree*) conectam todos os vértices de um grafo ponderado pelo menor custo possível, evitando a formação de ciclos.
- O objetivo é selecionar subconjunto de arestas que garanta conectividade global e minimize o custo total da rede.
- Essa abordagem é fundamental para problemas de infraestrutura, redes de computadores e economia de recursos.
- A árvore geradora mínima resulta em  $V - 1$  arestas, onde  $V$  é o número total de vértices do grafo analisado.
  - Algoritmos clássicos como Kruskal e Prim são usados para obter essa solução de maneira eficiente e comprovada.
  - O resultado final atende à propriedade do corte: qualquer aresta de menor peso cruzando uma partição sem ciclo mantém a minimalidade.

# Princípios do algoritmo de Kruskal

- Kruskal inicia com todos os vértices isolados, formando uma floresta na qual cada vértice é sua própria árvore.
- Ordena-se a lista de arestas pelo peso, do menor para o maior, garantindo prioridade às conexões mais baratas.
- Cada nova aresta é avaliada para inclusão, desde que não crie ciclo entre componentes já conectados.
- A verificação de ciclos utiliza estrutura união-busca (Union-Find) com compressão de caminho e união por tamanho.
  - O custo de identificar componentes cresce lentamente, devido à eficiência do Union-Find com função de Ackermann.
  - O processo termina quando todos os vértices formam um único componente conectado, ou seja, uma árvore.

# Complexidade e vantagens do algoritmo de Kruskal

- O tempo total do algoritmo de Kruskal é dominado pela ordenação das arestas, resultando em complexidade  $O(E \log E)$ .
- Cada inclusão de aresta diminui o número de componentes, aproximando a floresta de uma árvore única.
- Union-Find opera em tempo quase constante, tornando eficiente a verificação de conexões entre vértices.
- Kruskal é especialmente eficiente em grafos esparsos, com número de arestas próximo ao número de vértices.
  - O algoritmo é naturalmente paralelizável, pois o processamento de diferentes blocos de arestas pode ocorrer simultaneamente.
  - É ideal em contextos nos quais as conexões físicas ou lógicas são adicionadas gradativamente por custos crescentes.

# Definição do termo floresta e função de Ackermann

- “Floresta” representa um conjunto de componentes desconexos, cada um sendo uma árvore isolada no início do algoritmo.
- O termo descreve o estado inicial e intermediário em Kruskal, diferenciando-se da árvore única obtida ao final.
- Ao longo das iterações, árvores individuais vão sendo conectadas até restar apenas uma, a árvore geradora mínima.
- A função de Ackermann, citada no texto, expressa a eficiência teórica da compressão de caminho em Union-Find.
  - Seu crescimento extremamente rápido é utilizado na análise de algoritmos avançados de teoria da computação.
  - O uso dessa função demonstra que a identificação de componentes é praticamente constante mesmo para grandes grafos.

# Princípios do algoritmo de Prim

- Prim parte de um único vértice e cresce continuamente o componente conectado ao restante do grafo.
- Utiliza uma fila de prioridade para selecionar, a cada etapa, a aresta de menor peso conectando novo vértice.
- Em cada iteração, um vértice externo é incorporado, expandindo a árvore sem formação de ciclos.
- As arestas incidentes ao vértice recém-incluído entram na fila se levarem a vértices ainda não visitados.
  - A implementação com heap binário (heapq) assegura inserção e remoção eficiente em  $O(\log V)$  por operação.
  - O processo segue até que todos os vértices tenham sido adicionados ao componente em expansão.

# Complexidade e aplicações do algoritmo de Prim

- O tempo de execução de Prim é  $O(E \log V)$ , tornando-o eficiente em grafos densos e com muitas arestas.
- Em grafos muito densos, substituir o heap por matriz de chaves pode simplificar para  $O(V^2)$ , útil em grafos completos.
- O algoritmo é incremental, pois depende da escolha local do mínimo a cada nova expansão de componente.
- Fila de prioridade bem implementada reduz latência na escolha da próxima aresta a ser incorporada.
  - Prim é preferido em aplicações nas quais o número de arestas excede significativamente o número de vértices.
  - Adequado para situações em que o armazenamento das arestas não é significativamente superior ao dos vértices.



# Comparação entre Prim e Kruskal

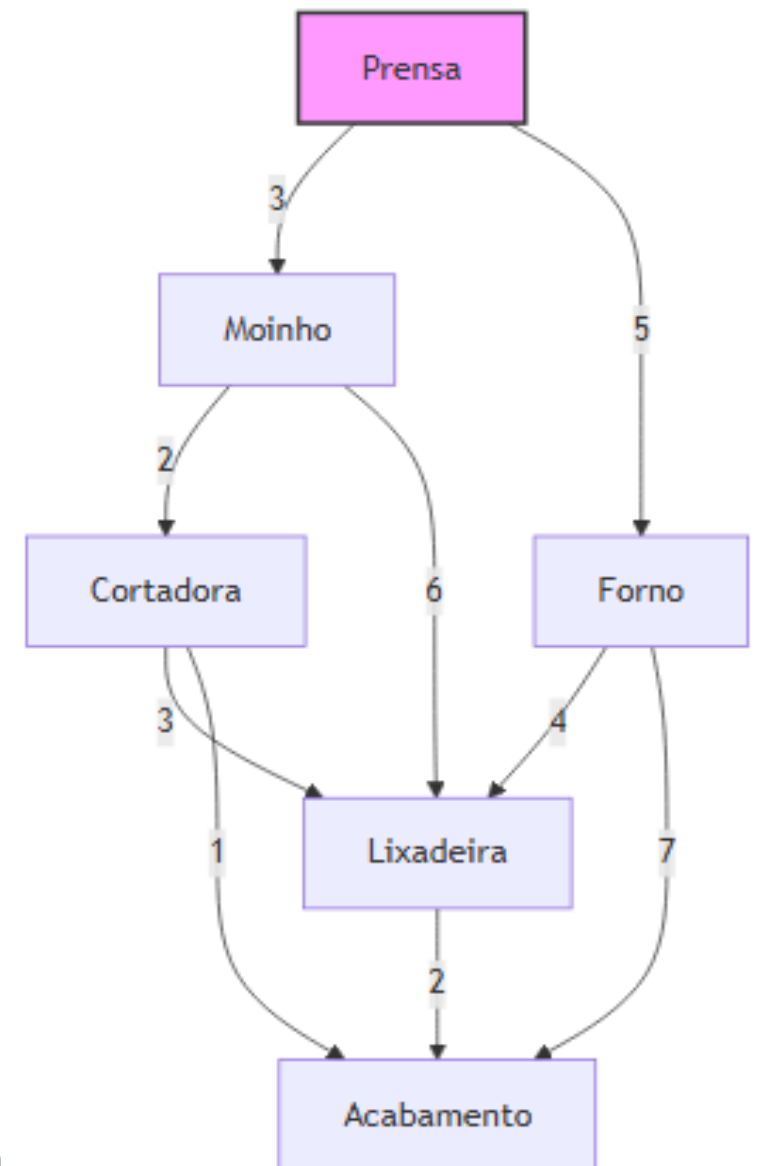
- Ambos os algoritmos produzem a mesma árvore geradora mínima em grafos sem pesos repetidos, garantindo unicidade da solução.
- A escolha entre eles depende do perfil do grafo: Kruskal destaca-se em grafos esparsos, Prim em densos.
- Kruskal beneficia-se da ordenação global e paralelização, facilitando uso em sistemas distribuídos.
- Prim se ajusta melhor a implementações que expandem um componente, como em roteadores de redes.
  - O volume de arestas e a estrutura de dados disponível podem influenciar na performance de cada algoritmo.
  - Fatores como facilidade de paralelização e tipo de armazenamento são determinantes na decisão do método.

# Analogia industrial para Prim e Kruskal

- Usando o exemplo de uma fábrica, cada máquina representa um vértice e as conexões possíveis são arestas com custos variados.
- Prim começa em uma máquina e conecta, sempre, a opção mais barata com outra máquina ainda desconectada.
- O crescimento se dá de forma local, conectando progressivamente novas máquinas à rede já formada.
- Kruskal seleciona as conexões mais baratas em todo o grafo, independentemente de sua localização inicial.
  - O critério é sempre evitar ciclos, garantindo que a rede final seja acíclica e conectada ao menor custo.
  - As duas abordagens ilustram diferentes estratégias para resolver o mesmo problema de otimização de conexões.

# Exemplo fabril

- O objetivo agora não é encontrar o caminho mais curto de uma máquina inicial (como em Dijkstra ou Bellman-Ford), mas sim conectar todas as máquinas da fábrica com tubos ou esteiras de transporte, gastando o menor custo possível, sem formar ciclos (loops).
- Algoritmo de Prim: "Expandir a partir de uma máquina".
- Algoritmo de Kruskal: "Escolher as conexões mais baratas primeiro".



# Exemplo fabril

## Resultado Prim – as conexões escolhidas são:

- Prensa → Moinho (3)
  - Moinho → Cortadora (2)
  - Cortadora → Acabamento (1)
  - Acabamento → Lixadeira (2)
  - Prensa → Forno (5)
  - Custo total:  $3 + 2 + 1 + 2 + 5 = 13$  unidades.
- 
- Característica principal: Prim "cresce" a rede a partir de uma máquina inicial, sempre escolhendo a conexão mais barata para uma máquina ainda não conectada, como se estivesse expandindo um sistema de tubos localmente.

# Exemplo fabril

## Resultado Kruskal – as conexões escolhidas são:

- Cortadora → Acabamento (1)
  - Moinho → Cortadora (2)
  - Acabamento → Lixadeira (2)
  - Prensa → Moinho (3)
  - Forno → Lixadeira (4)
  - Custo total:  $1 + 2 + 2 + 3 + 4 = 12$  unidades.
- 
- Característica principal: Kruskal escolhe as conexões mais baratas de todo o grafo, independentemente de onde estão, mas verifica se elas conectam máquinas que ainda não estão ligadas, evitando ciclos.

# Aplicação prática em sistemas distribuídos

- Árvores geradoras mínimas são fundamentais para projetar redes eficientes em ambientes de microsserviços e nuvem.
- A topologia resultante afeta diretamente a latência global e o custo operacional de sistemas distribuídos.
- O objetivo é equilibrar redundância para resiliência e contenção de custos para otimizar a infraestrutura.
- A espinha dorsal da comunicação pode ser modelada por uma árvore mínima, removendo enlaces desnecessários.
  - A análise desse modelo permite identificar a base eficiente para posterior adição de caminhos redundantes.
  - Em sistemas de larga escala, a árvore mínima serve de ponto de partida para ajustes finos de topologia.

# Estrutura das implementações em Python

- Python oferece recursos como `heapq` e `dataclasses` que simplificam a implementação dos algoritmos clássicos.
- O grafo é modelado como um dicionário de listas de adjacência e uma lista de arestas para rápida iteração.
- Arestas são objetos imutáveis, garantindo segurança na manipulação e no uso como chaves em dicionários.
- Union-Find é implementado com dicionários para pais e ranks, otimizando a detecção de ciclos em Kruskal.
  - Heap binário serve como fila de prioridade no algoritmo de Prim, assegurando seleções eficientes de arestas.
  - Funções auxiliares permitem carregar grafos de arquivos CSV, testar diferentes densidades e medir tempos de execução.

# Eficiência e aplicação dos algoritmos em contextos reais

- Kruskal apresenta complexidade  $O(E \log E)$ , favorecendo cenários com muitos vértices e poucas arestas.
- Prim exibe desempenho  $O(E \log V)$  com fila de prioridade, sendo vantajoso em grafos densos e completos.
- A modularidade e clareza do código facilitam ajustes, extensões e integração com sistemas maiores.
- A implementação serve como base para experimentos, validações conceituais e prototipagem de soluções reais.
  - A escolha do algoritmo deve considerar as características do grafo e o perfil de uso pretendido pela aplicação.
  - Dominar essas técnicas capacita profissionais a otimizar custos e desempenho em redes físicas e digitais.



# Interatividade

Assinale a alternativa correta sobre a construção de árvores geradoras mínimas em grafos ponderados utilizando os algoritmos de Kruskal e Prim.

- a) Kruskal constrói a árvore geradora mínima expandindo um componente único a partir de um vértice, usando fila de prioridade para escolher a aresta de menor peso.
- b) No algoritmo de Prim, as arestas são inicialmente ordenadas por peso, e o algoritmo seleciona as conexões mais baratas, evitando ciclos com estrutura união-busca.
- c) Kruskal é mais eficiente em grafos densos, enquanto Prim tem melhor desempenho em grafos esparsos, especialmente com uso de fila de Fibonacci.
- d) Em Kruskal, a verificação de ciclos é feita com estrutura união-busca (Union-Find), que une componentes desconexos e mantém a identificação dos conjuntos com eficiência.
- e) Ambos os algoritmos exigem ordenação das arestas por peso em cada iteração, resultando sempre em complexidade  $O(V^2)$ , independentemente do método.

## Resposta

Assinale a alternativa correta sobre a construção de árvores geradoras mínimas em grafos ponderados utilizando os algoritmos de Kruskal e Prim.

- a) Kruskal constrói a árvore geradora mínima expandindo um componente único a partir de um vértice, usando fila de prioridade para escolher a aresta de menor peso.
- b) No algoritmo de Prim, as arestas são inicialmente ordenadas por peso, e o algoritmo seleciona as conexões mais baratas, evitando ciclos com estrutura união-busca.
- c) Kruskal é mais eficiente em grafos densos, enquanto Prim tem melhor desempenho em grafos esparsos, especialmente com uso de fila de Fibonacci.
- d) Em Kruskal, a verificação de ciclos é feita com estrutura união-busca (Union-Find), que une componentes desconexos e mantém a identificação dos conjuntos com eficiência.
- e) Ambos os algoritmos exigem ordenação das arestas por peso em cada iteração, resultando sempre em complexidade  $O(V^2)$ , independentemente do método.

# Introdução à Divisão e Conquista

- O paradigma de divisão e conquista busca decompor problemas complexos em partes menores que se assemelham à questão original, promovendo raciocínio recursivo estruturado e reutilizável.
- Cada subproblema criado por divisão recebe tratamento independente, com suas soluções parciais posteriormente reunidas para formar a resposta global desejada.
- O método é apropriado quando a estrutura dos subproblemas não difere substancialmente do problema maior, facilitando o uso de algoritmos recursivos.
- Um dos benefícios consiste na possibilidade de aplicar estratégias específicas a cada parte, resultando em maior flexibilidade do que abordagens monolíticas.
  - A combinação das respostas individuais requer critério cuidadoso, pois erros nessa etapa comprometem a solução integral.
  - A divisão e conquista pode ser observada em vários problemas clássicos de algoritmos, incluindo busca, ordenação e otimização.

# O Problema da Mochila – Conceito

- O problema da mochila consiste em selecionar um subconjunto de objetos, cada um com peso e valor, sem ultrapassar um limite total de peso definido.
- O objetivo é maximizar o valor agregado dos itens escolhidos, respeitando a restrição imposta pela capacidade da mochila.
- Trata-se de um desafio clássico de otimização combinatória com aplicações que vão do transporte à alocação de recursos.
- A formulação permite interpretações variadas, adaptando-se a diferentes contextos, como duração, volume ou custo financeiro.
  - Frequentemente, as soluções exatas são inviáveis para grandes instâncias, justificando o uso de paradigmas como divisão e conquista.
  - A variante mais popular do problema é a chamada “mochila binária”, na qual cada item pode ser selecionado no máximo uma vez.

# O Problema da Mochila

Fonte: Imagem produzida pelo autor com tecnologia Grok 3, uma ferramenta de IA desenvolvida pela xAI.



# Divisão Inicial do Conjunto de Itens

- Uma aplicação direta de divisão e conquista divide o conjunto de  $n$  objetos em dois blocos de tamanho similar.
- Cada bloco é tratado isoladamente, facilitando o cálculo de soluções parciais sem interferência direta entre as partes.
- Esse fracionamento inicial pode ser feito de várias maneiras, desde divisões simétricas até critérios baseados em características dos itens.
- A divisão por metades permite balanceamento do esforço computacional e prepara o terreno para operações subsequentes eficientes.
  - O método se adapta tanto a implementações sequenciais quanto paralelas, dependendo do ambiente de execução.
  - A análise da estrutura dos blocos resultantes orienta o uso de algoritmos adequados para cada subinstância.



# Cálculo por Força Bruta em Blocos

- Para cada bloco, todos os subconjuntos possíveis são examinados por força bruta, registrando para cada peso o valor máximo correspondente.
- Esse método resulta em duas listas, cada uma representando as possíveis somas de peso e valor da metade dos itens originais.
- A abordagem por força bruta é viável porque o espaço de busca em cada bloco é reduzido em relação ao problema completo.
- O registro sistemático de pares (peso, valor) evita recomputações e permite fusão eficiente das informações na etapa seguinte.
  - A análise exaustiva em blocos menores reduz o crescimento exponencial observado em abordagens ingênuas aplicadas ao conjunto inteiro.
  - A técnica destaca-se por permitir tratamento independente dos blocos, promovendo modularidade do processo algorítmico.

# Analogia – Playlist e Problema da Mochila

- Planejar uma playlist para preencher exatamente uma hora, ou baixar músicas até ocupar quinhentos megabytes, equivale a resolver o problema da mochila.
- Cada música pode ser associada a um item com peso (duração ou tamanho) e valor (pontuação de preferência ou relevância).
- O desafio consiste em maximizar a soma das notas das faixas escolhidas sem ultrapassar o tempo ou espaço disponível.
- Essa modelagem facilita a aplicação de algoritmos de otimização já consolidados para personalização de experiências de usuário.
  - A correspondência entre elementos do problema clássico e o cenário de streaming é direta, possibilitando tradução imediata do raciocínio.
  - Plataformas de música utilizam variações desse modelo para sugerir e ajustar playlists em tempo real para milhões de usuários.



# Analogia – Playlist e Problema da Mochila

Fonte: Imagem produzida pelo autor com tecnologia Grok 3, uma ferramenta de IA desenvolvida pela xAI.

As marcas, imagens e fotos aqui analisadas e citadas são meramente exemplificativas para o contexto da aula e pertencem ao Spotify, que é detentor dos direitos de propriedade industrial e intelectual.



# Analogia – Playlist e Problema da Mochila

```
from __future__ import annotations
from dataclasses import dataclass
from typing import List, Tuple

@dataclass
class Musica:
    id: str
    duracao: int          # segundos
    nota: int             # preferência 0-100
```

# Analogia – Playlist e Problema da Mochila

```
def mochila_playlist(musicas: List[Musica], limite_seg: int) -> Tuple[int, List[Musica]]:
    n = len(musicas)
    # matriz de valores: duas linhas para economia de memória
    dp = [[0]*(limite_seg+1) for _ in range(2)]
    # matriz booleana que marca inclusão da música na solução
    escolha = [[False]*(limite_seg+1) for _ in range(n)]

    for i in range(n):
        atual = i % 2
        prev = (i-1) % 2
        dur = musicas[i].duracao
        val = musicas[i].nota
```

# Analogia – Playlist e Problema da Mochila

```
for s in range(limite_seg + 1):  
    if dur <= s:  
        incluir = val + dp[prev][s - dur]  
        nao_incluir = dp[prev][s]  
        if incluir > nao_incluir:  
            dp[atual][s] = incluir  
            escolha[i][s] = True  
        else:  
            dp[atual][s] = nao_incluir  
    else:  
        dp[atual][s] = dp[prev][s]
```

# Analogia – Playlist e Problema da Mochila

```
# reconstrução do conjunto de músicas
s = limite_seg
selecionadas: List[Musica] = []
for i in range(n-1, -1, -1):
    if escolha[i][s]:
        selecionadas.append(musicas[i])
        s -= musicas[i].duracao
selecionadas.reverse()
return dp[(n-1)%2][limite_seg], selecionadas
```

# Aplicação Prática na Indústria de Streaming

- Grandes serviços de música como Spotify empregam divisão e conquista para decompor problemas globais em subproblemas administráveis.
- A fragmentação do catálogo em grupos temáticos ou intervalos de duração viabiliza cálculos em paralelo e respostas rápidas.
- A atualização dinâmica de playlists, necessária diante de novos lançamentos, é facilitada pela estrutura modular do algoritmo.
- O modelo permite manter recomendações personalizadas mesmo com catálogos que atingem dezenas de milhões de faixas.
  - Divisão em blocos menores acelera adaptações a preferências individuais sem reprocessar todo o universo de músicas.
  - A estratégia eleva a escalabilidade do serviço, essencial para operar em ambientes com alta concorrência de acessos.

# Interatividade

Considerando a estratégia de divisão e conquista aplicada ao problema da mochila, assinale a alternativa que explique corretamente a principal vantagem do método de divisão em dois blocos e posterior fusão das soluções, quando comparado à busca exaustiva tradicional.

- a) O método permite sempre ignorar os itens de menor valor, bastando analisar apenas subconjuntos com peso total igual à metade da capacidade da mochila.
- b) A divisão em blocos reduz a complexidade do problema para  $O(n)$ , tornando-o viável mesmo para centenas de itens e pequenas capacidades.
- c) A abordagem de divisão em dois blocos possibilita gerar listas menores, eliminar redundâncias por peso e combinar soluções com busca binária, reduzindo significativamente o número de combinações analisadas.
  - d) A técnica elimina a necessidade de considerar a capacidade da mochila, pois apenas o valor total dos itens é relevante para a fusão dos blocos.
  - e) O método exige que todos os subproblemas sejam resolvidos sequencialmente, impossibilitando qualquer forma de paralelismo ou execução distribuída.



# Resposta

Considerando a estratégia de divisão e conquista aplicada ao problema da mochila, assinale a alternativa que explique corretamente a principal vantagem do método de divisão em dois blocos e posterior fusão das soluções, quando comparado à busca exaustiva tradicional.

- a) O método permite sempre ignorar os itens de menor valor, bastando analisar apenas subconjuntos com peso total igual à metade da capacidade da mochila.
- b) A divisão em blocos reduz a complexidade do problema para  $O(n)$ , tornando-o viável mesmo para centenas de itens e pequenas capacidades.
- c) A abordagem de divisão em dois blocos possibilita gerar listas menores, eliminar redundâncias por peso e combinar soluções com busca binária, reduzindo significativamente o número de combinações analisadas.
- d) A técnica elimina a necessidade de considerar a capacidade da mochila, pois apenas o valor total dos itens é relevante para a fusão dos blocos.
- e) O método exige que todos os subproblemas sejam resolvidos sequencialmente, impossibilitando qualquer forma de paralelismo ou execução distribuída.



# Fundamentos da Programação Dinâmica

- A programação dinâmica resolve problemas recursivos com subestruturas repetidas, armazenando respostas intermediárias para evitar cálculos redundantes e melhorar a eficiência computacional.
- Esse paradigma parte da decomposição do problema em subinstâncias de formato idêntico, permitindo que a solução global seja construída a partir das soluções ótimas das partes.
- A técnica identifica sobreposição de subproblemas: situações em que certas configurações retornam múltiplas vezes durante a recursão e, se memorizadas, economizam tempo.
- O uso de tabelas para guardar resultados reduz a complexidade de tempo de muitos problemas de exponencial para polinomial, tornando-os tratáveis na prática.
  - A economia de memória é viabilizada porque cada subinstância é resolvida uma única vez, em vez de repetir cálculos para configurações já analisadas.
  - Esse modelo é amplamente utilizado em contextos de otimização e busca de soluções exatas, especialmente onde há recombinação frequente de subproblemas.

# Características Estruturais dos Problemas

- A programação dinâmica é adequada para problemas que podem ser quebrados em subinstâncias menores com o mesmo formato estrutural do original.
- A construção da solução global ocorre pela combinação ótima das respostas dos subproblemas resolvidos, mantendo dependência lógica entre etapas.
- O sucesso da técnica exige reconhecimento prévio de subestruturas comuns e definição clara das relações de dependência.
- Não basta quebrar o problema em partes; é fundamental garantir que cada subinstância contribua diretamente para a solução maior.
  - O paradigma é aplicável apenas quando o espaço de subproblemas possíveis é gerenciável, evitando explosão de memória.
  - O uso de tabelas ou dicionários de armazenamento depende do número de combinações relevantes a serem guardadas durante o processo.

# A Subsequência Comum Mais Longa (LCS)

- O problema da subsequência comum mais longa busca a maior sequência ordenada de caracteres que aparece em duas cadeias, preservando a ordem relativa.
- A LCS ignora se os símbolos são contíguos, importando apenas que mantenham a sequência, o que permite flexibilidade na comparação.
- Uma abordagem recursiva pura testa todas as remoções possíveis de caracteres, resultando em crescimento exponencial do número de casos.
- Programação dinâmica reduz drasticamente o tempo, explorando apenas combinações essenciais e reutilizando respostas de prefixos analisados.
  - O algoritmo baseia-se em decidir, para cada par de prefixos das cadeias, se o caractere corrente é incluído ou se o melhor resultado é herdado de subproblemas.
  - A resposta é construída progressivamente, avançando nas cadeias, sem voltar a analisar sequências já comparadas anteriormente.

# Construção da Tabela Dinâmica

- A solução da LCS utiliza uma tabela bidimensional, cujas dimensões são os tamanhos das cadeias comparadas, preenchida de maneira incremental.
- Cada célula da tabela corresponde à solução ótima para os prefixos terminados naquela posição nas duas cadeias.
- O preenchimento pode ser feito linha por linha ou coluna por coluna, com cada célula recebendo valores das células vizinhas já computadas.
- O algoritmo diferencia dois casos: caracteres iguais (incrementa a resposta anterior) e caracteres diferentes (escolhe o maior valor entre eliminar um ou outro).
  - O custo de tempo e memória da solução é  $O(n \cdot m)$ , onde  $n$  e  $m$  são os comprimentos das cadeias, tornando a abordagem eficiente para sequências moderadas.
  - A tabela permite recuperar a própria subsequência comum, não apenas seu tamanho, por meio de percurso inverso a partir do resultado final.

# Aplicações Práticas da Programação Dinâmica

- Programação dinâmica vai além do problema de LCS, sendo essencial em bioinformática para alinhamento de sequências de DNA e proteínas.
- O paradigma resolve o cálculo de rotas mínimas em grafos, exemplificado pelo algoritmo de Floyd-Warshall em redes com pesos não negativos.
- Problemas de corte de hastes metálicas na indústria utilizam programação dinâmica para maximizar valor a partir de combinações de cortes possíveis.
- Em cada aplicação, identificar padrões de sobreposição e formular a relação de recorrência entre subproblemas é etapa crítica.
  - Python, por sua clareza sintática, facilita a transcrição de recorrências matemáticas para código, garantindo compreensão e depuração.
  - A metodologia transforma problemas aparentemente intratáveis em soluções eficientes, ampliando o leque de desafios solucionáveis.

# Vantagens e Limitações da Programação Dinâmica

- A principal vantagem reside na redução do tempo de execução, pois evita recomputar respostas de subinstâncias já resolvidas.
- O consumo de memória, embora menor que a busca exaustiva, ainda depende do número total de subproblemas distintos armazenados.
- A técnica não é aplicável quando não há subproblemas sobrepostos ou quando a decomposição não leva a instâncias de mesmo formato.
- Problemas que exigem apenas análise sequencial ou não possuem estrutura recursiva dificilmente se beneficiam de programação dinâmica.
  - Otimizações adicionais podem ser alcançadas armazenando apenas linhas ou colunas relevantes da tabela, reduzindo o espaço ocupado.
  - O paradigma demanda esforço inicial de modelagem, exigindo compreensão das dependências e da relação entre os subproblemas.

# LCS em Redes Sociais – Afinidade de Emojis

- O estudo de afinidade entre usuários pode ser modelado pela LCS, aplicando-se às sequências de reações rápidas com emojis em stories do Instagram.
- O algoritmo busca a maior subsequência ordenada de emojis que aparece nas interações de ambos os perfis, ignorando outros símbolos.
- Um alto valor de LCS sugere sincronia e repertório emocional compartilhado entre os amigos, fortalecendo a percepção de afinidade.
- A análise considera apenas a ordem relativa dos emojis, não a data exata ou a presença de outros emojis intermediários.
  - Tal aplicação demonstra como um conceito algorítmico pode ser usado para quantificar aspectos sociais e de comportamento digital.
  - Técnicas formais, como programação dinâmica, iluminam padrões ocultos na interação cotidiana de usuários em ambientes virtuais.

# LCS em Redes Sociais – Afinidade de Emojis

```
from __future__ import annotations
from dataclasses import dataclass
from typing import List, Tuple

@dataclass
class Perfil:
    nome: str
    reacoes: str    # sequência como string de códigos 'R','C','A'
```



# LCS em Redes Sociais – Afinidade de Emojis

```
def lcs_quase_linear(a: str, b: str) -> Tuple[int, str]:  
    if len(a) < len(b): # garante que b seja a menor para poupar memória  
        a, b = b, a  
    m, n = len(a), len(b)  
    dp = [[0]*(n+1) for _ in range(2)]  
    caminho: List[List[int]] = [[0]*(n+1) for _ in range(m+1)]  
    for i in range(1, m+1):  
        linha_atual = i % 2  
        linha_ant = (i-1) % 2
```

# LCS em Redes Sociais – Afinidade de Emojis

```
for j in range(1, n+1):
    if a[i-1] == b[j-1]:
        dp[linha_atual][j] = dp[linha_ant][j-1] + 1
        caminho[i][j] = 1          # diagonal
    else:
        if dp[linha_ant][j] >= dp[linha_atual][j-1]:
            dp[linha_atual][j] = dp[linha_ant][j]
            caminho[i][j] = 2      # cima
        else:
            dp[linha_atual][j] = dp[linha_atual][j-1]
            caminho[i][j] = 3      # esquerda
```

# LCS em Redes Sociais – Afinidade de Emojis

```
# reconstrução da subsequência
lcs_lista: List[str] = []
i, j = m, n
while i > 0 and j > 0:
    if caminho[i][j] == 1:
        lcs_lista.append(a[i-1])
        i -= 1
        j -= 1
    elif caminho[i][j] == 2:
        i -= 1
    else:
        j -= 1
return dp[m % 2][n],
"".join(reversed(lcs_lista))
```

# Interatividade

Considerando os princípios da programação dinâmica, qual das alternativas descreve corretamente o motivo pelo qual esse paradigma reduz a complexidade temporal de problemas como a subsequência comum mais longa (LCS)?

- a) Porque permite quebrar qualquer problema em partes independentes, sem necessidade de armazenar resultados intermediários.
- b) Porque evita recalcular soluções de subproblemas já resolvidos, armazenando os resultados em uma tabela para consultas futuras.
- c) Porque realiza buscas exaustivas por todas as soluções possíveis, garantindo sempre o melhor resultado ao custo de memória elevado.
  - d) Porque utiliza exclusivamente abordagens iterativas, tornando recursão desnecessária para todos os problemas.
  - e) Porque emprega paralelismo automático em todas as etapas, independentemente do problema ou do ambiente de execução.

## Resposta

Considerando os princípios da programação dinâmica, qual das alternativas descreve corretamente o motivo pelo qual esse paradigma reduz a complexidade temporal de problemas como a subsequência comum mais longa (LCS)?

- a) Porque permite quebrar qualquer problema em partes independentes, sem necessidade de armazenar resultados intermediários.
- b) Porque evita recalcular soluções de subproblemas já resolvidos, armazenando os resultados em uma tabela para consultas futuras.
- c) Porque realiza buscas exaustivas por todas as soluções possíveis, garantindo sempre o melhor resultado ao custo de memória elevado.
  - d) Porque utiliza exclusivamente abordagens iterativas, tornando recursão desnecessária para todos os problemas.
  - e) Porque emprega paralelismo automático em todas as etapas, independentemente do problema ou do ambiente de execução.

# Referências

- AHO, A. V.; HOPCROFT, J. ; ULLMAN, J. *Estruturas de dados e algoritmos*. Porto Alegre: Bookman, 2002.
- BEAZLEY, D.; JONES, B. K. *Python cookbook: recipes for mastering Python 3*. 3. ed. O'Reilly Media, 2013.
- CORMEN, H. *et al. Algoritmos: teoria e prática*. 4. ed. LTC, 2024.
- FURTADO, A. L. *Python: programação para leigos*. Rio de Janeiro: Alta Books, 2021.
- KNUTH, D. *The art of computer programming*. 3. ed. Addison-Wesley Professional, v. 2, 1997.

# Referências

- LUTZ, M. *Learning Python*. 5. ed. O'Reilly Media, 2013.
- NILO, L. E. *Introdução à programação com Python*. São Paulo: Novatec, 2019.
- SILVEIRA, B. R. *Desenvolvimento web com Python e Flask*. São Paulo: Casa do Código, 2021.
- VAN ROSSUM, G.; DRAKE, F. L. *Python reference manual*. PythonLabs, 2007.
- VIEIRA, A. *Introdução à ciência da computação com Python*. Rio de Janeiro: LTC, 2020.
- WING, J. M. Computational thinking. *Communications of the ACM*, v. 49, n. 3, p. 33-35, 2006.
- ZAVAGLIA, F. *Lógica de programação: a construção de algoritmos e estruturas de dados*. São Paulo: Érica, 2017.

**ATÉ A PRÓXIMA!**