

Unidade III

5 PROCESSAMENTO DE LINGUAGEM NATURAL (PLN)

Também conhecido como natural language processing (NLP), o PLN é uma área da inteligência artificial dedicada a permitir que máquinas compreendam, interpretem, gerem e interajam usando linguagem humana. Com o crescente volume de informações em formato textual e falado, o PLN se tornou essencial para desenvolver sistemas que se comuniquem de forma mais natural com os usuários.

O PLN é a união entre linguística computacional, inteligência artificial e aprendizado de máquina com o objetivo de processar e analisar a linguagem humana de maneira significativa. Ele busca traduzir a linguagem humana em representações que uma máquina possa manipular e, ao mesmo tempo, gerar linguagem compreensível para os seres humanos.

Os principais objetivos do PLN envolvem a capacidade de compreender o significado de textos e falas humanas, permitindo que sistemas computacionais interpretem, analisem e processem a linguagem de maneira eficiente. A extração de informações relevantes a partir de grandes volumes de dados linguísticos, possibilitando que os sistemas identifiquem padrões, temas e intenções presentes nas comunicações humanas, está entre as metas centrais do PLN. Além disso, o processamento de linguagem natural busca gerar automaticamente respostas coerentes, resumos de textos, traduções entre idiomas e análises semânticas, contribuindo para a automação de tarefas complexas. Outro objetivo fundamental é possibilitar a interação fluida entre humanos e máquinas, por meio da linguagem natural, promovendo interfaces mais acessíveis, intuitivas e inteligentes em assistentes virtuais, chatbots, mecanismos de busca e diversas outras aplicações.

O PLN possui uma ampla gama de aplicações práticas em diversas áreas, contribuindo significativamente para a melhoria da interação entre seres humanos e sistemas computacionais. No atendimento automatizado, por exemplo, o PLN permite o desenvolvimento de chatbots e assistentes virtuais, como a Alexa e a Siri, capazes de compreender comandos e oferecer respostas naturais. Na área de tradução automática, ferramentas como o Google Tradutor utilizam técnicas de PLN para traduzir textos em tempo real com crescente precisão.

Outro campo de destaque é a análise de sentimentos, que consiste em classificar automaticamente opiniões expressas em redes sociais, avaliações de produtos ou comentários de usuários, ajudando empresas a monitorar a percepção pública sobre suas marcas. O reconhecimento de fala é mais uma aplicação relevante, em que a voz do usuário é convertida em texto, possibilitando recursos como ditado por voz e comandos falados.

Além disso, o PLN é utilizado em sistemas de recomendação, analisando textos de preferências e avaliações para oferecer sugestões mais personalizadas aos usuários. A extração de informações é outra aplicação importante, pois permite identificar automaticamente entidades, datas, locais e outros dados

relevantes em documentos extensos, facilitando a organização e o acesso à informação. Por fim, o PLN também é capaz de realizar a geração automática de texto, criando resumos, e-mails, descrições de produtos e outros conteúdos com base em dados fornecidos, o que agiliza processos e amplia a produtividade em ambientes corporativos e digitais.

Tarefas comuns no PLN:

- **Tokenização:** divide um texto em unidades menores chamadas tokens (palavras, frases ou sílabas). Exemplo: texto: "Hoje é um ótimo dia." → Tokens: ["Hoje", "é", "um", "ótimo", "dia", "."].
- **Stemização:** reduz palavras à sua raiz (ex.: "correr", "correndo" → "corr").
- **Lematização:** reduz palavras à sua forma base correta (ex.: "correndo" → "correr").
- **Análise de sentimentos:** determina a polaridade emocional de um texto (positivo, negativo e neutro). Exemplo: "Achei o serviço excelente." → Sentimento: positivo.
- **Reconhecimento de entidades nomeadas (NER):** identifica nomes próprios e categorias importantes em textos (pessoas, organizações, locais e datas). Exemplo: "Vanessa trabalha na UNIP desde 2019." → Pessoa: Vanessa, organização: UNIP, data: 2019.
- **Classificação de texto:** associa categorias a textos. Pode ser usada para classificar e-mails como spam ou não spam, por exemplo.

Técnicas utilizadas em PLN:

- **Regras e modelos estatísticos:** essa abordagem se baseia na aplicação de regras linguísticas ou em modelos probabilísticos construídos a partir de grandes conjuntos de dados textuais. Técnicas como os modelos de Markov e o Naive Bayes são exemplos clássicos que utilizam a frequência e a probabilidade de ocorrência de palavras ou sequências linguísticas para realizar tarefas como análise morfo sintática, segmentação de texto e classificação básica.
- **Aprendizado de máquina:** o uso de modelos supervisionados e não supervisionados permite que algoritmos sejam treinados para tarefas como classificação de textos, detecção de padrões e clusterização semântica. Dentre os algoritmos mais utilizados nesse contexto estão o SVM, o Random Forest e o k-NN, que se destacam por sua capacidade de aprender com base em exemplos previamente rotulados ou em estruturas ocultas nos dados.



Observação

O SVM é um algoritmo de aprendizado supervisionado utilizado principalmente para tarefas de classificação, embora também possa ser aplicado à regressão. Sua principal ideia é encontrar um hiperplano ótimo que separe os dados em diferentes classes com a maior margem possível entre os pontos de diferentes categorias. O SVM é eficaz em problemas com grande dimensionalidade e pode ser adaptado para resolver problemas não lineares por meio do uso de funções kernel, que transformam os dados em espaços de maior dimensão nos quais a separação linear se torna possível.

O Random Forest é um algoritmo de aprendizado de máquina baseado em conjuntos de árvores de decisão. Ele funciona construindo várias árvores durante o treinamento e tomando decisões com base na votação da maioria (para classificação) ou na média dos resultados (para regressão). A ideia central é reduzir o risco de overfitting que ocorre com uma única árvore, aumentando a precisão e a robustez do modelo. Como cada árvore é construída a partir de uma amostra aleatória dos dados e das variáveis, o Random Forest é altamente eficiente em lidar com dados complexos, ruidosos ou com grande número de variáveis.

Já o k-NN é um algoritmo simples, mas eficaz, baseado em instâncias, que classifica um novo ponto de dados com base nos K pontos mais próximos já conhecidos no conjunto de treinamento. A distância (geralmente euclidiana) é usada para determinar a similaridade entre os dados, e a classe mais comum entre os vizinhos determina a classificação do novo ponto. Por ser um método preguiçoso (lazy learning), o k-NN não constrói um modelo prévio, mas realiza todos os cálculos no momento da previsão, o que o torna sensível à escala dos dados e ao valor de K escolhido.

Deep learning e redes neurais

As abordagens baseadas em deep learning utilizam redes neurais profundas, com destaque para as RNNs e os transformers, como o Bidirectional Encoder Representations from Transformers (BERT) e o Generative Pre-trained Transformer (GPT). Esses modelos oferecem desempenho significativamente superior em tarefas de compreensão contextual, tradução automática, resposta a perguntas e geração de linguagem natural devido à sua capacidade de capturar dependências complexas e relações semânticas profundas em grandes volumes de texto.

Exemplo de pipeline de PLN

Um pipeline de PLN consiste em uma sequência estruturada de etapas que permitem transformar dados linguísticos brutos em informações úteis e interpretáveis por sistemas computacionais. O processo começa com a **coleta de dados**, que pode envolver textos, falas ou mensagens oriundas de diversas fontes, como redes sociais, assistentes virtuais, e-mails ou documentos.

Em seguida, realiza-se o **pré-processamento**, etapa essencial para a limpeza e a padronização dos dados, em que são aplicadas técnicas como remoção de ruídos, tokenização (quebra do texto em unidades menores, como palavras), remoção de stopwords e lematização (redução das palavras à sua forma base).

Com os dados limpos, passa-se para a **extração de características**, na qual os textos são convertidos em representações numéricas que podem ser processadas por algoritmos. Isso pode ser feito por meio de vetorização tradicional (como Bag of Words ou TF-IDF) ou métodos mais avançados, como os embeddings, que capturam o significado semântico das palavras em espaços vetoriais.

Na etapa seguinte, realiza-se o **treinamento do modelo**, que pode envolver tarefas como classificação de textos, análise de sentimentos ou identificação de tópicos, utilizando algoritmos de aprendizado de máquina ou redes neurais profundas. Após o treinamento, o modelo é submetido a uma fase de **avaliação e ajuste**, na qual seu desempenho é analisado com métricas específicas, e seus parâmetros são refinados para melhorar a precisão e a generalização.

Por fim, o modelo é **aplicado em sistemas reais**, sendo integrado a interfaces com o usuário, assistentes inteligentes, plataformas de atendimento automático ou mecanismos de análise de conteúdo, permitindo uma interação mais inteligente, eficiente e natural entre humanos e máquinas.

O PLN enfrenta diversos desafios que impactam diretamente a precisão e a eficiência dos sistemas. Um dos principais é a ambiguidade semântica, pois muitas palavras podem assumir múltiplos significados dependendo do contexto em que são utilizadas – por exemplo, a palavra "banco" pode se referir tanto a uma instituição financeira quanto a um assento. Outro obstáculo relevante é a variação linguística, que abrange diferenças regionais, uso de gírias, variações culturais e até mesmo erros gramaticais presentes em textos reais, tornando mais difícil a padronização e a interpretação correta da linguagem.

Além disso, o PLN ainda encontra limitações ao lidar com sarcasmo e ironia, que exigem uma compreensão mais profunda da intenção comunicativa por trás das palavras, algo que vai além do significado literal. Por fim, o contexto e a dependência temporal representam desafios significativos, já que o sentido de uma expressão pode mudar de acordo com o contexto imediato da conversa ou com o tempo – termos que eram comuns ou neutros em determinado período podem ganhar conotações diferentes com o passar dos anos. Esses desafios exigem soluções cada vez mais sofisticadas, como o uso de modelos de linguagem baseados em deep learning e o treinamento com dados contextualizados e atualizados.

Nas últimas décadas, o PLN tem avançado significativamente, impulsionado principalmente pelo surgimento de modelos baseados na arquitetura transformer, como o BERT, o GPT e o Text-to-Text Transfer Transformer (T5). Esses modelos revolucionaram a forma como as máquinas compreendem e geram linguagem, oferecendo um nível de entendimento contextual muito mais profundo e produzindo textos com fluidez e coerência comparáveis à linguagem humana.

Outro avanço importante é o desenvolvimento de modelos multilíngues e de técnicas como o zero-shot learning (ZSL), que permitem a generalização para diferentes idiomas e tarefas sem a necessidade de um treinamento específico para cada caso. Isso amplia enormemente a escalabilidade e aplicabilidade das soluções de PLN, especialmente em cenários globais.

Além disso, o PLN passou a ser fundamental em sistemas de IA generativa, sendo utilizado em ferramentas como assistentes de redação, geradores de código, tradutores inteligentes e plataformas de conversação natural, que interagem com os usuários de maneira cada vez mais personalizada e eficiente. Esses avanços consolidam o PLN como uma das áreas mais dinâmicas e promissoras da IA moderna.

5.1 Engenharia de prompt: interagindo com modelos de linguagem natural

Engenharia de prompt é a prática de projetar, testar e refinar instruções textuais (prompts) para direcionar o comportamento de LLMs, como o GPT, de forma eficiente e segura. Diferentemente do desenvolvimento tradicional, em que algoritmos são codificados de forma direta, aqui o comportamento do modelo é influenciado por instruções em linguagem natural.



Observação

LLM é a sigla para *large language model*, que em português significa "modelo de linguagem de grande escala".

Um LLM é um tipo de modelo de IA treinado com grandes volumes de texto para entender, gerar, traduzir e responder em linguagem natural. Esses modelos são baseados em redes neurais profundas, geralmente da arquitetura transformer, e são capazes de realizar diversas tarefas de PLN sem necessidade de treinamento específico para cada uma delas.

Os LLMs são treinados com grandes volumes de dados textuais e são capazes de responder a uma vasta gama de tarefas, desde tradução e resumo até raciocínio lógico e programação. No entanto, seu desempenho depende fortemente da forma como a tarefa é apresentada. A engenharia de prompt surge, portanto, como uma habilidade estratégica para extrair o melhor desempenho desses modelos sem a necessidade de fine-tuning adicional. A seguir, serão apresentados os principais tipos de prompt utilizados.

- **Zero-shot:** nesse tipo de abordagem, o modelo é solicitado a realizar uma tarefa sem receber exemplos prévios de entrada e saída. A instrução é fornecida de forma direta, e o modelo utiliza

apenas o conhecimento prévio aprendido durante o treinamento. Exemplo: "Resuma o seguinte texto em três frases claras".

- **Few-shot:** aqui, o prompt inclui um pequeno número de exemplos ilustrativos para orientar o modelo sobre o padrão desejado de resposta. Essa técnica ajuda a melhorar a precisão em tarefas específicas, ao mostrar ao modelo como ele deve se comportar. Exemplo: "Entrada: O céu está nublado. → Saída: Previsão de chuva. Agora processe: Entrada: Céu limpo e sol forte. → Saída:".
- **Chain-of-thought (cadeia de pensamento):** esse tipo de prompt incentiva o modelo a explicitar seu raciocínio passo a passo antes de apresentar uma resposta final. É especialmente útil para tarefas que exigem lógica, cálculo ou inferência. Exemplo: "Resolva o problema e explique o raciocínio: Se João tem 3 maçãs e ganha mais 2, quantas ele tem agora?".
- **Prompts com atribuição de papéis:** consistem em instruções que colocam o modelo em um papel ou persona específica, permitindo que ele adapte o estilo e o conteúdo da resposta conforme o contexto desejado. Exemplo: "Você é um médico explicando o diagnóstico de diabetes a um paciente leigo. Use linguagem simples e empática".

Boas práticas

A formulação eficaz de prompts é essencial para garantir que modelos de linguagem gerem respostas relevantes, claras e seguras. Algumas boas práticas recomendadas incluem diretrizes que se aplicam a diversas áreas de uso e que podem ser ilustradas por exemplos práticos.

A primeira recomendação importante é manter a especificidade e a objetividade. Redigir prompts de forma clara, direta e sem ambiguidade evita que o modelo gere respostas genéricas ou incoerentes. Por exemplo, ao invés de perguntar "Explique inteligência artificial", o que pode resultar em uma explicação ampla e pouco direcionada, é mais eficaz solicitar: "Explique o conceito de inteligência artificial para alunos do ensino médio, usando exemplos do cotidiano em um parágrafo curto". Essa formulação direciona o conteúdo, o estilo e o nível de complexidade esperados.

A definição do formato de saída também é essencial. Informar explicitamente se deseja uma lista, um parágrafo, uma tabela ou um trecho de código ajuda o modelo a estruturar corretamente a resposta. Por exemplo, ao solicitar "Liste os principais sintomas da gripe em formato de tópicos curtos e objetivos", evita-se que a resposta venha em um texto corrido ou com excesso de explicações técnicas.

Outra prática relevante é o uso de exemplos ilustrativos. Em tarefas complexas, fornecer exemplos positivos (corretos) e negativos (indesejados) ajuda o modelo a entender o padrão esperado. Suponha que se deseje classificar sentenças como positivas ou negativas: fornecer ao modelo exemplos como "O produto é excelente → Positiva" e "Demorou muito para chegar → Negativa" é mais eficaz do que apenas dizer "Classifique sentimentos".

A iteração e o refinamento do prompt são processos fundamentais. É comum que a primeira formulação não gere o resultado ideal. Assim, testar versões alternativas e observar como pequenas alterações impactam a resposta permite aprimorar continuamente a interação com o modelo. Por exemplo, ao pedir "Resuma este artigo", o modelo pode devolver um parágrafo excessivamente longo. Alterando o prompt para "Resuma este artigo em três frases objetivas", o retorno tende a ser mais adequado ao objetivo.

Por fim, é fundamental considerar o contexto e o público-alvo da aplicação. A linguagem e o estilo devem ser adaptados conforme o perfil do usuário final. Um mesmo conteúdo técnico, como "Explicar o funcionamento de uma rede neural", deve ser apresentado de forma diferente para um público leigo (com analogias simples e sem jargões) e para especialistas (com termos técnicos e aprofundamento conceitual).

A aplicação combinada dessas boas práticas resulta em prompts mais eficazes e modelos mais alinhados às necessidades humanas, contribuindo para interações mais seguras, produtivas e éticas com sistemas baseados em IA.

Limitações e riscos

Apesar de ser uma técnica poderosa e versátil, a engenharia de prompt também apresenta limitações e riscos que merecem atenção especial. Um dos desafios mais recorrentes é a alucinação de informações, situação em que o modelo gera respostas incorretas ou inventadas, mas com aparente confiança e fluidez, o que pode induzir o usuário ao erro, especialmente em contextos técnicos, acadêmicos ou médicos.

Outro aspecto crítico é a sensibilidade ao prompt. Pequenas variações na formulação da pergunta podem resultar em respostas significativamente diferentes, tanto em conteúdo quanto em qualidade. Isso exige um processo contínuo de refinamento e validação para garantir consistência e utilidade nas respostas geradas.

A indução de vieses também representa um risco importante. O modelo pode refletir preconceitos implícitos presentes nos dados com os quais foi treinado ou ser influenciado por escolhas na formulação do prompt. Isso pode levar à reprodução de estereótipos, à exclusão de grupos sociais ou à tomada de decisões discriminatórias.

Além disso, há a questão da falta de transparência. Muitos modelos operam como verdadeiras "caixas-pretas", dificultando a interpretação das razões por trás de determinadas respostas. Isso compromete a rastreabilidade, a confiabilidade e a responsabilização em aplicações sensíveis, como saúde, justiça ou finanças.

Essas limitações não anulam o valor da engenharia de prompt, mas reforçam a importância de sua aplicação consciente, crítica e contextualizada, aliada a práticas de validação humana, auditoria e supervisão ética contínua.

5.1.1 Ferramentas e frameworks

Com o aumento do uso de LLMs, diversos frameworks e ferramentas foram desenvolvidos para facilitar a criação, o gerenciamento e a experimentação com prompts. Esses recursos são fundamentais para tornar o processo mais controlado, eficiente e integrado a outras aplicações de inteligência artificial.

- **PromptLayer:** é uma plataforma voltada para o versionamento, o rastreamento e a análise de prompts utilizados com APIs de modelos de linguagem. Ela permite registrar automaticamente os prompts enviados e as respostas recebidas e avaliar o desempenho de diferentes versões, o que é essencial para testes comparativos e auditoria.
- **LangChain:** trata-se de um framework avançado que permite encadear múltiplos prompts e interações entre o modelo e ferramentas externas, como bancos de dados, APIs, navegadores e até planilhas. Com ele, é possível criar pipelines complexos que integram o raciocínio do modelo com a busca em fontes externas e a execução de lógica de programação – tudo orientado por linguagem natural.
- **LlamaIndex (antigo GPT Index):** é uma biblioteca voltada a conectar modelos de linguagem a fontes de dados estruturadas ou não estruturadas, como arquivos, bancos de dados ou documentos corporativos. Ela facilita a criação de sistemas de busca inteligentes e a resposta a perguntas baseadas em conteúdo específico.
- **OpenAI Playground:** é um ambiente interativo que permite testar e ajustar prompts em tempo real com diferentes parâmetros, como temperatura, frequência e comprimento da resposta. É ideal para prototipagem rápida, experimentação educacional ou desenvolvimento de aplicações baseadas em linguagem natural.

Essas ferramentas ampliam significativamente o potencial da engenharia de prompt, tornando possível construir aplicações mais robustas, seguras e personalizadas com base em LLMs.

Aplicações práticas

A engenharia de prompt tem se mostrado uma ferramenta versátil e estratégica, sendo aplicada com sucesso em diversas áreas do conhecimento e da indústria. Ao explorar o poder dos modelos de linguagem, diferentes setores têm obtido ganhos expressivos em produtividade, personalização e automação inteligente de tarefas.

Na educação, os prompts são utilizados para criar tutores personalizados, capazes de adaptar explicações ao nível de conhecimento do estudante. Também são empregados na geração automática de questões, elaboração de resumos e reformulação de conteúdos em diferentes estilos ou níveis de complexidade.

Na área da saúde, a engenharia de prompt é aplicada em sistemas de apoio à decisão clínica, como a triagem inicial de sintomas, a geração de relatórios médicos padronizados e o fornecimento de explicações sobre diagnósticos ou tratamentos em linguagem acessível para pacientes.

No mundo dos negócios, os modelos orientados por prompts vêm sendo usados para automatizar atendimentos ao cliente, realizar análises de sentimentos em redes sociais e canais de comunicação, além de resumir contratos e documentos jurídicos de forma clara e objetiva.

Na programação, os usos vão desde a geração de trechos de código sob demanda, passando pela explicação de blocos complexos, até o apoio em processos de depuração (debugging), tornando o trabalho dos desenvolvedores mais ágil e eficiente.

Esses exemplos demonstram como a engenharia de prompt atua como ponte entre o potencial técnico dos modelos de linguagem e as necessidades práticas do mundo real, viabilizando soluções mais inteligentes, acessíveis e contextualizadas.

Com o avanço das IAs generativas, a engenharia de prompt tornou-se uma competência essencial. Profissionais de tecnologia, conteúdo, marketing, direito e educação têm incorporado essa prática em suas rotinas, buscando melhorar a comunicação com LLMs, aumentar a produtividade e garantir maior controle e segurança na interação com esses sistemas. O domínio dessa habilidade é hoje um diferencial competitivo em diversas áreas do mercado.

O PLN é uma das áreas mais dinâmicas e impactantes da IA moderna. Ele aproxima a linguagem humana da linguagem de máquina, possibilitando interações mais intuitivas, análise automática de grandes volumes de texto e uma comunicação eficiente entre sistemas e pessoas. Para profissionais da área de desenvolvimento de sistemas, compreender os fundamentos e as aplicações do PLN é essencial para construir soluções cada vez mais inteligentes, acessíveis e humanas.

5.2 Técnicas de PLN

O PLN é composto por um conjunto de técnicas que permitem às máquinas compreender, interpretar e gerar linguagem humana de forma significativa. Essas técnicas combinam conhecimentos de linguística, estatística, aprendizado de máquina e redes neurais para transformar dados textuais e verbais em informações úteis e acionáveis.

Neste tópico serão apresentadas as principais técnicas de PLN, organizadas por etapa do processo de tratamento da linguagem natural.

Pré-processamento de texto

Antes que qualquer análise de texto possa ser realizada em um sistema de PLN, é fundamental que o conteúdo passe por uma etapa chamada pré-processamento. Esse processo envolve a normalização e a limpeza dos textos, com o objetivo de remover ruídos, padronizar a linguagem e preparar os dados para que os algoritmos possam extrair informações de forma mais eficaz. Palavras irrelevantes, pontuações, símbolos especiais e variações desnecessárias são tratadas ou eliminadas, tornando o texto mais consistente e estruturado. Essa etapa é essencial para garantir que os modelos analíticos operem com maior precisão, eficiência e relevância na identificação de padrões e significados.

- **Tokenização:** é uma das primeiras etapas, que consiste em dividir o texto em unidades menores chamadas tokens – geralmente palavras, pontuações ou até expressões. Por exemplo, a frase "A inteligência artificial é fascinante." seria decomposta nos tokens: ["A", "inteligência", "artificial", "é", "fascinante", "."]. Essa segmentação facilita a manipulação e a análise das informações.
- **Remoção de stopwords:** em seguida, realiza-se a remoção de stopwords, ou seja, a exclusão de palavras muito frequentes e geralmente pouco informativas, como "de", "o", "a" e "em". Essas palavras, apesar de essenciais para a construção gramatical das frases, tendem a não agregar valor semântico significativo na maioria das tarefas analíticas e, por isso, são removidas para reduzir o ruído nos dados.
- **Lematização e stemming:** outro passo importante é o tratamento das variações morfológicas das palavras, realizado por meio de stemming e lematização. O stemming reduz as palavras à sua raiz ou base, muitas vezes sem considerar se a forma resultante corresponde a uma palavra real. Por exemplo, "correr", "correndo" e "correu" podem ser reduzidas a "corr". Entretanto, a lematização vai além, utilizando regras linguísticas para transformar as palavras em sua forma canônica ou de dicionário – assim, "correndo" e "correu" seriam convertidas em "correr", mantendo o sentido linguístico correto.
- **Normalização:** por fim, a normalização do texto inclui operações como a conversão de todas as letras para minúsculas, a remoção de pontuações e caracteres especiais, além da padronização de acentuação. Essas transformações garantem que variações superficiais, como "Informação" e "informação", sejam tratadas como equivalentes, evitando distorções na análise posterior. Juntas, essas etapas são essenciais para preparar os textos de forma eficiente e garantir resultados mais precisos nas tarefas de PLN.

Representação de texto

Para que algoritmos de IA possam processar e compreender a linguagem natural, é fundamental que o texto seja convertido para uma forma numérica. Esse processo é conhecido como representação de texto e consiste em transformar palavras, frases ou documentos em vetores, estruturas matemáticas compreensíveis pelos modelos computacionais. Como os algoritmos não lidam diretamente com palavras ou símbolos linguísticos, essa conversão permite que o conteúdo textual seja analisado, comparado e manipulado em termos matemáticos. A representação vetorial do texto é essencial para viabilizar tarefas como classificação, tradução, análise de sentimentos e geração automática de linguagem, tornando a linguagem humana acessível ao raciocínio computacional.

- **Bag of Words (BoW):** para que modelos de IA compreendam textos de forma eficaz, é essencial representá-los numericamente por meio de técnicas de vetorização. Uma das abordagens mais simples e utilizadas é o BoW, que representa o texto como um vetor baseado na frequência de ocorrência das palavras, desconsiderando a ordem em que aparecem. Apesar de sua simplicidade, o BoW é bastante eficaz em textos curtos e tarefas básicas de classificação ou análise.

- **Term Frequency – Inverse Document Frequency (TF-IDF):** uma evolução do método de BOW é o TF-IDF, que, além de contabilizar a frequência de palavras, ajusta os pesos com base em sua relevância dentro de um conjunto de documentos. Palavras muito comuns, como "e" ou "o", são penalizadas, enquanto termos mais raros e específicos ganham maior destaque, melhorando a representação do conteúdo informativo.
- **Word embeddings:** técnicas mais sofisticadas são os word embeddings, que mapeiam palavras em vetores densos e contínuos, nos quais a proximidade entre vetores reflete relações semânticas entre os termos. Modelos como Word2Vec, Global Vectors (GloVe) e FastText são utilizados para capturar essas similaridades, permitindo que palavras com significados semelhantes estejam próximas no espaço vetorial, mesmo que não sejam idênticas.
- **Embeddings contextuais com transformers:** mais recentemente, surgiram os embeddings contextuais com o uso de modelos baseados em transformers, como o BERT e o GPT. Diferentemente das abordagens anteriores, esses modelos geram representações vetoriais que variam de acordo com o contexto em que a palavra aparece. Ou seja, uma mesma palavra pode ter significados e vetores diferentes dependendo da frase em que está inserida, o que resulta em uma compreensão muito mais precisa e rica da linguagem. Essas representações contextuais são hoje a base dos avanços mais expressivos no PLN.

Técnicas avançadas de análise

A seguir, apresentaremos as técnicas avançadas de análise.

- **Análise de sentimentos:** uma das aplicações mais populares é a análise de sentimentos, que busca identificar a opinião expressa em um texto – classificando-a como positiva, negativa ou neutra. Essa técnica é muito utilizada em redes sociais, avaliações de produtos e feedbacks de clientes, ajudando empresas a monitorar a percepção pública sobre suas marcas ou serviços.
- **Classificação de texto:** responsável por atribuir uma ou mais categorias a um determinado conteúdo textual. Por exemplo, sistemas de notícias podem usar essa técnica para classificar automaticamente artigos nas seções de política, esportes, economia, tecnologia, entre outras.
- **Reconhecimento de entidades nomeadas:** o NER, do inglês Named Entity Recognition, é outro componente essencial do PLN, permitindo identificar e extrair informações específicas de um texto, como nomes de pessoas, datas, locais e organizações. Essa extração automatizada facilita tarefas como análise de documentos, preenchimento de formulários e indexação de conteúdo.
- **Resumo automático (text summarization):** a geração de resumos automáticos é mais uma funcionalidade relevante, que visa condensar textos longos em versões mais curtas, mantendo os principais pontos informativos. Essa tarefa pode ser realizada por meio de duas abordagens: o resumo extrativo, que seleciona frases ou trechos diretamente do texto original, e o resumo abstrativo, que reescreve as ideias principais com base em uma compreensão mais profunda do conteúdo.

- **Tradução automática:** é outro avanço importante e permite converter textos entre idiomas diferentes. Os modelos mais modernos utilizam arquiteturas neurais avançadas, como redes Sequence-to-Sequence (Seq2Seq), com mecanismos de atenção e transformers, proporcionando traduções mais naturais e contextualmente corretas.
- **Geração de texto:** por fim, destaca-se a geração automática de texto, em que o sistema é capaz de criar conteúdos inteiros com base em um contexto ou instrução inicial. Essa técnica é aplicada em assistentes virtuais, geração de resumos, composição de e-mails, respostas automáticas e até mesmo na criação de textos criativos, consolidando o PLN como uma tecnologia central para o desenvolvimento da IA moderna.

5.2.1 Técnicas de PLN com aprendizado de máquina

Algoritmos clássicos

As primeiras aplicações de PLN com aprendizado de máquina utilizaram algoritmos clássicos supervisionados, que ainda hoje se mostram eficazes em tarefas específicas. Um dos mais utilizados é o Naive Bayes, um classificador probabilístico simples, baseado no teorema de Bayes e na suposição de independência entre as características (palavras) do texto. Apesar dessa simplificação, ele se destaca por sua eficiência e bom desempenho em tarefas como classificação de e-mails (spam ou não spam), análise de sentimentos e categorização básica de documentos.

Outro algoritmo muito empregado é o SVM, que busca encontrar um hiperplano ótimo que separe os dados em diferentes categorias. Ele é especialmente eficaz em problemas de classificação binária e multiclasse, como a categorização de textos em áreas temáticas (política, esporte, tecnologia etc.) ou a detecção de fake news. Já algoritmos como k-NN e árvores de decisão são mais simples, mas úteis em cenários em que os dados têm baixa dimensionalidade ou exigem interpretabilidade. Embora essas abordagens não captem relações semânticas complexas, são importantes como base conceitual e, em muitos casos, ainda são competitivas em tarefas específicas com conjuntos de dados menores ou bem estruturados.

Aprendizado profundo

Com o avanço da IA, surgiram as técnicas de aprendizado profundo (deep learning), que revolucionaram o PLN ao permitir uma modelagem mais rica e sofisticada dos textos. Entre os primeiros modelos utilizados estão as RNNs, que conseguem lidar com sequências de palavras, aproveitando o fato de a linguagem natural ter uma estrutura temporal. No entanto, as RNNs possuem limitações na captura de dependências de longo prazo, o que prejudica sua capacidade de manter o contexto ao longo de frases extensas.

Com o objetivo de superar essas limitações, surgiram variantes mais avançadas como as long short-term memory (LSTMs) e as gated recurrent units (GRUs). Essas redes introduzem mecanismos de memória que permitem armazenar e esquecer informações ao longo da sequência, tornando-as mais eficazes em tarefas como tradução automática, modelagem de linguagem e geração de texto com maior coesão. No entanto, o verdadeiro salto de desempenho ocorreu com o surgimento dos transformers,

uma arquitetura que abandonou a estrutura sequencial das RNNs e adotou o mecanismo de atenção para processar todas as palavras de uma sequência ao mesmo tempo.

Os transformers se tornaram a base dos modelos mais avançados em PLN, como o BERT, o GPT, o Robustly Optimized BERT Approach (RoBERTa) e o T5, que são capazes de capturar com profundidade o significado contextual das palavras em diferentes situações. Esses modelos alcançaram resultados superiores em diversas tarefas, como resposta a perguntas, tradução automática, geração de texto e análise de sentimentos. Além de sua alta precisão, eles oferecem a vantagem de lidar com grandes volumes de dados e adaptar-se a múltiplas línguas e domínios. Como resultado, o aprendizado profundo, especialmente com transformers, representa hoje o estado da arte no desenvolvimento de sistemas linguísticos baseados em IA.

5.2.2 Ferramentas e bibliotecas para PLN

No ecossistema do PLN, diversas bibliotecas e ferramentas são fundamentais na implementação de soluções eficientes e escaláveis. Entre as mais conhecidas está a Natural Language Toolkit (NLTK), uma biblioteca utilizada para tarefas básicas de processamento textual. Ela oferece recursos como tokenização, stemming, lematização, análise gramatical e corpora linguísticos, sendo útil em ambientes acadêmicos e educacionais, onde a compreensão conceitual das etapas do PLN é essencial.

Outra ferramenta poderosa é o spaCy, projetado para aplicações industriais que exigem alto desempenho e eficiência. Com uma arquitetura otimizada para velocidade, o spaCy permite executar tarefas como reconhecimento de entidades nomeadas, análise sintática, vetorização e extração de informações de maneira rápida e confiável, sendo adotada em projetos comerciais e pipelines robustos de PLN.

Complementando essas bibliotecas, o scikit-learn oferece uma ampla gama de algoritmos de aprendizado de máquina que podem ser aplicados à classificação e à vetorização de textos, como Naive Bayes, SVM e TF-IDF. Ele é útil quando se deseja combinar tarefas de PLN com outras técnicas clássicas de mineração de dados e aprendizado supervisionado.

Para o treinamento de modelos mais complexos, especialmente os baseados em redes neurais profundas, destacam-se os frameworks TensorFlow e PyTorch. Ambos oferecem suporte avançado ao desenvolvimento e treinamento de modelos personalizados de deep learning, incluindo redes recorrentes, LSTMs e transformers. Enquanto o TensorFlow é conhecido por sua robustez em ambientes de produção, o PyTorch se destaca pela flexibilidade e facilidade de prototipagem, tornando-se a escolha preferida em ambientes de pesquisa.

Por fim, a biblioteca Hugging Face Transformers tem ganhado destaque como uma das mais importantes do cenário atual, ao disponibilizar modelos pré-treinados de última geração, como BERT, GPT, RoBERTa e T5. Com apenas algumas linhas de código, é possível integrar modelos de altíssimo desempenho a aplicações reais, seja para tarefas de classificação, tradução, resumo automático, geração de texto ou resposta a perguntas. Essa biblioteca tornou-se essencial para desenvolvedores que buscam aliar alta performance e praticidade no uso de IA aplicada à linguagem natural.

Quadro 17

Biblioteca	Descrição
NLTK	Ferramentas básicas de processamento textual
spaCy	Análise rápida e eficiente de texto
Scikit-learn	Classificação e vetorização de texto
TensorFlow/PyTorch	Treinamento de modelos profundos
Hugging Face Transformers	Modelos pré-treinados de última geração

As técnicas de PLN formam a base de sistemas inteligentes capazes de interpretar, categorizar, resumir, traduzir e gerar linguagem humana com alto nível de precisão. Desde tarefas simples, como a contagem de palavras, até o uso de modelos de deep learning avançados, o PLN permite que as máquinas compreendam e interajam com humanos em seu próprio idioma. Dominar essas técnicas é essencial para qualquer profissional que deseje atuar com IA aplicada a comunicação, automação e análise textual.

5.2.3 Tokenização, stemming e lematização

O primeiro passo para qualquer sistema de PLN é a transformação de textos brutos em estruturas manipuláveis. Para isso, são aplicadas técnicas de pré-processamento como tokenização, stemming e lematização, que têm como objetivo reduzir a complexidade do texto, facilitando a análise posterior por algoritmos de aprendizado de máquina ou outras ferramentas linguísticas.

Tokenização

É o processo de dividir um texto em unidades menores chamadas tokens. Os tokens podem ser palavras, frases, caracteres ou até sílabas, dependendo do objetivo da análise.

Exemplo:

Frase: "A inteligência artificial está revolucionando o mundo."

Tokens (por palavras): ["A", "inteligência", "artificial", "está", "revolucionando", "o", "mundo", "."].

Há alguns tipos de tokenização. A tokenização por palavra é a forma mais comum e consiste em dividir o texto com base em espaços e sinais de pontuação, separando-o em palavras individuais. Já a tokenização por sentença segmenta o texto em frases completas, sendo útil para análises em nível discursivo ou de estrutura textual. A tokenização por caractere divide o texto em unidades mínimas, caractere por caractere, sendo especialmente útil em tarefas como correção ortográfica, processamento de emojis ou em línguas com escrita aglutinada. Por fim, a tokenização por subpalavra (subword) é muito utilizada em modelos modernos de linguagem, como o BERT, por permitir uma representação mais eficaz de palavras raras ou compostas, ao quebrá-las em unidades menores e reutilizáveis.

A tokenização é fundamental para o PLN, pois permite identificar a estrutura sintática básica de um texto. Ela serve como etapa inicial para diversas outras tarefas, como análise sintática, vetorização de palavras e classificação de conteúdos, sendo essencial para que os modelos compreendam e processem a linguagem de forma eficiente.

Stemming

É a técnica de reduzir uma palavra à sua raiz ou radical, removendo afixos (prefixos e sufixos), sem considerar se a forma resultante é uma palavra válida no idioma.

Exemplo:

Palavras: "correndo", "correu", "correria" → **Stem**: "corr".

O stemming é um processo essencialmente mecânico, baseado em regras simples de truncamento de palavras. A forma obtida, conhecida como stem, nem sempre corresponde a uma palavra real do idioma, mas representa uma raiz comum entre variações morfológicas. Trata-se de uma abordagem simples, rápida e eficiente, especialmente adequada para tarefas em que a precisão linguística completa não é prioritária, como buscas por palavras-chave ou análises exploratórias de texto.

Existem alguns algoritmos populares de stemming. O **Porter Stemmer** é um dos algoritmos de stemming mais utilizados para a língua inglesa, conhecido por sua simplicidade e eficácia na redução de palavras à sua raiz. O **Snowball Stemmer**, também desenvolvido por Martin Porter, é uma versão mais robusta e flexível, com suporte a múltiplos idiomas além do inglês. Já o **RSLP Stemmer** foi projetado especificamente para o português, aplicando uma série de regras linguísticas adaptadas às particularidades morfológicas da língua.

O stemming é muito útil em tarefas como a classificação de textos, em que variações morfológicas das palavras não afetam o resultado, tornando a forma exata dos termos menos relevante. Também é indicado quando se busca reduzir a dimensionalidade do vocabulário, otimizando o desempenho de algoritmos e diminuindo a complexidade computacional.

Lematização

É o processo de reduzir uma palavra à sua forma canônica ou dicionarizada, chamada de **lema**, com base em análise linguística e gramatical.

Exemplo:

Palavras: "correndo", "correu", "correria" → **Lema**: "correr".

A lematização considera o contexto gramatical da palavra, como tempo verbal, gênero, número e outros elementos morfossintáticos. Para isso, requer o uso de dicionários linguísticos e análise sintática, a fim de identificar corretamente a forma canônica das palavras. Ao contrário do stemming, a lematização retorna palavras reais, corretas e gramaticalmente apropriadas dentro do idioma.

A lematização é recomendada em aplicações que demandam maior precisão semântica e correção linguística. É muito útil em tarefas como extração de informações, geração automática de texto e tradução automática, nas quais a forma correta e contextualizada das palavras é essencial para a qualidade e a coerência dos resultados.

Quadro 18 – Stemming versus lematização

Característica	Stemming	Lematização
Abordagem	Regras simples (mecânico)	Baseada em gramática e vocabulário
Forma final	Raiz truncada (stem)	Palavra do dicionário (lema)
Velocidade	Mais rápida	Mais lenta
Precisão linguística	Menor	Maior
Exemplo ("amando")	"am"	"amar"



Destaque

Instalação de bibliotecas: preparando o ambiente

Antes de executarmos os códigos de PLN, precisamos instalar e configurar algumas bibliotecas importantes. Esse processo deve ser feito apenas uma vez, no início do projeto.

Vamos utilizar as bibliotecas:

- **NLTK**: usada para tokenização, stemming e outras técnicas de PLN.
- **spaCy**: biblioteca poderosa para processamento eficiente de texto.
- **pt_core_news_sm**: modelo da língua portuguesa utilizado pelo spaCy.

Se estiver usando o computador com Python instalado (ex.: VS Code, PyCharm ou terminal), abra o terminal ou o prompt de comando e execute os comandos a seguir, um por vez:

```
pip install nltk spacy
```

```
python -m nltk.downloader punkt
```

```
python -m spacy download pt_core_news_sm
```

Se estiver usando o Google Colab, cole os comandos em uma célula de código, precedidos de !:

```
!pip install nltk spacy
```

```
!python -m nltk.downloader punkt
```

```
!python -m spacy download pt_core_news_sm
```

Sobre os comandos:

- **pip install nltk spacy**: instala as bibliotecas NLTK e spaCy.
- **python -m nltk.downloader punkt**: baixa o modelo de tokenização do NLTK (essencial para dividir textos).
- **python -m spacy download pt_core_news_sm**: baixa o modelo em português do spaCy.

Esses comandos devem ser executados antes de rodar os códigos com análise de texto. Em caso de erro, verifique se o Python e o pip estão corretamente instalados no seu sistema.

```

1  import nltk
2  from nltk.tokenize import word_tokenize, sent_tokenize
3  from nltk.stem import RSLPStemmer
4  import spacy
5
6  # Baixar dados necessários
7  nltk.download('punkt')
8  nltk.download('punkt_tab')
9  nltk.download('rsllp')
10
11 # Carregar modelo SpaCy para português
12 nlp = spacy.load("pt_core_news_sm")
13
14 # Texto de exemplo
15 texto = "As crianças estavam brincando no jardim. Elas brincam lá todos os dias."
16
17 print("Texto original:")
18 print(texto)
19 print("-" * 50)
20
21 # 1. TOKENIZAÇÃO
22
23 print("1. Tokenização")
24
25 # Tokenização por sentença com NLTK
26 sentencas = sent_tokenize(texto, Language='portuguese')
27 print("\nSentenças:")
28 print(sentencas)
29
30 # Tokenização por palavra com NLTK
31 palavras = word_tokenize(texto, Language='portuguese')
32 print("\nPalavras:")
33 print(palavras)
34
35 # Tokenização com spaCy
36 doc = nlp(texto)
37 print("\nTokens com spaCy:")
38 print([token.text for token in doc])
39 print("-" * 50)
40
41 # 2. STEMMING (com RSLPStemmer)
42
43 print("2. Stemming com RSLPStemmer")
44
45 stemmer = RSLPStemmer()
46 stems = [stemmer.stem(palavra.lower()) for palavra in palavras if palavra.isalpha()]
47 print("Palavras após stemming:")
48 print(stems)
49 print("-" * 50)
50
51 # 3. LEMATIZAÇÃO (com spaCy)
52
53 print("3. Lematização com spaCy")
54
55 lemmas = [token.lemma_ for token in doc if token.is_alpha]
56 print("Palavras após lematização:")
57 print(lemmas)

```

Figura 32

```
Texto original:
As crianças estavam brincando no jardim. Elas brincam lá todos os dias.
-----
1. Tokenização

Sentenças:
['As crianças estavam brincando no jardim.', 'Elas brincam lá todos os dias.']

Palavras:
['As', 'crianças', 'estavam', 'brincando', 'no', 'jardim', '.', 'Elas', 'brincam', 'lá', 'todos', 'os', 'dias', '.']

Tokens com spaCy:
['As', 'crianças', 'estavam', 'brincando', 'no', 'jardim', '.', 'Elas', 'brincam', 'lá', 'todos', 'os', 'dias', '.']
-----
2. Stemming com RSLPStemmer
Palavras após stemming:
['as', 'crianç', 'est', 'brinc', 'no', 'jardim', 'ela', 'brinc', 'lá', 'tod', 'os', 'dia']
-----
3. Lematização com spaCy
Palavras após lematização:
['o', 'criança', 'estar', 'brincar', 'em o', 'jardim', 'elas', 'brincar', 'lá', 'todo', 'os', 'dias']
-----
```

Figura 33 – Saída

As técnicas de tokenização, stemming e lematização são essenciais no pré-processamento de textos em projetos de PLN. Enquanto a tokenização segmenta o texto em unidades processáveis, o stemming e a lematização ajudam a normalizar as palavras, reduzindo a variabilidade do vocabulário e otimizando o desempenho de modelos de linguagem. A escolha entre stemming e lematização depende do nível de precisão e velocidade desejados, sendo fundamental compreender as diferenças para aplicá-las corretamente nos projetos de IA.

5.2.4 Análise de sentimentos e classificação de texto

A análise de sentimentos e a classificação de texto são duas aplicações importantes do PLN, utilizadas para interpretar o conteúdo textual e extrair significado de forma automática. Essas técnicas são empregadas em redes sociais, plataformas de avaliação, atendimento ao cliente, sistemas de recomendação, entre outros domínios em que entender a opinião ou a categoria de um texto é fundamental.

Análise de sentimentos

É o processo de identificar e classificar emoções ou opiniões expressas em um texto. O objetivo é determinar se o sentimento é positivo, negativo ou neutro e, em alguns casos, medir a intensidade da emoção.

Exemplo:

Texto: "Adorei a nova atualização do aplicativo, está muito mais rápido!"

Resultado: sentimento positivo.

Texto: "O atendimento foi péssimo, não recomendo".

Resultado: sentimento negativo.

Abordagens para análise de sentimentos

A análise de sentimentos pode ser realizada por meio de diferentes abordagens, que variam em complexidade e recursos computacionais. As principais são:

- **Abordagem baseada em regras léxicas:** dispõe de dicionários ou léxicos contendo palavras previamente classificadas quanto à sua polaridade (positiva, negativa ou neutra). Por exemplo, termos como "bom" podem receber uma pontuação positiva (+1), enquanto palavras como "ruim" são associadas a uma pontuação negativa (-1). A análise é realizada a partir da contagem e ponderação desses termos no texto.
- **Abordagem baseada em aprendizado de máquina:** utiliza algoritmos treinados com conjuntos de dados rotulados para classificar o sentimento dos textos. No aprendizado supervisionado, modelos como SVM, Naive Bayes e redes neurais são comumente empregados, exigindo uma etapa prévia de treinamento com exemplos anotados.
- **Abordagem baseada em deep learning:** usa arquiteturas mais sofisticadas, como RNNs, LSTM e transformers, que são capazes de capturar dependências temporais, nuances linguísticas e contexto semântico das palavras. Modelos pré-treinados como o BERT têm se destacado por seu desempenho superior em tarefas de análise de sentimentos, especialmente em contextos complexos.

Aplicações práticas

A análise de sentimentos tem sido muito utilizada em diversos contextos, permitindo extrair informações valiosas a partir de grandes volumes de texto não estruturado. Entre as principais aplicações práticas, destacam-se:

- **Monitoramento de marcas em redes sociais:** permite acompanhar, em tempo real, a percepção pública sobre produtos, serviços ou empresas, possibilitando ações estratégicas de marketing e gerenciamento de reputação.
- **Análise de feedbacks de clientes:** utilizada por empresas de e-commerce e serviços de atendimento ao consumidor (SACs) para compreender a satisfação dos clientes, identificar pontos críticos e orientar melhorias nos produtos ou no atendimento.
- **Deteção de sentimentos em comentários de notícias:** contribui para avaliar a reação do público em relação a determinados temas, reportagens ou eventos, sendo útil para veículos de comunicação e pesquisadores da área de mídia.

- **Análise de discurso político e social:** aplicada para identificar tendências de opinião, polarizações e emoções predominantes em discursos, manifestações públicas e debates sociais, sendo uma ferramenta relevante em estudos de ciências sociais, ciência política e comunicação.

Classificação de texto

É o processo de atribuir categorias predefinidas a um conteúdo textual. Pode ser binária (duas classes), multiclasse (várias categorias exclusivas) ou multirrótulo (várias categorias simultâneas por texto).

Exemplos:

- Classificar um e-mail como "spam" ou "não spam".
- Categorizar uma notícia como "política", "esportes", "tecnologia".
- Detectar se um comentário é "ofensivo", "neutro" ou "educativo".

Etapas da classificação de texto

O processo de classificação de texto envolve uma sequência estruturada de etapas que visam transformar dados textuais brutos em entradas compreensíveis para algoritmos de aprendizado de máquina, culminando em modelos capazes de prever rótulos ou categorias associados a textos. A seguir, detalham-se as principais etapas desse processo:

- **Pré-processamento:** nessa fase inicial, o texto é preparado para a análise. As etapas de pré-processamento visam reduzir a complexidade e remover ruídos dos dados.
 - **Limpeza:** consiste na remoção de caracteres especiais, pontuações, números irrelevantes, stopwords (palavras de pouca relevância como "de", "a", "que") e padronização do texto para minúsculas.
 - **Tokenização:** divide o texto em unidades menores chamadas tokens, geralmente palavras ou expressões.
 - **Lematização:** reduz as palavras às suas formas canônicas (lemas), mantendo seu significado. Por exemplo, as palavras "correndo" e "correu" são reduzidas ao lema "correr". Esse processo melhora a generalização do modelo e reduz a dimensionalidade do texto.
- **Vetorização:** o texto, uma vez pré-processado, é convertido em uma representação numérica para que possa ser utilizado por algoritmos de aprendizado de máquina. Os métodos mais comuns incluem:
 - **BoW:** representa o texto por meio da frequência das palavras, desconsiderando a ordem.

- **TF-IDF**: pondera a frequência das palavras considerando sua importância relativa entre os documentos.
- **Embeddings**: técnicas mais avançadas, como Word2Vec, GloVe ou BERT, mapeiam palavras ou sentenças em vetores densos em espaços semânticos, preservando relações de similaridade entre termos.
- **Treinamento do modelo**: com os dados vetorizados, aplica-se um algoritmo de aprendizado supervisionado para treinar um modelo de classificação. Entre os algoritmos que são mais utilizados destacam-se:
 - **Naive Bayes**: baseia-se no teorema de Bayes com a suposição de independência entre as características. É eficiente e particularmente eficaz para problemas de classificação de texto com dados balanceados.
 - **SVM**: busca um hiperplano ótimo para separar classes distintas no espaço de características. É robusto em casos de alta dimensionalidade, como nos textos vetorizados.
 - **Redes neurais**: especialmente Deep Neural Networks (DNNs), que capturam relações complexas entre palavras e estruturas sintáticas.
 - **Transformers**: arquiteturas modernas como BERT, RoBERTa e GPT utilizam mecanismos de atenção para contextualizar cada palavra dentro da sentença, obtendo alto desempenho em tarefas de classificação complexas.
- **Avaliação e teste**: após o treinamento, o modelo é avaliado por meio de métricas que permitem medir sua eficácia:
 - **Acurácia**: razão entre o número de previsões corretas e o total de previsões.
 - **Precisão**: proporção de itens classificados como positivos que são realmente positivos.
 - **Recall**: proporção de itens realmente positivos que foram corretamente identificados.
 - **F1-score**: média harmônica entre precisão e recall, útil especialmente em casos de dados desbalanceados.

Essas etapas são fundamentais para garantir que o modelo final seja eficiente, interpretável e aplicável a contextos reais, como classificação de sentimentos, categorização de notícias, triagem de e-mails, entre outras aplicações relevantes no campo do PLN.

A classificação de texto é muito utilizada em soluções de PLN para lidar com grandes volumes de informações textuais de forma automatizada. Suas aplicações práticas abrangem diversos setores, contribuindo para a eficiência operacional e melhorando a experiência do usuário.

Uma das aplicações mais difundidas da classificação de texto é a detecção automática de mensagens indesejadas, conhecidas como spam. Os modelos são treinados para distinguir entre e-mails legítimos (ham) e spams, com base em padrões linguísticos, remetentes, presença de palavras-chave suspeitas, links, entre outros fatores. A filtragem automatizada ajuda a manter a caixa de entrada organizada e protege o usuário contra fraudes, phishing e propagandas não solicitadas.

Em ambientes de suporte técnico e atendimento ao cliente, sistemas automatizados de classificação são utilizados para categorizar os tickets (chamados) conforme o tipo de problema reportado, como "problema técnico", "falha no sistema", "dúvida operacional" ou "solicitação administrativa". Isso permite o encaminhamento automático para o setor responsável, reduzindo o tempo de resposta e otimizando o fluxo de atendimento.

Em portais de notícias, repositórios científicos e blogs, a classificação de texto pode ser utilizada para atribuir categorias temáticas a novos conteúdos, como "política", "economia", "esportes", "tecnologia", entre outras. Isso facilita a indexação, navegação e recomendação personalizada de conteúdo, tanto para usuários finais quanto para sistemas de busca interna.

Em centrais de atendimento de alto volume, como em instituições bancárias, operadoras de telecomunicações ou serviços públicos, a classificação textual pode ser usada para priorizar automaticamente as mensagens recebidas. Com base no conteúdo da solicitação, como menções a "fraude", "cancelamento de serviço" ou "urgente", o sistema identifica os casos mais críticos e atribui um nível de prioridade, garantindo que situações sensíveis sejam atendidas com maior rapidez.

Essas aplicações demonstram como a classificação de texto, aliada a modelos de aprendizado de máquina, pode gerar ganhos expressivos de produtividade, redução de custos operacionais e melhoria no relacionamento com o cliente, sendo uma tecnologia essencial em contextos que lidam com grande volume e diversidade de informações textuais.

Ferramentas populares

Diversas ferramentas e bibliotecas são utilizadas na tarefa de classificação de texto, cada uma desempenhando um papel específico dentro do fluxo de processamento e modelagem. O scikit-learn é uma das bibliotecas mais populares para a aplicação de classificadores tradicionais, como Naive Bayes, SVM e regressão logística, sendo bastante eficaz em tarefas supervisionadas com vetores esparsos. Para as etapas iniciais de pré-processamento e vetorização, bibliotecas como NLTK e spaCy oferecem recursos robustos para tokenização, remoção de stopwords, lematização e análise morfofossintática.

Quando o objetivo é realizar a análise de sentimentos de forma mais simples, baseada em regras predefinidas, a biblioteca TextBlob é uma alternativa prática, oferecendo classificadores embutidos e fácil integração com outras ferramentas. Já para abordagens mais modernas e de alto desempenho, a biblioteca Transformers, mantida pela Hugging Face, disponibiliza acesso a modelos pré-treinados de última geração (como BERT, RoBERTa e GPT) para tarefas de classificação, extração de entidades, tradução e muito mais.

Por fim, quando o projeto demanda maior flexibilidade e controle sobre o treinamento de modelos profundos, frameworks como TensorFlow e PyTorch são os mais indicados. Eles permitem a construção e o treinamento de redes neurais complexas e são utilizados em aplicações avançadas de PLN e aprendizado profundo.

A análise de sentimentos e a classificação de texto são técnicas fundamentais para transformar dados linguísticos em informações estruturadas e acionáveis. Enquanto a análise de sentimentos busca compreender emoções e opiniões, a classificação organiza o conteúdo em categorias específicas, permitindo automação, filtragem, recomendação e insights estratégicos. Ambas as tarefas impulsionam soluções modernas de IA aplicadas à comunicação, ao marketing, ao atendimento ao cliente e à segurança da informação.

5.3 Modelos de linguagem

Os modelos de linguagem são a espinha dorsal do PLN. Eles permitem que sistemas computacionais compreendam, processem, prevejam e gerem linguagem humana. Desde tarefas simples como autocompletar frases até aplicações complexas como assistentes virtuais e tradutores automáticos, os modelos de linguagem estão presentes em praticamente todas as soluções modernas de IA linguística.

Um modelo de linguagem é um sistema matemático ou estatístico que, dado um conjunto de palavras ou caracteres, é capaz de prever a probabilidade de ocorrência da próxima palavra, ou avaliar a fluidez de uma frase. Ele aprende com grandes volumes de texto a reconhecer padrões e contextos na linguagem.

Exemplo:

Entrada: "O céu está muito..."

Saída esperada: "azul" (alta probabilidade), "livro" (baixa probabilidade).

A seguir, veremos alguns dos principais tipos de modelos de linguagem.

Modelos baseados em n-gramas

São abordagens estatísticas clássicas utilizadas no PLN para modelar sequências de palavras. Esses modelos estimam a probabilidade de ocorrência de uma palavra com base nas palavras imediatamente anteriores, assumindo que o contexto linguístico pode ser parcialmente capturado por uma janela de palavras de tamanho fixo.

Um unigrama considera cada palavra de forma independente, ignorando a relação com palavras vizinhas. Já bigramas e trigramas consideram, respectivamente, pares e trios de palavras consecutivas, proporcionando uma visão mais contextualizada. Por exemplo, no modelo de bigramas, a sequência "como vai" pode levar à predição da palavra "você" com alta probabilidade, com base em padrões aprendidos de textos anteriores.

Apesar de sua simplicidade e eficiência computacional, os modelos de n-gramas apresentam algumas limitações significativas. Eles não são capazes de capturar contextos de longo alcance, uma vez que consideram apenas um número fixo de palavras anteriores. Além disso, sofrem com o problema da escassez de dados (sparse data) à medida que o valor de n aumenta, pois combinações mais longas de palavras tendem a aparecer com pouca frequência em corpora de treinamento, prejudicando a capacidade de generalização do modelo.

Essas restrições motivaram o desenvolvimento de abordagens mais sofisticadas, como os modelos de linguagem baseados em redes neurais e transformers, que conseguem representar relações semânticas e dependências em longo prazo de maneira mais eficaz.

Modelos com redes neurais

Com o avanço do aprendizado profundo, as redes neurais passaram a desempenhar um papel central nas tarefas de classificação e modelagem de linguagem. Diferentemente dos modelos estatísticos baseados em n-gramas, que possuem limitações em capturar dependências de longo prazo, os modelos neurais utilizam representações vetoriais (embeddings) e múltiplas camadas ocultas para aprender relações complexas e não lineares entre palavras.

Entre as arquiteturas mais relevantes estão as RNNs, que processam sequências de forma iterativa e armazenam informações sobre os estados anteriores, permitindo uma modelagem mais natural de dados sequenciais como textos. No entanto, as RNNs tradicionais enfrentam dificuldades em manter o contexto por longas distâncias, devido ao problema do desvanecimento do gradiente.

Para superar essas limitações, surgiram variantes mais avançadas, como as LSTMs e as GRUs. Ambas incorporam mecanismos de controle de fluxo de informações (gates) que permitem reter e esquecer dados seletivamente ao longo do tempo, tornando-as mais eficazes na captura de dependências temporais prolongadas em textos extensos.

Outra arquitetura importante é o modelo Seq2Seq, muito utilizado em tarefas como tradução automática. Ele consiste em dois componentes principais: um encoder, responsável por codificar toda a sequência de entrada em uma representação vetorial densa, e um decoder, que gera a sequência de saída a partir dessa codificação. O modelo pode ser treinado para realizar uma variedade de tarefas sequenciais, como sumarização, resposta automática a perguntas e transcrição de fala para texto.

As abordagens baseadas em redes neurais representam um avanço significativo em relação aos métodos tradicionais, proporcionando maior capacidade de generalização, compreensão de contexto e flexibilidade para lidar com textos de natureza variada e complexa.

Modelos baseados em transformers

Esses modelos revolucionaram o campo do PLN ao introduzir uma arquitetura capaz de lidar com contextos amplos de forma paralela e altamente contextualizada. Diferentemente das redes recorrentes, que processam as palavras de forma sequencial, os transformers utilizam mecanismos de atenção

(attention) que permitem analisar simultaneamente todas as palavras de uma sentença, capturando relações semânticas de curto e longo alcance com grande eficiência.

Diversos modelos foram desenvolvidos com base nessa arquitetura, cada um com características específicas que os tornam mais adequados para determinadas tarefas. Entre os principais, destacam-se:

- **BERT**: lançado em 2018, introduziu o conceito de codificação bidirecional, permitindo ao modelo compreender o significado de uma palavra levando em consideração tanto o contexto anterior quanto o posterior. É bastante utilizado em tarefas de classificação, reconhecimento de entidades e resposta automática a perguntas.
- **GPT**: também lançado em 2018 e com versões mais avançadas nos anos seguintes, é um modelo unidirecional voltado para a geração de texto. Seu foco está na previsão da próxima palavra com base no histórico anterior, sendo especialmente eficaz em tarefas de linguagem natural aberta, como redação automática e criação de diálogos.
- **T5**: apresentado em 2020, adota uma abordagem multitarefa e trata todas as tarefas de PLN como problemas de transformação de texto – seja tradução, classificação ou sumarização. Baseia-se em uma estrutura completa de encoder-decoder, o que o torna extremamente flexível e poderoso.
- **RoBERTa**: lançado em 2019, é uma versão aprimorada do BERT, treinado com mais dados e por mais tempo. Ele apresenta desempenho superior em várias tarefas, graças a ajustes na forma como o treinamento é realizado.
- **DistilBERT**: também de 2019, é uma versão mais compacta e eficiente do BERT, projetada para oferecer desempenho semelhante com menor tempo de processamento e consumo de recursos. É ideal para aplicações em dispositivos com restrições de hardware ou que exigem respostas rápidas.

Esses modelos representam o estado da arte em PLN e são adotados em aplicações como assistentes virtuais, mecanismos de busca, análise de sentimentos, tradução automática, entre outros. Sua capacidade de entender a linguagem em profundidade, aliada à escalabilidade e à versatilidade, os torna indispensáveis para sistemas inteligentes baseados em texto.

Aplicações de modelos de linguagem

Modelos de linguagem vêm transformando diversas áreas da comunicação digital por meio de aplicações práticas que automatizam, otimizam e enriquecem a interação entre humanos e máquinas.

Podemos citar como exemplos:

- Autocompletar textos e mensagens, como em editores de texto e plataformas de e-mail, quando o modelo sugere palavras ou frases seguintes com base no contexto, agilizando a escrita e reduzindo erros.

- Correção ortográfica e gramatical automática, com sugestões de melhorias linguísticas em tempo real, oferecendo ao usuário uma forma mais fluida e correta de comunicação escrita.
- Tradução automática de idiomas, como nos sistemas oferecidos por plataformas como Google Translate e DeepL, utilizando modelos neurais para interpretar o significado de uma frase no idioma de origem e recriá-la com fidelidade no idioma de destino.
- Respostas automáticas em assistentes virtuais e chatbots, que permitem a simulação de diálogos naturais com os usuários em contextos de atendimento ao cliente, suporte técnico e assistentes pessoais, muitas vezes com compreensão semântica e adaptação ao contexto.
- Geração automática de conteúdo, como resumos de textos longos, redação de e-mails, criação de relatórios e até mesmo produção de textos criativos, utilizando modelos capazes de sintetizar e reestruturar informações com fluidez e coerência.
- Análise de sentimentos e compreensão de perguntas, fundamentais em pesquisas de opinião, monitoramento de redes sociais e sistemas de busca inteligente, nos quais o modelo avalia a carga emocional de um texto ou interpreta corretamente uma pergunta para fornecer respostas relevantes.

Essas aplicações tornam os modelos de linguagem ferramentas essenciais para a automação inteligente da linguagem escrita, promovendo maior produtividade, acessibilidade e personalização em diversas áreas, como educação, negócios, marketing e tecnologia.

5.3.1 Representações semânticas em modelos de linguagem

A representação de palavras em formato vetorial é uma das bases do PLN moderno. Ao converter palavras em números – mais especificamente em vetores de alta dimensão –, os modelos de linguagem conseguem capturar relações semânticas e sintáticas, permitindo que algoritmos interpretem o significado e o contexto das palavras de maneira matemática.

Word embeddings

São representações vetoriais densas e contínuas, em que cada palavra é mapeada para um ponto em um espaço vetorial multidimensional. Modelos como Word2Vec, GloVe e FastText foram pioneiros nessa abordagem, permitindo que palavras com significados semelhantes ocupem posições próximas nesse espaço vetorial.

Essas representações capturam similaridades semânticas, de modo que palavras frequentemente utilizadas em contextos parecidos apresentem vetores semelhantes. Um exemplo clássico da capacidade desses modelos é a operação vetorial:

$$\text{vet}(\text{"rei"}) - \text{vet}(\text{"homem"}) + \text{vet}(\text{"mulher"}) \approx \text{vet}(\text{"rainha"})$$

Esse tipo de relação mostra que os embeddings podem capturar não apenas similaridades, mas também relações linguísticas e analógicas de forma surpreendentemente eficaz.

Embeddings contextuais

Embora os word embeddings tradicionais representem cada palavra com um único vetor fixo, os embeddings contextuais – introduzidos por modelos como BERT, GPT, ELMo, entre outros – representam as palavras levando em consideração o contexto em que aparecem. Isso significa que a mesma palavra pode ter diferentes representações dependendo da frase em que está inserida.

Por exemplo, a palavra "banco" em "Sentei no banco para descansar" tem o significado relacionado a um assento. Já em "Fui ao banco sacar dinheiro", se refere a uma instituição financeira.

Em modelos contextuais, essas duas ocorrências de "banco" terão vetores distintos, pois o modelo reconhece o significado contextual baseado nas palavras ao redor. Essa capacidade é fundamental para lidar com ambiguidade lexical e torna os embeddings contextuais muito mais poderosos e precisos em tarefas como classificação, tradução, perguntas e respostas, entre outras.

Essas representações semânticas são a base para que modelos de linguagem modernos consigam compreender, gerar e manipular texto com alto nível de sofisticação.

5.3.2 Treinamento de modelos de linguagem

O treinamento envolve expor o modelo a um grande corpus de texto para que ele aprenda a prever palavras, frases ou respostas com base em contextos anteriores. Quanto maior e mais diverso o corpus, melhor a generalização do modelo.

Técnicas comuns de pré-treinamento

O treinamento de modelos de linguagem é uma etapa importante no desenvolvimento de sistemas capazes de compreender e gerar texto de forma inteligente. Esse processo consiste em expor o modelo a um grande corpus textual, permitindo que ele aprenda padrões linguísticos, relações semânticas e estruturas sintáticas por meio da análise estatística de contextos. À medida que o modelo processa grandes volumes de dados, ele ajusta seus parâmetros internos para prever palavras, frases ou respostas com base no que aprendeu.

A qualidade, a variedade e o volume do corpus de treinamento são fatores determinantes para o desempenho final do modelo. Um corpus extenso e diversificado – contendo diferentes domínios, estilos de escrita e registros linguísticos – possibilita uma maior capacidade de generalização, ou seja, o modelo se torna mais apto a lidar com diferentes tipos de linguagem e situações de uso.

Duas das principais estratégias de pré-treinamento utilizadas nos modelos modernos são:

- **Máscara de palavras (MLM, do inglês masked language modeling):** utilizada em modelos como o BERT, essa técnica consiste em ocultar aleatoriamente algumas palavras da frase e treinar o modelo para prever os termos mascarados com base no contexto ao redor. Por exemplo, na sentença "A ____ está muito quente hoje", o modelo deve prever a palavra "cidade" ou "temperatura", dependendo do contexto. Essa abordagem permite que o modelo aprenda a interpretar o significado das palavras considerando as informações anteriores e posteriores.
- **Previsão da próxima palavra ou next word prediction (CLM, do inglês causal language modeling):** técnica característica de modelos como o GPT, nos quais o objetivo é prever a próxima palavra em uma sequência com base nas palavras anteriores. Por exemplo, ao receber a entrada "O céu está", o modelo aprende a completar com palavras como "azul", "nublado" ou "limpo", de acordo com a distribuição de frequência observada nos dados. Essa abordagem treina o modelo de forma sequencial e unidirecional.

Ambas as estratégias visam ensinar o modelo a internalizar o funcionamento da linguagem natural, permitindo que ele seja posteriormente ajustado (via fine-tuning) para tarefas específicas, como tradução, classificação de texto, análise de sentimentos ou geração automática de conteúdo.

No desenvolvimento de aplicações baseadas em linguagem natural, uma decisão estratégica importante é escolher entre o uso de modelos pré-treinados genéricos ou a criação de modelos personalizados adaptados a um domínio específico. Ambas as abordagens têm seus méritos e aplicações ideais e muitas vezes são utilizadas em conjunto.

Modelos pré-treinados são modelos que já passaram por uma fase intensiva de treinamento em grandes corpora de texto genéricos, como Wikipedia, Common Crawl, livros digitais, fóruns e redes sociais. Modelos como BERT, GPT, RoBERTa e T5 são exemplos utilizados por seu bom desempenho em tarefas gerais de linguagem. Esses modelos estão prontos para uso imediato e são eficazes em uma variedade de aplicações comuns, como análise de sentimentos, respostas a perguntas e tradução automática.

No entanto, esses modelos generalistas nem sempre oferecem desempenho ideal em contextos especializados, como textos médicos, jurídicos, técnicos ou corporativos. Para suprir essa limitação, utiliza-se a técnica de fine-tuning (ou ajuste fino), que consiste em adaptar um modelo pré-treinado a uma tarefa ou domínio específico por meio de um novo ciclo de treinamento com dados representativos do contexto de aplicação.

Esse processo permite criar modelos personalizados, capazes de interpretar nuances linguísticas, jargões e estruturas próprias de determinado setor. Por exemplo:

- Um modelo ajustado para linguagem jurídica pode compreender termos como "liminar", "jurisprudência" ou "habeas corpus" com maior precisão.
- Em contextos médicos, o modelo pode aprender a reconhecer e categorizar termos clínicos, nomes de medicamentos e sintomas com mais segurança.

- Na área técnica, pode lidar com especificações de produto, comandos ou documentação com maior fidelidade.

Modelos personalizados, portanto, combinam a robustez dos modelos pré-treinados com a especialização necessária para aplicações reais em ambientes específicos. Essa abordagem é altamente recomendada quando a precisão, o entendimento contextual e a adaptação ao vocabulário do domínio são fatores críticos de sucesso.

5.3.3 Desafios dos modelos de linguagem

Embora os modelos de linguagem representem um avanço significativo no PLN, sua aplicação prática ainda enfrenta uma série de desafios técnicos, éticos e operacionais que exigem atenção constante por parte de desenvolvedores e pesquisadores.

Um dos principais desafios é o viés linguístico. Como esses modelos são treinados com base em grandes volumes de dados coletados da internet e de outras fontes públicas, eles tendem a refletir – e, em muitos casos, perpetuar – preconceitos sociais, culturais ou ideológicos presentes nesses dados. Isso pode levar a respostas discriminatórias, estereotipadas ou enviesadas, impactando negativamente a equidade e a confiabilidade dos sistemas.

Outro obstáculo relevante é a ambiguidade linguística, ou seja, a dificuldade em lidar com palavras ou expressões que possuem múltiplos significados. Modelos de linguagem podem interpretar erroneamente o sentido de termos ambíguos quando o contexto não é suficientemente claro ou quando o modelo não possui conhecimento específico do domínio.

Além disso, há o alto custo computacional associado ao treinamento e à execução de modelos de grande porte, como o GPT ou o T5. Essas arquiteturas exigem infraestrutura robusta, com uso intensivo de memória e processamento gráfico (GPUs ou TPUs), o que pode limitar seu acesso a organizações com recursos restritos.

Por fim, destaca-se o problema das chamadas alucinações dos modelos, em que o sistema gera informações incorretas, imprecisas ou até mesmo inventadas, apresentando-as com alto grau de confiança. Em contextos sensíveis, como medicina, direito ou educação, esse tipo de erro pode ter consequências graves. Também há riscos relacionados à segurança da informação, com possibilidade de gerar conteúdos inapropriados, ofensivos ou que violem diretrizes de privacidade.

Esses desafios reforçam a necessidade de práticas responsáveis no uso de modelos de linguagem, como curadoria criteriosa dos dados de treinamento, monitoramento contínuo de viés e desempenho, uso de validação humana em tarefas críticas e desenvolvimento de mecanismos para explicar e auditar o comportamento dos modelos.

Os modelos de linguagem são componentes fundamentais da IA aplicada à linguagem. Sua evolução – de n-gramas simples a transformers capazes de compreender contextos complexos – transformou radicalmente a forma como sistemas computacionais lidam com a linguagem humana. Com aplicações

que vão de chatbots a sistemas de geração de texto sofisticados, esses modelos são ferramentas essenciais para o desenvolvimento de soluções em comunicação, análise de dados e automação inteligente.

5.3.4 Redes neurais para processamento de texto

As redes neurais artificiais revolucionaram o PLN ao oferecer modelos capazes de capturar padrões, relações semânticas e estruturas complexas da linguagem humana. Ao processar textos como sequências de dados, essas redes se tornaram fundamentais em tarefas como tradução automática, análise de sentimentos, geração de texto, classificação e muito mais.

Adiante, exploraremos os principais tipos de redes neurais aplicadas ao PLN e suas aplicações.

Redes neurais no PLN

As redes neurais revolucionaram o campo do PLN ao oferecer uma abordagem mais flexível, precisa e adaptável em comparação com técnicas tradicionais. Uma das principais vantagens é a sua capacidade de generalização. Redes neurais aprendem padrões linguísticos complexos diretamente a partir de grandes volumes de exemplos, o que as torna capazes de lidar com variações de linguagem e contextos diversos, mesmo sem regras explícitas.

Além disso, essas redes eliminam a necessidade de engenharia manual de atributos (feature engineering), uma etapa que exigia tempo e conhecimento linguístico especializado. Em vez disso, as redes neurais são capazes de aprender representações distribuídas de palavras, frases e sentenças, extraindo automaticamente características relevantes a partir dos dados brutos.

Outro grande diferencial é o suporte à compreensão contextual e sequencial da linguagem. Arquiteturas como RNNs, LSTMs e transformers permitem que o modelo interprete o significado das palavras com base no contexto anterior e posterior, capturando dependências semânticas, nuances sintáticas e estruturas discursivas com maior precisão.

As redes neurais demonstram alta flexibilidade, podendo ser aplicadas a uma ampla gama de tarefas no PLN. Entre elas estão: classificação de texto, tradução automática, resposta a perguntas, análise de sentimentos, sumarização automática e geração de texto, entre outras. Essa versatilidade torna as redes neurais uma escolha estratégica para soluções modernas e robustas em linguagem natural.

Veremos nos tópicos a seguir as principais arquiteturas de redes neurais para texto.

Feedforward neural networks (FNNs)

As redes neurais feedforward representam a forma mais simples de arquitetura neural. São compostas por camadas densas (fully connected), nas quais os dados fluem em uma única direção – da camada de entrada até a camada de saída, sem ciclos ou retroalimentações. São comumente aplicadas em tarefas de classificação de texto, utilizando representações vetoriais estáticas como BoW ou TF-IDF, que transformam documentos em vetores numéricos de características.

Apesar de sua simplicidade, as FNNs são eficazes para tarefas básicas e bem definidas, como classificação de sentimentos, categorização de e-mails ou detecção de spam, especialmente quando o volume de dados é limitado e o contexto sequencial não é essencial.

No entanto, uma limitação importante dessa abordagem é que ela não leva em consideração a ordem das palavras nem o contexto linguístico em que elas aparecem. Como consequência, duas frases com as mesmas palavras, mas em ordens diferentes, podem ser tratadas como equivalentes pelo modelo, o que compromete a compreensão semântica em tarefas mais complexas. Por esse motivo, as FNNs são frequentemente substituídas por modelos mais avançados em contextos que exigem interpretação profunda e contextualizada da linguagem.

Redes neurais recorrentes (RNNs)

As RNNs foram desenvolvidas para lidar com dados sequenciais, como textos, áudios e séries temporais. Diferentemente das redes neurais tradicionais, as RNNs são projetadas para que a saída de cada etapa dependa não apenas da entrada atual, mas também dos estados anteriores da rede, permitindo a retenção de informações ao longo da sequência.

Essa característica confere às RNNs uma vantagem significativa em tarefas que exigem a compreensão do contexto ao longo do tempo, sendo especialmente úteis em aplicações de PLN, em que a ordem e a relação entre palavras são essenciais para interpretar o significado de uma sentença.

Entre os exemplos de aplicação mais comuns estão: os sistemas de autocompletar texto, em que o modelo prevê a próxima palavra com base na sequência já digitada; o reconhecimento automático de fala, que converte sinais de áudio em texto coerente; e a tradução automática simples, em que frases de um idioma são convertidas para outro mantendo a estrutura sequencial.

No entanto, uma das principais limitações das RNNs tradicionais é a dificuldade de capturar dependências de longo prazo dentro das sequências. À medida que a distância entre palavras relevantes aumenta, torna-se mais difícil para o modelo manter a informação útil, devido ao problema conhecido como desvanecimento ou explosão do gradiente durante o treinamento. Essa limitação motivou o desenvolvimento de arquiteturas mais sofisticadas, como as LSTM e GRU, que tratam essas questões de maneira mais eficiente.

LSTM e GRU

As arquiteturas LSTM e GRU são extensões das redes neurais recorrentes, projetadas especificamente para superar as limitações dessas redes em lidar com dependências de longo prazo em sequências. Ambas utilizam mecanismos de portas internas (gates) que controlam o fluxo de informações ao longo do tempo, permitindo que o modelo decida quais dados devem ser mantidos, atualizados ou descartados em cada etapa do processamento.

Esses mecanismos tornam as LSTM e GRU mais eficazes para aprender relações distantes entre palavras ou eventos em textos, superando problemas comuns em RNNs tradicionais, como o desvanecimento ou

a explosão dos gradientes. Como resultado, essas arquiteturas se tornaram muito utilizadas em tarefas nas quais a preservação de contexto ao longo de grandes sequências é essencial. Algumas das aplicações mais frequentes incluem:

- Geração de texto criativo, como na composição automática de músicas, histórias ou roteiros, na qual é necessário manter coerência ao longo de diversas sentenças.
- Análise de sentimentos em frases longas ou complexas, em que o modelo precisa identificar a polaridade emocional com base em múltiplas pistas distribuídas pela sentença.
- Tradução automática neural, na qual é fundamental reter o sentido e a estrutura de frases inteiras durante a conversão entre idiomas.

Tanto LSTM quanto GRU oferecem um equilíbrio entre capacidade de memória e eficiência computacional, sendo escolhidas conforme a complexidade da tarefa e os recursos disponíveis.

Redes neurais convolucionais (CNNs) para texto

Embora tenham sido originalmente desenvolvidas para tarefas de visão computacional, as CNNs também têm se mostrado eficazes em aplicações de PLN, especialmente em tarefas que exigem a detecção de padrões locais em sequências de palavras. No contexto textual, as CNNs são capazes de identificar estruturas relevantes, como expressões, frases curtas ou n-gramas significativos, sem depender diretamente da ordem global do texto.

O funcionamento das CNNs para texto envolve o uso de filtros convolucionais, que deslizam sobre a sequência de palavras (geralmente representadas por embeddings), capturando características específicas de trechos curtos do texto. Esses filtros atuam como detectores de padrões linguísticos recorrentes, como negações, opiniões fortes ou combinações de termos com significado específico. Entre as principais aplicações das CNNs em PLN, destacam-se:

- A classificação de texto, como a categorização de notícias, resenhas ou comentários.
- A detecção de conteúdo ofensivo, tóxico ou inadequado, por meio da identificação de frases ou palavras-chave com conotação negativa.
- A análise de sentimentos em mensagens curtas, como postagens em redes sociais ou avaliações breves, em que os padrões locais são muitas vezes suficientes para determinar a intenção comunicativa.

As CNNs oferecem vantagens como treinamento eficiente, baixa complexidade computacional e bom desempenho em tarefas que envolvem textos de curta ou média extensão. Embora não sejam as mais indicadas para capturar dependências de longo prazo, seu uso estratégico continua relevante em muitas soluções de PLN.



Saiba mais

Para saber mais sobre CNNs leia o capítulo 21 sobre aprendizado profundo do livro:

RUSSELL, S. J.; NORVIG, P. *Aprendizagem por reforço*. In: RUSSELL, S. J.; NORVIG, P. *Inteligência artificial: uma abordagem moderna*. Rio de Janeiro: LTC, 2022.

Transformers

A arquitetura transformer representou um marco no avanço do PLN ao introduzir um modelo altamente eficiente e escalável, capaz de analisar todas as palavras de uma sequência simultaneamente por meio do inovador mecanismo de atenção. Essa capacidade de processamento paralelo e contextualizado, aliada à flexibilidade estrutural, tornou os transformers a base dos modelos de linguagem mais poderosos da atualidade.

Entre os componentes-chave dessa arquitetura destaca-se o mecanismo de self-attention, responsável por calcular a relevância de cada palavra em relação às demais dentro da mesma sentença. Isso permite ao modelo capturar dependências de longo alcance e relações semânticas complexas, mesmo entre palavras distantes. Como a arquitetura não possui recorrência, a preservação da ordem sequencial é garantida por meio do **positional encoding**, um mecanismo que insere informações sobre a posição das palavras, permitindo que o modelo compreenda a estrutura do texto.

Diversos modelos de linguagem amplamente utilizados são construídos sobre a base do transformer, cada um com características específicas:

- **BERT**: voltado para tarefas de compreensão de texto, como classificação, extração de entidades e resposta a perguntas.
- **GPT**: projetado para a geração de texto fluida e criativa, com forte capacidade preditiva e contextual.
- **T5, RoBERTa e XLNet**: modelos mais recentes com foco em multitarefas, que combinam compreensão e geração, adaptando-se a uma variedade de aplicações com alto desempenho.

As principais aplicações da arquitetura transformer abrangem desde a compreensão profunda da linguagem natural até a geração de textos coerentes e relevantes. Graças à sua versatilidade, escalabilidade e capacidade de capturar relações contextuais ricas, os transformers tornaram-se o padrão de excelência em PLN, superando significativamente modelos anteriores em termos de desempenho e aplicabilidade.

Embeddings como entrada das redes

Independentemente da arquitetura utilizada – seja uma rede recorrente, convolucional ou baseada em transformers –, todas as redes neurais aplicadas ao PLN dependem de uma etapa fundamental: a conversão de palavras em representações numéricas vetoriais, conhecidas como embeddings. Essas representações permitem que a linguagem humana, naturalmente ambígua e rica em significados, seja processada computacionalmente de forma eficiente e estruturada.

Os word embeddings mapeiam cada palavra para um vetor denso de dimensões fixas, em que as relações semânticas e sintáticas entre os termos são preservadas no espaço vetorial. Palavras com significados semelhantes, por exemplo, tendem a ocupar posições próximas. Entre as técnicas clássicas de geração de embeddings destacam-se:

- **Word2Vec**: aprende a representação de palavras com base no contexto de uso (modelo Skip-gram ou CBOW).
- **GloVe**: combina coocorrência global com contexto local para capturar relações semânticas.
- **FastText**: estende o Word2Vec ao considerar subpalavras (n-gramas de caracteres), sendo mais eficaz com palavras raras ou compostas.

Mais recentemente, surgiram os embeddings contextuais, produzidos por modelos como BERT e GPT. Ao contrário dos métodos tradicionais, que atribuem um vetor fixo por palavra, os embeddings contextuais geram representações dinâmicas que variam conforme o uso da palavra na sentença. Isso permite que o modelo compreenda nuances de significado com base no contexto, como em frases em que a palavra “banco” pode se referir a um assento ou a uma instituição financeira.

Essas representações vetoriais são a base de entrada para os modelos neurais, fornecendo uma ponte eficaz entre o texto bruto e os mecanismos de processamento e aprendizado automático, permitindo que a rede capture padrões, relações e significados com alta precisão.



Observação

Execute este comando antes de rodar o código:

```
pip install pandas
```



```

1  import numpy as np
2  import matplotlib.pyplot as plt
3  from sklearn.metrics.pairwise import cosine_similarity
4  from sklearn.decomposition import PCA
5  import pandas as pd
6
7  # Palavras e seus embeddings simulados (4 dimensões)
8  palavras = ["rei", "rainha", "homem", "mulher", "cavalo", "carro"]
9
10 # Dicionário com embeddings fictícios
11 embeddings = {
12     "rei": np.array([0.8, 0.6, 0.1, 0.2]),
13     "rainha": np.array([0.9, 0.5, 0.2, 0.1]),
14     "homem": np.array([0.7, 0.4, 0.2, 0.1]),
15     "mulher": np.array([0.8, 0.3, 0.3, 0.2]),
16     "cavalo": np.array([0.2, 0.1, 0.9, 0.7]),
17     "carro": np.array([0.1, 0.2, 0.8, 0.6])
18 }
19
20 # Convertendo os vetores para uma matriz
21 matriz = np.array([embeddings[p] for p in palavras])
22
23 # Calculando similaridade de cosseno entre os vetores
24 similaridade = cosine_similarity(matriz)
25
26 # Reduzindo de 4 para 2 dimensões para visualização com PCA
27 pca = PCA(n_components=2)
28 reduzido = pca.fit_transform(matriz)
29
30 # Plotando os vetores em 2D
31 plt.figure(figsize=(8, 6))
32 for i, palavra in enumerate(palavras):
33     x, y = reduzido[i]
34     plt.scatter(x, y)
35     plt.text(x + 0.01, y + 0.01, palavra, fontsize=10)
36
37 plt.title("Representação vetorial (embeddings) de palavras - exemplo prático")
38 plt.xlabel("Componente Principal 1")
39 plt.ylabel("Componente Principal 2")
40 plt.grid(True)
41 plt.tight_layout()
42 plt.show()
43
44 # Exibindo a matriz de similaridade como tabela
45 df_sim = pd.DataFrame(similaridade, index=palavras, columns=palavras)
46 print("Matriz de Similaridade de Cosseno entre Palavras:")
47 print(df_sim.round(2))

```

Figura 34 – Representação vetorial (embeddings) de palavras




Figura 35 – Saida

O código anterior:

- simula vetores de palavras semanticamente relacionadas;
- calcula a similaridade de cosseno entre elas;
- usa PCA para projetar os vetores em 2D e exibe um gráfico de dispersão;
- mostra a matriz de similaridade em formato de tabela.

Tabela 2 – Matriz de similaridade de cosseno entre palavras

	rei	rainha	homem	mulher	cavalo	carro
Rei	1.00	0.98	0.98	0.94	0.38	0.38
Rainha	0.98	1.00	1.00	0.97	0.39	0.38
Homem	0.98	1.00	1.00	0.98	0.44	0.43
Mulher	0.94	0.97	0.98	1.00	0.56	0.53
Cavalo	0.38	0.39	0.44	0.56	1.00	0.99
Carro	0.38	0.38	0.43	0.53	0.99	1.00

Desafios no uso de redes neurais para texto

Apesar do avanço significativo que as redes neurais proporcionaram ao PLN, seu uso em aplicações com texto ainda enfrenta uma série de desafios técnicos e éticos que exigem atenção cuidadosa.

Um dos principais obstáculos é a necessidade de grandes volumes de dados para que o modelo possa aprender representações linguísticas eficazes. Modelos neurais, especialmente os de arquitetura profunda, exigem conjuntos extensos e variados de texto para evitar aprendizado superficial ou enviesado. Além disso, o alto custo computacional associado ao treinamento e à implementação desses modelos limita seu uso a instituições com infraestrutura robusta, dificultando a democratização da tecnologia.

Outro ponto crítico é o risco de viés linguístico. Como os modelos aprendem diretamente a partir dos dados disponíveis, eles podem absorver e reproduzir preconceitos sociais, culturais ou ideológicos presentes nos corpora de treinamento. Isso representa um risco significativo em contextos sensíveis, como análise jurídica, atendimento ao cliente ou sistemas de recomendação.

Além disso, as redes neurais profundas ainda são percebidas como "caixas-pretas", dificultando a explicabilidade e a interpretação de suas decisões. Essa falta de transparência pode comprometer a confiança dos usuários e dificultar auditorias em ambientes regulados.

Por fim, há o problema do sobreajuste (overfitting), especialmente em tarefas com poucos dados rotulados. Nesses casos, o modelo pode se adaptar excessivamente ao conjunto de treinamento e perder a capacidade de generalização, resultando em desempenho instável em dados novos.

Enfrentar esses desafios requer o uso de boas práticas, como técnicas de regularização, curadoria ética dos dados, uso de modelos interpretáveis e, sempre que possível, a aplicação de abordagens híbridas que combinem inteligência artificial com supervisão humana.

As redes neurais aplicadas ao processamento de texto permitiram que os sistemas de IA entendessem, gerassem e interagissem com linguagem natural de maneira muito mais eficaz. Das RNNs às arquiteturas baseadas em transformers, essas redes são hoje ferramentas fundamentais para criar aplicações que lidam com textos em diferentes contextos, desde chatbots até sistemas de recomendação personalizados. Seu domínio é essencial para profissionais que desejam desenvolver soluções linguísticas inteligentes e inovadoras.

5.3.5 Aplicação de transformer e BERT

A arquitetura transformer revolucionou o PLN, permitindo que modelos de IA entendessem o contexto completo das palavras em uma frase, com alta precisão e desempenho. Um dos modelos mais influentes baseados nessa arquitetura é o BERT, desenvolvido pela Google. Ele se tornou uma referência no uso de atenção bidirecional e pré-treinamento contextualizado para compreensão de linguagem.

Os transformers são uma arquitetura de rede neural introduzida por Vaswani *et al.* (2023) no artigo seminal *Attention is all you need*. Esse modelo marcou uma ruptura significativa no campo do PLN ao superar as limitações das arquiteturas anteriores baseadas em sequências, como as RNNs e LSTMs.

Diferentemente das RNNs, que processam os dados sequencialmente e, portanto, têm dificuldades com paralelização e longas dependências, os transformers foram projetados para processar todas as palavras de uma sequência simultaneamente, o que aumenta de maneira drástica a eficiência de treinamento e melhora o aproveitamento do contexto global de uma frase ou um parágrafo.

Um dos principais avanços dessa arquitetura é o uso do mecanismo de atenção múltipla, conhecido como **multi-head attention**. Esse mecanismo permite que o modelo aprenda relações complexas entre as palavras em diferentes níveis da estrutura da sentença, como dependências sintáticas, semânticas ou posicionais. Com isso, os transformers conseguem capturar de maneira mais precisa o significado das palavras de acordo com o contexto em que estão inseridas. Além disso, os transformers oferecem vantagens como:

- Paralelismo eficiente durante o treinamento, possibilitando o uso mais eficaz de hardware especializado como GPUs e TPUs.
- Capacidade de processar sequências longas com melhor estabilidade e desempenho.
- Base escalável para pré-treinamento e fine-tuning, sendo o alicerce de modelos de linguagem de última geração, como BERT, GPT, T5 e RoBERTa.

Graças a essas qualidades, os transformers se tornaram o padrão dominante em aplicações modernas de PLN, tradução automática, geração de texto, resposta a perguntas, sumarização e muitas outras tarefas linguísticas avançadas.

Atenção (attention mechanism)

O mecanismo de atenção é uma técnica central nos modelos de linguagem modernos, especialmente nos transformers. Ele permite que o modelo focalize as partes mais relevantes de uma sequência de texto, mesmo quando estão distantes entre si. Em vez de tratar todas as palavras da mesma forma, o modelo aprende a atribuir diferentes pesos a cada palavra do contexto, destacando aquelas que são mais importantes para a tarefa em questão.

Esse mecanismo é fundamental para lidar com relações linguísticas de longo alcance, como pronomes, ambiguidade estrutural ou referências indiretas, que muitas vezes escapam a modelos sequenciais simples.

Por exemplo, na frase: "O cachorro viu o gato com o telescópio", o modelo precisa decidir quem estava com o telescópio – o cachorro ou o gato. O mecanismo de atenção ajuda nesse processo ao considerar todo o contexto da frase simultaneamente, permitindo que o modelo identifique a interpretação mais provável com base na estrutura e nos padrões linguísticos aprendidos.

Ao fazer isso, o modelo melhora significativamente sua capacidade de compreensão contextual, o que é essencial em tarefas como tradução automática, geração de texto, resposta a perguntas e análise semântica.

BERT

O BERT é um modelo de linguagem pré-treinado desenvolvido pelo Google, baseado na arquitetura transformer, que se destacou por sua capacidade de compreensão profunda do texto. Lançado em 2018, o BERT introduziu um avanço importante ao aplicar um mecanismo de atenção bidirecional, permitindo que o modelo considere simultaneamente o contexto anterior e posterior de cada palavra em uma sentença. Essa característica difere dos modelos unidirecionais, como o GPT, que processam o texto apenas da esquerda para a direita ou vice-versa.

O pré-treinamento do BERT é realizado com duas tarefas principais:

- **MLM:** o modelo aprende a prever palavras ocultas (mascaradas) dentro de uma frase. Por exemplo, em "O gato ____ no sofá", o modelo deve prever a palavra mais provável, como "dormiu".
- **Next sentence prediction (NSP):** o modelo aprende a identificar se uma segunda frase é uma continuação lógica da primeira, ajudando na compreensão de relações entre sentenças.

Essas tarefas treinam o BERT para capturar nuances semânticas e sintáticas de forma eficaz, o que o torna altamente adaptável a diversas aplicações em PLN.

Características do BERT:

- **Bidirecionalidade real:** uma das maiores inovações do BERT é sua capacidade de entender o contexto completo de uma palavra, observando tanto o que vem antes quanto o que vem depois, o que melhora a precisão da interpretação semântica.
- **Baseado no encoder do transformer:** ao utilizar apenas a parte de codificação (encoder) da arquitetura transformer, o BERT é otimizado para tarefas de compreensão de linguagem, como classificação de texto, análise de sentimentos e resposta a perguntas.
- **Modelo transferível:** após o pré-treinamento, o BERT pode ser facilmente ajustado (fine-tuned) para tarefas específicas com relativamente poucos dados rotulados, o que amplia seu uso em diferentes domínios, como jurídico, médico ou educacional.
- **Treinado em larga escala:** o modelo é inicialmente treinado em grandes corpora, como a Wikipedia em inglês e livros digitalizados, o que garante uma base linguística rica e variada.

Graças a essas características, o BERT tornou-se uma base sólida para diversos modelos derivados (como RoBERTa, ALBERT e DistilBERT) e permanece como referência em tarefas de entendimento profundo da linguagem natural.

Aplicações práticas de BERT e transformers:



Observação

Execute este comando antes de rodar o código:

```
pip install transformers
```

```
1 from transformers import pipeline
2
3 # Carrega o pipeline de análise de sentimentos com BERT
4 analisador_sentimento = pipeline("sentiment-analysis")
5
6 # Lista de frases para análise
7 frases = [
8     "I am very happy with the results of the project.", # "Estou muito feliz com os resultados do projeto.",
9     "This service was terrible and disappointing.", # "Esse serviço foi terrível e decepcionante.",
10    "The quality is acceptable but could be improved.", # "A qualidade é aceitável, mas pode melhorar.",
11    "I'm not sure I liked the service." # "Não tenho certeza se gostei do atendimento.",
12 ]
13
14 # Aplica o modelo nas frases
15 resultados = analisador_sentimento(frases)
16
17 # Exibe os resultados
18 for frase, resultado in zip(frases, resultados):
19     print(f"Frase: {frase}")
20     print(f"Sentimento: {resultado['label']} (confiança: {resultado['score']:.3f})\n")
```

Figura 36

```
Frase: I am very happy with the results of the project.
Sentimento: POSITIVE (confiança: 1.000)

Frase: This service was terrible and disappointing.
Sentimento: NEGATIVE (confiança: 1.000)

Frase: The quality is acceptable but could be improved.
Sentimento: NEGATIVE (confiança: 0.624)

Frase: I'm not sure I liked the service.
Sentimento: NEGATIVE (confiança: 1.000)
```

Figura 37 – Saída

O que esse código faz:

- Utiliza o modelo BERT (por trás do pipeline sentiment-analysis).
- Analisa o sentimento de diferentes frases (positivo ou negativo).
- Mostra o resultado com a confiança da predição.

Aplicações do BERT

O modelo BERT, ao ser ajustado por meio de fine-tuning, pode ser adaptado com alta eficácia para diversas tarefas de PLN, apresentando desempenho superior às abordagens tradicionais.

Uma das aplicações mais comuns é a classificação de texto, em que o modelo aprende a atribuir rótulos a conteúdos com base em seu significado. Isso permite, por exemplo, detectar se um e-mail é spam ou legítimo, classificar automaticamente notícias em categorias como política, esportes ou economia, ou ainda identificar a intenção de mensagens em canais de atendimento – como distinguir entre uma reclamação, um elogio ou uma solicitação de suporte.

Outra aplicação bastante relevante é a análise de sentimentos. Diferentemente de métodos baseados em palavras-chave, o BERT é capaz de capturar nuances emocionais e contextuais da linguagem, permitindo identificar emoções expressas de forma sutil ou ambígua, como ironias ou frases com sentimentos mistos.

No campo da resposta a perguntas (Question Answering), o BERT se destaca por sua capacidade de ler um texto e localizar, com precisão, a resposta para uma pergunta formulada pelo usuário. Por exemplo, ao receber um trecho como "A Terra é o terceiro planeta a partir do Sol" e a pergunta "Qual é o terceiro planeta do sistema solar?", o modelo consegue identificar corretamente a resposta como "Terra".

Além disso, o BERT é utilizado em tarefas de NER, nas quais o modelo identifica e classifica elementos específicos em um texto, como nomes de pessoas, organizações, locais geográficos, datas ou valores monetários, o que é essencial para sistemas de extração de informações em documentos jurídicos, notícias ou registros clínicos.

Por fim, o BERT também é uma poderosa ferramenta para a geração de embeddings contextuais. Diferentemente de vetores fixos, os embeddings levam em conta o contexto completo em que a palavra aparece, tornando-os ideais para tarefas como cálculo de similaridade semântica entre frases, busca textual baseada em significado ou sistemas de recomendação que utilizam descrição textual como base de comparação.

Variações do BERT

Desde o lançamento do BERT, diversas variantes foram desenvolvidas para atender a necessidades específicas de desempenho, domínio ou eficiência computacional. Entre as mais conhecidas, destaca-se o DistilBERT, uma versão compacta do modelo original, projetada para ser mais leve e rápida, mantendo a maior parte da performance com um menor consumo de recursos – ideal para aplicações em tempo real ou em dispositivos com capacidade limitada.

O RoBERTa é outra versão muito utilizada, que aprimora o BERT ao ser treinado com um volume de dados significativamente maior e sem a tarefa de NSP. Essa alteração, aliada a outras melhorias no processo de pré-treinamento, proporciona desempenho superior em várias tarefas de PLN.

Já o ALBERT (A Lite BERT) foi desenvolvido com foco em redução de complexidade computacional, utilizando técnicas como compartilhamento de pesos e fatoração da matriz de embedding. Isso o torna

mais eficiente em termos de memória e tempo de treinamento, sem comprometer significativamente sua precisão.

Além dessas versões otimizadas, surgiram também modelos especializados em domínios técnicos. O BioBERT, por exemplo, foi adaptado para a linguagem biomédica, sendo treinado com artigos científicos e bases de dados da área da saúde. Isso o torna extremamente eficaz em tarefas como extração de informações clínicas, interpretação de literatura médica e classificação de diagnósticos.

De forma semelhante, o LegalBERT foi treinado com textos jurídicos, como leis, contratos e decisões judiciais, o que o capacita a lidar com os desafios específicos da linguagem técnica do direito, como ambiguidade legal, terminologia especializada e estruturas textuais complexas.

Essas variantes mostram a versatilidade do BERT e sua capacidade de ser adaptado para diferentes cenários, proporcionando soluções mais precisas e eficientes para aplicações em contextos variados.

Benefícios do uso de BERT e transformers

Os transformers e modelos como o BERT trouxeram um novo padrão de excelência ao PLN, com capacidade de entender a semântica profunda da linguagem e gerar resultados altamente precisos. Sua aplicação vai desde respostas automáticas em chatbots até classificação jurídica de documentos, tornando-se indispensáveis no desenvolvimento de soluções modernas de IA linguística. Para quem trabalha com desenvolvimento de sistemas inteligentes, compreender essas ferramentas é essencial para explorar o potencial completo da linguagem humana nas máquinas.

Quadro 19 – Benefícios do uso de BERT e transformers

Benefício	Descrição
Alta precisão	Compreensão profunda de contexto e significado
Flexibilidade	Pode ser ajustado para múltiplas tarefas de PLN
Pré-treinamento	Reutilizável em diferentes domínios com pouco ajuste
Comunidade ativa	Suporte por bibliotecas como Hugging Face e Google AI

6 VISÃO COMPUTACIONAL

A visão computacional é uma área da IA que tem como objetivo permitir que as máquinas "vejam", interpretem e compreendam o conteúdo de imagens e vídeos, imitando a capacidade visual dos seres humanos. Por meio dessa tecnologia, computadores podem realizar tarefas como identificar objetos, reconhecer rostos, analisar movimentos e até tomar decisões com base em imagens.

A visão computacional (do inglês computer vision) envolve o processamento, análise e compreensão de imagens digitais, extraindo informações relevantes que possam ser utilizadas por sistemas inteligentes. Isso inclui desde operações simples, como detecção de bordas e contornos, até tarefas complexas, como o entendimento do contexto de uma cena.

Objetivos da visão computacional

A visão computacional é um campo da IA que busca desenvolver sistemas capazes de interpretar e compreender imagens e vídeos da mesma forma que os seres humanos. Seus principais objetivos envolvem o reconhecimento de padrões visuais, permitindo que algoritmos identifiquem características recorrentes em imagens, como formas, texturas ou cores. Entre suas aplicações centrais está a capacidade de detectar e classificar objetos automaticamente, ou seja, identificar o que está presente em uma imagem e atribuir rótulos como "carro", "pessoa" ou "animal".

Além disso, a visão computacional também se dedica à análise de movimentos em vídeos, sendo fundamental para aplicações como vigilância inteligente, rastreamento de pessoas ou análise de comportamento. Outra função relevante é a segmentação de imagens, que consiste em dividir uma imagem em regiões distintas, separando, por exemplo, o fundo de um objeto ou diferentes partes de um organismo em exames médicos.

Por fim, um objetivo central da área é a conversão de imagens em dados estruturados, tornando possível integrar a informação visual em sistemas automatizados de decisão, reconhecimento facial, diagnósticos médicos, veículos autônomos, entre outras aplicações de ponta.

Aplicações da visão computacional em diferentes áreas e suas principais tarefas

A visão computacional possui várias aplicações em diversos setores, contribuindo significativamente para a automação, a tomada de decisões e a melhoria de processos.

Na área de segurança, é utilizada em sistemas de reconhecimento facial, controle de acesso e monitoramento em tempo real, permitindo a identificação de pessoas e comportamentos suspeitos em ambientes públicos ou privados.

Na medicina, a tecnologia é empregada em diagnósticos por imagem, como na análise de radiografias, tomografias e ressonâncias magnéticas, auxiliando na detecção precoce de tumores e outras anomalias com precisão superior à observação humana isolada.

No setor industrial, a visão computacional é aplicada em controle de qualidade e inspeção automatizada, identificando falhas em produtos durante a linha de produção, garantindo maior padronização e redução de desperdícios.

Na agricultura, a tecnologia permite a identificação de pragas, doenças e deficiências nutricionais em plantações, por meio da análise de imagens captadas por drones ou sensores, promovendo uma agricultura mais eficiente e sustentável.

No varejo, a visão computacional viabiliza a análise do comportamento dos consumidores dentro das lojas, rastreando trajetórias, expressões faciais e padrões de interesse, o que contribui para o aprimoramento da experiência do cliente e estratégias de marketing mais eficazes.

Na área de transportes, é essencial para sistemas de leitura automática de placas, direção autônoma e semáforos inteligentes, que utilizam câmeras e algoritmos para interpretar o ambiente em tempo real e tomar decisões com base nas condições do trânsito.

Por fim, no setor de esportes, a tecnologia é aplicada no rastreamento de atletas, na análise de jogadas e no monitoramento do desempenho físico e técnico, auxiliando treinadores e comentaristas na avaliação mais precisa das partidas.

As principais tarefas da visão computacional são:

- **Deteção de objetos (object detection):** identifica a presença e localização de objetos dentro de uma imagem, desenhando caixas delimitadoras (bounding boxes). Exemplo: detectar pedestres e veículos em imagens de tráfego.
- **Classificação de imagens:** associa uma categoria ou rótulo a uma imagem inteira. Exemplo: dizer se uma imagem representa um gato, cachorro ou carro.
- **Segmentação semântica:** associa rótulos a cada pixel da imagem, diferenciando objetos até em áreas sobrepostas. Exemplo: separar o céu, a rua e os veículos em uma imagem urbana.
- **Reconhecimento facial:** identifica e compara rostos humanos em imagens ou vídeos. É aplicado em sistemas de segurança, desbloqueio de dispositivos, entre outros.
- **Reconhecimento óptico de caracteres (OCR):** converte textos em imagens (como documentos escaneados ou placas de carro) em texto editável digitalmente.
- **Rastreamento de objetos (tracking):** acompanha objetos em movimento ao longo de uma sequência de quadros em vídeo.



Lembrete

Um pixel (abreviação de picture element, ou "elemento da imagem" em português) é a menor unidade de uma imagem digital. Ele representa um ponto individual que contém informações de cor e brilho. Quando observamos uma foto, uma tela de computador, celular ou televisão, estamos, na verdade, vendo milhões de pixels organizados em uma grade (ou matriz), cada um com uma cor específica que, juntos, formam a imagem completa. Em imagens coloridas, cada pixel geralmente é composto por três canais de cor – vermelho (R), verde (G) e azul (B) –, que se combinam para produzir uma ampla gama de tonalidades. A quantidade de pixels em uma imagem determina sua resolução, e quanto mais pixels houver, maior será a definição e o nível de detalhe visível. Por isso, dispositivos com maior resolução oferecem imagens mais nítidas e realistas.

Há técnicas e algoritmos utilizados na visão computacional, que serão descritos a seguir.

Processamento de imagem tradicional

As técnicas tradicionais de visão computacional baseiam-se principalmente em métodos estatísticos e matemáticos aplicados diretamente sobre os pixels das imagens. Entre os recursos mais utilizados estão os filtros convolucionais, os histogramas de cor ou de gradientes e diversas transformações espaciais, que permitem a detecção de formas, bordas, texturas e padrões visuais. Essas técnicas foram, por muitos anos, o alicerce da visão computacional clássica, sendo muito empregadas em tarefas como segmentação, detecção de objetos e alinhamento de imagens.

Para implementá-las, duas bibliotecas são geralmente utilizadas: a OpenCV (Open Source Computer Vision Library), uma das mais completas e eficientes para manipulação e análise de imagens e vídeos, e a Pillow (PIL – Python Imaging Library), uma biblioteca mais simples e leve, ideal para tarefas básicas de processamento de imagem como redimensionamento, corte, rotação e ajustes de cor. Embora os métodos baseados em aprendizado profundo tenham ganhado destaque nos últimos anos, essas ferramentas e técnicas tradicionais continuam sendo essenciais em soluções com restrições de hardware ou que exigem alto desempenho em tempo real.

Redes neurais convolucionais (CNNs)

As CNNs são a base da visão computacional moderna e revolucionaram a forma como as máquinas interpretam imagens. Sua principal característica é a capacidade de extrair automaticamente características visuais hierárquicas, desde padrões simples, como bordas e texturas, até estruturas mais complexas, como rostos, objetos ou cenas completas. Isso é possível graças ao uso de camadas convolucionais, que atuam como filtros treináveis, e camadas de pooling, que ajudam a reduzir a dimensionalidade preservando informações essenciais.

As CNNs são utilizadas em tarefas como classificação de imagens (por exemplo, identificar se uma imagem contém um gato ou um cachorro), detecção de objetos (localizando e rotulando diferentes elementos em uma cena), e segmentação semântica, que consiste em dividir uma imagem em regiões com significados distintos, como separar o fundo dos objetos em primeiro plano.

Diversas arquiteturas se destacam no desenvolvimento e evolução dessa tecnologia. A LeNet, uma das primeiras CNNs, foi pioneira no reconhecimento de dígitos manuscritos. Em seguida, a AlexNet popularizou o uso de CNNs ao vencer competições internacionais com desempenho muito superior às abordagens anteriores. A visual geometry group (VGG) introduziu uma estrutura mais profunda e simples, enquanto a ResNet inovou com conexões residuais que permitem treinar redes extremamente profundas sem perda de desempenho.

Modelos mais recentes, como o You Only Look Once (YOLO), são voltados para detecção em tempo real, oferecendo excelente equilíbrio entre velocidade e precisão. Já a Mask R-CNN é uma das arquiteturas mais avançadas para segmentação de instâncias, sendo capaz de identificar e isolar cada objeto individualmente em uma imagem, inclusive com a geração de máscaras pixel a pixel.

Em conjunto, essas redes e suas variantes formam a espinha dorsal da maioria dos sistemas inteligentes que lidam com imagem e vídeo em áreas como saúde, segurança, indústria, mobilidade e entretenimento.

Aprendizado supervisionado, não supervisionado e autossupervisionado

No contexto da visão computacional, diferentes paradigmas de aprendizado de máquina são utilizados conforme a natureza dos dados e o objetivo da tarefa. O aprendizado supervisionado é o mais tradicional e envolve o uso de imagens rotuladas, ou seja, cada imagem do conjunto de dados é previamente associada a uma categoria ou informação específica. Essa abordagem permite treinar modelos para tarefas como classificação de imagens, detecção de objetos ou segmentação semântica, com alta precisão – desde que se disponha de uma quantidade significativa de dados anotados manualmente.

Por outro lado, o aprendizado não supervisionado busca extrair conhecimento a partir de dados sem rótulos explícitos. Os algoritmos tentam identificar padrões, estruturas ou agrupamentos naturais nas imagens, sendo úteis, por exemplo, para organização automática de acervos visuais, compressão de dados, ou para descobrir categorias ocultas dentro de um conjunto de imagens.

Uma abordagem emergente e cada vez mais relevante é o aprendizado autossupervisionado (self-supervised learning). Nessa técnica, os modelos são pré-treinados com grandes volumes de dados não rotulados, utilizando tarefas artificiais – como prever partes ocultas de uma imagem ou reconhecer diferentes transformações aplicadas a ela – para aprender representações visuais ricas. Posteriormente, essas representações podem ser refinadas com uma pequena quantidade de dados rotulados, combinando o melhor dos dois mundos: eficiência de dados e generalização robusta. Essa estratégia tem impulsionado os avanços em grandes modelos visuais, especialmente em cenários nos quais a rotulagem manual é cara ou inviável.

Exemplo prático: classificação de imagens com CNN

Um dos exemplos mais comuns de aplicação de redes neurais convolucionais é a classificação de imagens, como diferenciar fotos de gatos e cachorros. O processo começa com a preparação de um conjunto de dados rotulado, no qual cada imagem está identificada com sua respectiva categoria. Em seguida, realiza-se o pré-processamento das imagens, o que geralmente inclui o redimensionamento para uma dimensão uniforme (por exemplo, 128×128 pixels) e a normalização dos valores de pixel, a fim de facilitar o aprendizado da rede.

Durante o treinamento, a CNN aprende a extrair padrões visuais hierárquicos, desde bordas e texturas, nas camadas iniciais, até formas mais complexas, nas camadas profundas, que caracterizam cada classe. Após o treinamento, o modelo é avaliado com um conjunto de dados de teste, que contém imagens inéditas para medir sua capacidade de generalização, geralmente por meio de métricas como acurácia, precisão e recall.

Uma vez validado, o modelo final pode ser utilizado para classificar novas imagens, ou seja, prever automaticamente se uma imagem desconhecida representa um gato ou um cachorro com base nos

padrões aprendidos. Essa abordagem é a base de diversos sistemas inteligentes de reconhecimento de imagem presentes em aplicativos móveis, redes sociais, sistemas de vigilância e ferramentas industriais.

Desafios da visão computacional

Apesar dos avanços significativos, a visão computacional ainda enfrenta diversos desafios técnicos e conceituais que afetam diretamente a precisão e a robustez dos modelos. Um dos principais obstáculos é a ambiguidade visual, em que objetos com aparência semelhante – como diferentes raças de cães, ou copos e garrafas vistos de certos ângulos – podem confundir os algoritmos, levando a classificações incorretas.

Outro fator crítico está relacionado às condições variáveis de iluminação. Mudanças na luz ambiente, sombras ou reflexos podem modificar drasticamente a aparência de uma imagem, comprometendo a detecção e o reconhecimento de padrões visuais, especialmente em ambientes não controlados.

Além disso, situações em que há oclusões parciais ou sobreposição entre objetos representam um desafio para tarefas como segmentação semântica e detecção precisa, uma vez que parte da informação visual fica oculta ou fundida com outros elementos da cena.

Um dos desafios mais complexos é a capacidade de generalização dos modelos. Em muitos casos, redes treinadas em bases de dados bem-organizadas e balanceadas não mantêm o mesmo desempenho quando expostas a dados do mundo real, que são frequentemente mais ruidosos, desbalanceados e variados. Isso exige o desenvolvimento de arquiteturas mais resilientes e a aplicação de técnicas de regularização e data augmentation (aumento de dados) para melhorar a adaptabilidade dos modelos.

A visão computacional é uma das áreas mais empolgantes e promissoras da IA, com aplicações reais que impactam diretamente a sociedade. De diagnósticos médicos a carros autônomos, ela permite que sistemas enxerguem e compreendam o mundo visual, abrindo caminho para decisões inteligentes e automação de processos complexos. Dominar seus fundamentos e ferramentas é essencial para qualquer desenvolvedor interessado em IA aplicada a imagens e vídeos.

6.1 Introdução à visão computacional

A visão computacional é um ramo da IA voltado para a criação de sistemas capazes de "ver", interpretar e compreender informações visuais – como imagens e vídeos – de forma semelhante à percepção humana. Assim como os seres humanos utilizam os olhos e o cérebro para decodificar o mundo ao seu redor, a visão computacional busca dotar máquinas da capacidade de interpretar o ambiente visual, automatizando tarefas que tradicionalmente exigem percepção humana.

Esse campo tem crescido exponencialmente nas últimas décadas, impulsionado por avanços em aprendizado profundo, pela disponibilidade de grandes volumes de dados visuais e pelo aumento expressivo da capacidade computacional. Atualmente, está presente em aplicações que vão desde reconhecimento facial em smartphones até sistemas de direção autônoma e diagnósticos médicos baseados em imagem.

De forma conceitual, a visão computacional pode ser definida como a área da IA responsável por permitir que computadores extraiam informações úteis a partir de dados visuais. O processo envolve

etapas como captura da imagem, processamento digital e análise de conteúdo, com o objetivo de gerar conhecimento acionável. Por exemplo, em um supermercado, um sistema de visão computacional pode capturar a imagem de um produto no caixa, identificá-lo automaticamente com base em sua aparência e registrá-lo diretamente no sistema de pagamento – tudo sem intervenção humana.

É importante diferenciar visão computacional de processamento de imagem, embora os dois termos sejam frequentemente confundidos. O processamento de imagem se concentra na manipulação ou melhoria das imagens, aplicando técnicas como realce de contraste, filtros de suavização ou remoção de ruído. Já a visão computacional vai além, pois seu objetivo é extrair conhecimento a partir das imagens para que sistemas possam tomar decisões ou agir de forma autônoma.

O funcionamento de um sistema de visão computacional geralmente segue uma cadeia lógica. Tudo começa com a captura da imagem ou vídeo, feita por câmeras, sensores ou drones. Em seguida, ocorre o pré-processamento, que pode incluir ajuste de brilho, redimensionamento e remoção de ruídos. Após isso, o sistema realiza a extração de características visuais, como bordas, texturas, formas ou cores, e, então, parte para a análise e interpretação dos dados, aplicando algoritmos de classificação, detecção, rastreamento ou segmentação. Por fim, os resultados podem ser usados para tomada de decisão automatizada ou interação com outros sistemas inteligentes.

A importância da visão computacional está no fato de que a visão é uma das fontes mais ricas de informação sobre o ambiente. Ao permitir que máquinas vejam e interpretem o mundo visual, é possível automatizar tarefas repetitivas, como inspeções industriais, aumentar a precisão de diagnósticos médicos, reduzir falhas humanas em ambientes críticos e desenvolver sistemas inteligentes com percepção visual avançada, como carros autônomos, robôs domésticos ou sistemas de vigilância inteligente.

Diversos setores já se beneficiam diretamente dessa tecnologia. Na saúde, é utilizada para diagnóstico por imagem e monitoramento de pacientes. No setor de segurança, viabiliza o reconhecimento facial e a análise de vídeo em tempo real. Na indústria, contribui com inspeções automatizadas e controle de qualidade. Na agricultura, ajuda na detecção de pragas e na análise de condições de cultivo. O varejo usa visão computacional para identificar produtos e analisar o comportamento dos clientes nas lojas. Já no setor de transportes, a tecnologia é aplicada em sistemas de direção autônoma, leitura de placas e reconhecimento de sinais de trânsito.

Carros autônomos e veículos equipados com sistemas de assistência ao motorista capturam continuamente imagens para navegação e segurança. Essas imagens são processadas em tempo real para tomar decisões de direção.




Figura 38 – Uma amostra da câmera com visão artificial em tempo real com detecção de objetos para condução autônoma

Adaptada de: Abualhoul, Munoz e Nashashibi (2018, p. 4).

Com os avanços recentes, a área evoluiu de métodos baseados em algoritmos manuais, como detecção de bordas ou análise de histogramas, para abordagens modernas com CNNs e modelos de deep learning, capazes de realizar tarefas com precisão comparável à humana em grandes bases de dados visuais.

Entretanto, a visão computacional também enfrenta desafios importantes. Entre eles estão: a ambiguidade visual, que dificulta a interpretação correta de imagens complexas; as variações nas condições de iluminação e ângulo, que podem alterar a percepção dos objetos; o alto custo computacional, exigindo GPUs poderosas para treinar modelos sofisticados; e a capacidade de generalização, uma vez que modelos treinados em um cenário podem falhar em contextos novos e não previstos.

Em síntese, a visão computacional é uma das tecnologias mais promissoras da atualidade e um pilar essencial da próxima geração de sistemas inteligentes. Ao conectar a percepção visual artificial à capacidade de ação autônoma, ela abre caminho para máquinas que interagem com o mundo de forma mais natural, eficiente e segura. Com aplicações práticas em quase todos os setores da economia, dominar seus fundamentos é uma habilidade estratégica para qualquer profissional que deseje atuar com IA aplicada ao mundo real.

6.1.1 Detecção de bordas e reconhecimento de padrões

A detecção de bordas e o reconhecimento de padrões são duas técnicas fundamentais da visão computacional, utilizadas para extrair informações estruturais de imagens. Elas permitem que os sistemas inteligentes compreendam formas, contornos e estruturas visuais, servindo de base para tarefas mais complexas como classificação de objetos, segmentação de imagens, leitura de caracteres e reconhecimento facial.

Detecção de bordas

Trata-se do processo de identificar regiões com variações abruptas de intensidade em uma imagem, geralmente indicando as fronteiras entre objetos diferentes. As bordas destacam os limites visuais e facilitam a interpretação da estrutura da cena.

A detecção de bordas é uma etapa fundamental na visão computacional, especialmente em tarefas que exigem a identificação precisa dos contornos de objetos. Entre as aplicações mais comuns, destacam-se: a delimitação de estruturas em imagens médicas, como tumores ou órgãos em exames de tomografia e ressonância; a segmentação de placas de veículos em sistemas de monitoramento e fiscalização; o pré-processamento para reconhecimento facial, em que o contorno dos olhos, boca e nariz é essencial para a extração de características; e o rastreamento de objetos em vídeos, em que as bordas auxiliam na separação entre figura e fundo ao longo do tempo.

Diversos algoritmos clássicos são utilizados para detectar bordas em imagens digitais. O algoritmo de Sobel é um dos mais conhecidos e utiliza filtros convolucionais horizontais e verticais para identificar mudanças de intensidade nos pixels, facilitando a detecção de bordas verticais e horizontais. De forma semelhante, o método de Prewitt também aplica filtros direcionais, porém com uma ênfase menor nos pixels centrais da máscara, o que pode gerar resultados ligeiramente diferentes em determinadas situações.

Outro método relevante é o Laplaciano, que se diferencia por ser um operador de segunda ordem capaz de detectar variações abruptas de intensidade em todas as direções, sendo útil para encontrar pontos de transição brusca em regiões complexas da imagem.

O algoritmo de Canny, por sua vez, é considerado um dos mais eficazes. Ele combina várias etapas, incluindo suavização da imagem com filtro Gaussiano, cálculo do gradiente de intensidade, supressão não máxima (para eliminar falsas bordas) e aplicação de limiares com histerese, o que permite identificar bordas mais contínuas e precisas mesmo em ambientes com ruído.

Esses algoritmos continuam sendo utilizados tanto em aplicações industriais quanto acadêmicas e servem como base para etapas posteriores de segmentação, reconhecimento de padrões e interpretação semântica em sistemas inteligentes de visão computacional.

Exemplo prático de como realizar a segmentação de imagens usando o operador Sobel em Python com a biblioteca OpenCV:



Observação

Execute este comando antes de rodar o código:

```
pip install opencv-python
```

```

1  import cv2
2  import numpy as np
3  import matplotlib.pyplot as plt
4
5  # Carregue a imagem em tons de cinza
6  imagem = cv2.imread('sua_imagem.jpg', cv2.IMREAD_GRAYSCALE)
7
8  # Aplique o operador de Sobel para detecção de bordas na direção x (horizontal)
9  bordas_x = cv2.Sobel(imagem, cv2.CV_64F, 1, 0, ksize=3)
10
11 # Aplique o operador de Sobel para detecção de bordas na direção y (vertical)
12 bordas_y = cv2.Sobel(imagem, cv2.CV_64F, 0, 1, ksize=3)
13
14 # Calcule a magnitude das bordas (combinação das bordas horizontais e verticais)
15 magnitude_bordas = np.sqrt(bordas_x**2 + bordas_y**2)
16
17 # Aplique um limiar para segmentar as bordas
18 limiar = 100 # Você pode ajustar esse valor conforme necessário
19 imagem_segmentada = cv2.threshold(magnitude_bordas, limiar, 255, cv2.THRESH_BINARY)[1]
20
21 # Exiba a imagem original e a imagem suavizada
22 plt.figure(figsize=(9, 10))
23
24 plt.subplot(3, 2, 1)
25 plt.imshow(imagem, cmap='gray')
26 plt.title('Imagem Original')
27 plt.axis('off')
28
29 plt.subplot(3, 2, 2)
30 bordas_x = np.uint8(np.absolute(bordas_x))
31 plt.imshow(bordas_x, cmap='gray')
32 plt.title('Sobel Horizontal (SobelX)')
33 plt.axis('off')
34
35 plt.subplot(3, 2, 3)
36 bordas_y = np.uint8(np.absolute(bordas_y))
37 plt.imshow(bordas_y, cmap='gray')
38 plt.title('Sobel Vertical (SobelY)')
39 plt.axis('off')
40
41 plt.subplot(3, 2, 4)
42 plt.imshow(magnitude_bordas, cmap='gray')
43 plt.title('Magnitude das Bordas')
44 plt.axis('off')
45
46 plt.subplot(3, 2, 5)
47 plt.imshow(imagem_segmentada, cmap='gray')
48 plt.title('Imagem Segmentada')
49 plt.axis('off')
50
51 plt.show()

```

Figura 39




Figura 40 – Saída. Em A, temos a imagem original. Em B, Sobel horizontal (SobelX). Em C, Sober vertical (SobelY). Em D, a magnitude das bordas. Já em E, vemos a imagem segmentada

Nas figuras 39 e 40, carregamos uma imagem em tons de cinza. Aplicamos o operador Sobel na direção x (horizontal) e na direção y (vertical) para detectar bordas nas duas direções. Calculamos a magnitude das bordas combinando as bordas horizontais e verticais usando a fórmula da hipotenusa. Aplicamos um limiar para segmentar as bordas da imagem. Pixels com intensidade maior que o limiar são definidos como objetos, enquanto pixels com intensidade menor que o limiar são definidos como fundo.

A imagem resultante ("imagem_segmentada") mostra as regiões da imagem em que as bordas foram detectadas. É possível ajustar o valor do limiar de acordo com a imagem e os requisitos de segmentação. Esse é um exemplo básico de como realizar a segmentação de imagens usando o operador Sobel em Python.

```
1 import cv2
2 imagem = cv2.imread('sua_imagem.jpg', 0) # Imagem em escala de cinza
3 bordas = cv2.Canny(imagem, 100, 200)
4 cv2.imshow('Bordas', bordas)
5 cv2.waitKey(0)
6 cv2.destroyAllWindows()
```

Figura 41 – Exemplo prático de detecção de bordas com Canny (em Python)




Figura 42 – Saída

A imagem é o resultado da aplicação do operador Canny para a detecção de bordas em uma fotografia de paisagem natural, contendo formações rochosas, mar e céu. O filtro Canny evidenciou as transições abruptas de intensidade luminosa ao longo da imagem, resultando em um contorno bem definido das estruturas principais, como as bordas das pedras, o recorte da linha do horizonte e detalhes texturais na superfície da água e das rochas.

Podemos observar que, além dos contornos estruturais principais, o operador também capturou bordas de texturas finas, especialmente nas regiões rochosas, nas quais há muita variação de pixel em pequena escala. Esse nível de detalhamento é característico do Canny, pois ele consegue preservar bordas verdadeiras enquanto reduz o número de bordas espúrias por meio da supressão não máxima e do uso de limiares duplos com histerese. O resultado é uma imagem binária de alto contraste, ideal para ser usada como entrada em etapas posteriores de segmentação, reconhecimento de forma ou

reconstrução de cena tridimensional. Esse tipo de aplicação é comum em sistemas de mapeamento geográfico, processamento ambiental e análise automatizada de paisagens naturais.

```
1  import cv2
2  import numpy as np
3  import matplotlib.pyplot as plt
4
5  # Carregue a imagem em tons de cinza
6  imagem = cv2.imread('sua_imagem.jpg', cv2.IMREAD_GRAYSCALE)
7
8  # Aplique o operador Laplaciano para detecção de bordas
9  laplaciano = cv2.Laplacian(imagem, cv2.CV_64F)
10
11 # Converta a imagem resultante para valores não negativos
12 laplaciano_absoluto = np.abs(laplaciano)
13
14 # Aplique um limiar para segmentar as bordas
15 limiar = 100 # Você pode ajustar esse valor conforme necessário
16 imagem_segmentada = cv2.threshold(laplaciano_absoluto, limiar, 255, cv2.THRESH_BINARY)[1]
17
18 # Exiba a imagem original, o operador Laplaciano e a imagem segmentada
19 plt.figure(figsize=(10, 8))
20
21 plt.subplot(2, 2, 1)
22 plt.imshow(imagem, cmap='gray')
23 plt.title('Imagem Original')
24 plt.axis('off')
25
26 plt.subplot(2, 2, 2)
27 plt.imshow(laplaciano_absoluto, cmap='gray')
28 plt.title('Operador Laplaciano')
29 plt.axis('off')
30
31 plt.subplot(2, 2, 3)
32 plt.imshow(imagem_segmentada, cmap='gray')
33 plt.title('Imagem Segmentada')
34 plt.axis('off')
35
36 plt.show()
```

Figura 43 – Exemplo de segmentação de imagens utilizando o operador Laplaciano




Figura 44 – Saída. Em A, temos a imagem original. Em B, o operador Laplaciano. Em C, vemos a imagem segmentada

Nas figuras 43 e 44, carregamos uma imagem em tons de cinza. Aplicamos o operador Laplaciano para calcular a segunda derivada da intensidade da imagem, que realça as mudanças abruptas de intensidade. Para garantir que a imagem resultante seja não negativa, calculamos o valor absoluto do resultado do operador Laplaciano. Em seguida, aplicamos um limiar para segmentar as áreas da imagem em que as bordas foram detectadas. Pixels com intensidade maior que o limiar são definidos como objetos, enquanto pixels com intensidade menor que o limiar são definidos como fundo.

A imagem resultante ("imagem_segmentada") destaca as áreas em que ocorrem mudanças abruptas de intensidade, que geralmente correspondem a bordas e detalhes na figura. É possível ajustar o valor do limiar de acordo com a imagem e os requisitos de segmentação. Esse é um exemplo simples de como realizar a segmentação de imagens usando o operador Laplaciano em Python.

Reconhecimento de padrões

O reconhecimento de padrões consiste em identificar características visuais recorrentes e classificá-las de acordo com modelos ou categorias previamente aprendidas. Ele é essencial para que os sistemas de visão computacional reconheçam objetos, rostos, textos, gestos e estruturas visuais específicas.

Vejamos, então, as etapas típicas do reconhecimento de padrões.

O reconhecimento de padrões em visão computacional envolve uma sequência estruturada de etapas que permite a identificação automática de objetos, formas ou comportamentos em imagens ou vídeos. O processo começa com a aquisição da imagem, por meio de sensores, câmeras ou dispositivos

móveis, que capturam a cena a ser analisada. Em seguida, ocorre o pré-processamento, que pode incluir operações como remoção de ruído, normalização de iluminação e realce de contraste, com o objetivo de preparar a imagem para a análise computacional.

Na fase seguinte, são aplicadas técnicas de extração de características, que transformam a imagem em representações numéricas compactas e descritivas, capturando elementos como formas, texturas, cores ou padrões estruturais. Essas características são então comparadas com padrões previamente aprendidos durante a etapa de treinamento do modelo, utilizando algoritmos de classificação supervisionada ou não supervisionada. Por fim, o sistema gera um resultado de identificação, indicando a classe, a categoria ou o rótulo mais provável associado à imagem analisada.

Esse processo é fundamental em aplicações como reconhecimento facial, leitura de placas veiculares, análise de escrita manuscrita, detecção de defeitos industriais e em qualquer cenário em que seja necessário automatizar a interpretação de padrões visuais com alta precisão.

Além das etapas típicas, o reconhecimento de padrões é classificado em duas categorias principais, de acordo com a natureza dos dados analisados: reconhecimento estático e reconhecimento dinâmico.

O reconhecimento estático refere-se à análise de padrões presentes em imagens fixas ou dados estacionários, ou seja, informações que não variam no tempo. Esse tipo de abordagem é utilizado em tarefas como o reconhecimento de caracteres ou dígitos manuscritos, identificação de objetos em fotos, classificação de imagens médicas e reconhecimento facial em imagens estáticas. O foco está na análise da estrutura visual, sem considerar qualquer aspecto temporal ou de movimento.

Por outro lado, o reconhecimento dinâmico lida com sequências de dados que variam ao longo do tempo, exigindo que o sistema compreenda padrões em movimento ou mudanças sucessivas. Um exemplo típico é o reconhecimento de gestos em vídeos, em que o sistema precisa interpretar a progressão dos movimentos de mãos, corpo ou rosto para identificar ações específicas. Esse tipo de reconhecimento também é comum em aplicações como leitura labial, análise de comportamento, monitoramento de atividades e interpretação de sinais de trânsito em tempo real.

Ambas as abordagens são fundamentais em visão computacional e, muitas vezes, podem ser combinadas em sistemas híbridos que analisam tanto o conteúdo visual estático quanto suas variações temporais.

Diversas técnicas são utilizadas em sistemas de reconhecimento de padrões visuais, variando em complexidade e aplicação conforme o tipo de dado e o nível de precisão exigido. Uma das abordagens mais simples e intuitivas é o k-NN, que classifica uma nova amostra com base nos exemplos mais próximos no espaço de características. Essa técnica é bastante eficaz em tarefas como reconhecimento de dígitos e letras manuscritas, especialmente em conjuntos de dados bem definidos e com baixa dimensionalidade.

Outra técnica bastante comum é a SVM, que é particularmente eficiente em problemas de classificação com dados de alta dimensionalidade. As SVMs são amplamente utilizadas em aplicações visuais em que

há necessidade de separação clara entre classes, como na classificação de texturas, no reconhecimento facial ou na identificação de padrões biométricos.

As CNNs representam o estado da arte em reconhecimento de padrões complexos. Elas são capazes de aprender automaticamente características hierárquicas de imagens, permitindo o reconhecimento avançado de objetos, rostos e cenas com alto nível de acurácia. As CNNs são utilizadas em sistemas comerciais, como filtros de imagens, veículos autônomos e segurança por vídeo.

Além dessas técnicas baseadas em aprendizado de máquina, existe também o template matching, que consiste em comparar diretamente uma imagem de entrada com um modelo de referência (template). Essa abordagem é útil em aplicações de detecção por similaridade, como localizar logotipos, símbolos ou formatos fixos dentro de uma imagem, sendo bastante usada em sistemas industriais e interfaces visuais simples.

Cada técnica possui vantagens e limitações, e a escolha da mais adequada depende do contexto da aplicação, da quantidade de dados disponíveis e da complexidade dos padrões a serem reconhecidos.

A seguir, um exemplo de código Python que usa a biblioteca scikit-learn para implementar um classificador k-NN para reconhecimento de dígitos escritos à mão, usando o conjunto de dados MNIST:

```
1  import numpy as np
2  from sklearn.datasets import fetch_openml
3  from sklearn.model_selection import train_test_split
4  from sklearn.neighbors import KNeighborsClassifier
5  from sklearn.metrics import accuracy_score
6
7  # Carregando o conjunto de dados MNIST
8  mnist = fetch_openml('mnist_784', version=1)
9  X = mnist.data.astype('float32')
10 y = mnist.target.astype('int')
11
12 # Dividindo os dados em conjuntos de treinamento e teste
13 X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)
14
15 # Criando e treinando o classificador k-NN
16 knn = KNeighborsClassifier(n_neighbors=3)
17 knn.fit(X_train, y_train)
18
19 # Classificando as imagens de teste
20 y_pred = knn.predict(X_test)
21
22 # Calculando a precisão do modelo
23 accuracy = accuracy_score(y_test, y_pred)
24 print(f'A precisão do k-NN é: {accuracy * 100:.2f}%')
```

Figura 45 – Saída: a precisão do k-NN é: 97,13%



Saiba mais

Para saber mais sobre k-NN, leia o texto a seguir:

PEDRINI, H.; SCHWARTZ, W. R. Regra dos k-vizinhos mais próximos. In: PEDRINI, H.; SCHWARTZ, W. R. *Análise de imagens digitais: princípios, algoritmos e aplicações*. São Paulo: Cengage Learning, 2007.

No exemplo da figura 45, o k-NN é treinado no conjunto de dados MNIST, que consiste em imagens de dígitos manuscritos de 0 a 9. O código carrega o conjunto de dados, divide-o em conjuntos de treinamento e teste, cria um modelo k-NN com $k = 3$ vizinhos e avalia a precisão do modelo.

Lembre-se de que o valor de k deve ser ajustado com base na natureza dos dados e na tarefa de classificação específica. Um valor adequado de k é crucial para obter um desempenho ideal do k-NN em uma aplicação de processamento de imagem.




Figura 46 – Exemplo de conjunto de dados de números MNIST

Disponível em: <http://bit.ly/4lQQVr2>. Acesso em: 25 jul. 2025.

Integração entre detecção de bordas e reconhecimento de padrões

A detecção de bordas é fundamental como etapa preliminar no processo de reconhecimento de padrões em visão computacional. Ao identificar os contornos dos objetos presentes em uma imagem, o sistema consegue isolar regiões de interesse, facilitando a extração de características relevantes e eliminando informações redundantes. Essa filtragem espacial contribui diretamente para melhorar a precisão da segmentação e reduzir a complexidade computacional nas etapas subsequentes, como classificação, identificação e análise estrutural.

No entanto, essa integração também enfrenta desafios técnicos importantes. Imagens com baixo contraste, ruído ou resolução limitada podem dificultar a identificação precisa das bordas. Além disso, bordas suaves, sobrepostas ou degradadas exigem algoritmos de detecção mais sensíveis e robustos, como o operador de Canny com ajuste fino de parâmetros. O reconhecimento de padrões, por sua vez, pode ser afetado por variações de iluminação, escala, orientação ou deformações geométricas, exigindo modelos treinados com dados diversificados e técnicas de normalização.

A sinergia entre bordas e padrões se revela em diversas aplicações reais. Na OCR, por exemplo, a segmentação por bordas isola os caracteres, que são posteriormente reconhecidos por modelos treinados. Em diagnósticos médicos, a identificação de contornos em exames de imagem permite detectar anomalias ou regiões suspeitas com maior clareza. Sistemas de verificação biométrica, como leitura de íris, utilizam a extração precisa de bordas para delimitar áreas únicas do olho e comparar com padrões armazenados. Já na indústria, a detecção de falhas em peças muitas vezes depende da análise de bordas irregulares ou deformações fora do padrão esperado.



Lembrete

O reconhecimento óptico de caracteres (OCR) é uma tecnologia geral para converter imagens de texto em texto legível por máquina, enquanto o reconhecimento de placas de veículos (LPR) é uma aplicação específica de OCR focada no reconhecimento de placas de veículos.

A detecção de bordas e o reconhecimento de padrões formam a base de muitas tarefas em visão computacional. Enquanto as bordas revelam estrutura e contorno, os padrões permitem que o sistema compreenda e classifique elementos visuais. Quando combinadas, essas técnicas tornam os sistemas inteligentes capazes de "ver e entender" o conteúdo das imagens, abrindo caminho para soluções automatizadas em saúde, segurança, transporte e muito mais.

6.1.2 Redes neurais convolucionais (CNN)

As redes neurais convolucionais, ou convolutional neural networks (CNNs), são um tipo especializado de rede neural projetado para processar dados com estrutura em grade, como imagens. Elas foram desenvolvidas para simular o funcionamento do córtex visual humano e tornaram-se o padrão-ouro para tarefas de visão computacional, como reconhecimento de objetos, classificação de imagens, detecção de rostos e muito mais.

As CNNs se destacam no processamento de imagens por sua capacidade de explorar eficientemente as propriedades espaciais dos dados visuais, como altura, largura e profundidade (canais de cor). Diferentemente das redes neurais tradicionais, que tratam imagens como vetores planos e ignoram sua estrutura bidimensional, as CNNs preservam a topologia espacial entre os pixels, permitindo que o modelo compreenda relações locais e padrões visuais com mais fidelidade.

Uma das principais vantagens das CNNs é a habilidade de detectar automaticamente padrões visuais locais, como bordas, texturas, formas e regiões de contraste, por meio de filtros convolucionais aplicados nas camadas iniciais. À medida que a rede se aprofunda, essas detecções se combinam e evoluem, resultando na extração de características cada vez mais complexas e abstratas, como rostos, objetos ou cenas completas.

Além disso, as CNNs são arquiteturas mais eficientes, visto que utilizam conexões locais e compartilhamento de pesos, o que reduz drasticamente o número de parâmetros em comparação com redes densamente conectadas. Essa eficiência computacional não apenas melhora o desempenho em tarefas de reconhecimento de imagem, mas também possibilita o treinamento de modelos robustos com menor custo computacional.

Arquitetura de uma CNN

A arquitetura de uma CNN é composta por camadas organizadas de forma a extrair e processar informações visuais progressivamente, permitindo que o modelo aprenda desde padrões simples até estruturas complexas. As três principais camadas que compõem uma CNN são as camadas convolucionais, as camadas de pooling e as camadas densas.

- **Camadas convolucionais (convolutional layers):** essas são as camadas centrais de uma CNN. Elas aplicam operações de convolução entre a imagem de entrada e pequenos filtros ou kernels, que percorrem a imagem extraíndo padrões locais. Cada filtro é treinado para reconhecer um tipo específico de característica, como bordas horizontais, linhas diagonais ou contornos curvos. Por exemplo, um filtro pode responder fortemente à presença de uma borda vertical em uma determinada região da imagem. Ao empilhar várias camadas convolucionais, a rede consegue capturar representações cada vez mais abstratas e informativas.
- **Camadas de pooling (subamostragem):** têm a função de reduzir a dimensionalidade espacial da imagem (largura e altura), mantendo os elementos mais relevantes. Isso contribui para diminuir o custo computacional, reduzir o risco de overfitting e aumentar a robustez do modelo a variações como mudanças de escala, rotação e pequenos deslocamentos. Os dois tipos mais comuns de pooling são:
 - **Max pooling:** seleciona o valor mais alto de uma região, preservando a característica mais marcante.
 - **Average pooling:** calcula a média dos valores da região, proporcionando um efeito suavizado.
- **Camadas densas (fully connected layers):** na etapa final da CNN, as informações extraídas pelas camadas anteriores são "achataadas" (flatten) e passadas para uma ou mais camadas densamente conectadas, semelhantes às usadas em redes neurais tradicionais. Nessas camadas, cada neurônio se conecta a todos os neurônios da camada anterior, permitindo que o modelo combine as características aprendidas para realizar a classificação ou regressão final. A última camada

geralmente usa uma função de ativação como softmax (em tarefas de classificação) para indicar a probabilidade de cada classe.

Treinamento e ajuste de CNNs

Para que uma CNN desempenhe suas funções com precisão, é essencial que ela seja treinada com um conjunto de imagens rotuladas, ou seja, imagens acompanhadas das respectivas classes corretas. Durante o processo de treinamento, os filtros convolucionais aprendem automaticamente quais padrões visuais são mais úteis para a tarefa específica – como contornos, texturas ou formas complexas. O modelo ajusta seus pesos e vieses por meio do algoritmo de retropropagação do erro, combinado ao gradiente descendente, minimizando a função de perda, que quantifica o quão distante a previsão atual está do valor real. Esse processo iterativo permite que a rede evolua gradualmente, melhorando sua capacidade de generalização.

As CNNs se destacam por diversos motivos no contexto da visão computacional. Elas apresentam alto desempenho em tarefas visuais, como classificação de imagens, detecção de objetos e segmentação semântica. Uma de suas maiores vantagens é o aprendizado hierárquico de características, em que camadas mais profundas aprendem representações cada vez mais abstratas a partir de informações simples. Além disso, possuem menos parâmetros do que redes totalmente conectadas, graças ao uso de filtros compartilhados e conexões locais, o que as torna mais eficientes. Outro ponto forte é sua capacidade de generalização, permitindo que o modelo reconheça padrões mesmo diante de variações na iluminação, escala, rotação ou perspectiva.

Apesar de suas vantagens, as CNNs também apresentam limitações e desafios importantes. Um dos principais obstáculos é a necessidade de grandes volumes de dados rotulados para treinar modelos eficazes, o que pode ser um entrave em domínios nos quais a anotação de dados é dispendiosa ou complexa. Além disso, o custo computacional é elevado, especialmente em arquiteturas profundas com muitas camadas, exigindo hardware especializado como GPUs. Outro desafio crítico é a sensibilidade a ruído adversarial – pequenas perturbações imperceptíveis a olho nu podem induzir o modelo ao erro. Por fim, as CNNs, como outras redes profundas, sofrem com baixa interpretabilidade, sendo frequentemente consideradas “caixas-pretas”, o que dificulta a compreensão de como e por que certas decisões são tomadas.

As CNNs são a base da visão computacional moderna. Elas tornaram possível que sistemas de IA reconheçam objetos, interpretem cenas e tomem decisões baseadas em dados visuais com nível de precisão comparável ao humano. Seu domínio é essencial para profissionais que desejam atuar com aplicações inteligentes baseadas em imagens, desde a análise médica até veículos autônomos.

6.2 Aplicações de visão computacional

A visão computacional deixou de ser uma área teórica da IA para se tornar uma tecnologia presente no cotidiano, com aplicações em saúde, segurança, indústria, agricultura, transporte, varejo e muito mais. Ao permitir que sistemas digitais interpretem imagens e vídeos como um ser humano faria, a visão

computacional amplia a capacidade das máquinas de atuar no mundo real com eficiência, autonomia e inteligência.

Aplicações na saúde

A visão computacional tem desempenhado um papel cada vez mais transformador na medicina moderna, contribuindo significativamente para diagnósticos mais rápidos, precisos e acessíveis. Ao integrar algoritmos avançados de processamento de imagem com técnicas de IA, essa tecnologia tem permitido auxílio clínico automatizado em diferentes etapas do cuidado à saúde.

Dentre suas aplicações mais relevantes, destaca-se o diagnóstico por imagem, envolvendo raios X, tomografias e ressonâncias magnéticas, em que sistemas inteligentes são capazes de identificar automaticamente tumores, fraturas, lesões ou anomalias que poderiam passar despercebidas a olho nu. Na oftalmologia, algoritmos de visão computacional analisam imagens da retina para a detecção precoce de doenças como diabetes e glaucoma, promovendo intervenções mais eficazes. Além disso, a contagem celular automatizada e o reconhecimento de padrões patológicos em lâminas de biópsias ou exames hematológicos agilizam o trabalho dos laboratórios e aumentam a padronização dos resultados.

O impacto é significativo: redução de erros médicos, maior agilidade nos diagnósticos, padronização de laudos e, sobretudo, suporte clínico em regiões com escassez de especialistas, ampliando o acesso a exames de qualidade. A visão computacional, nesse contexto, não substitui os profissionais da saúde, mas atua como uma ferramenta de apoio altamente eficaz, promovendo uma medicina mais precisa, preventiva e acessível.

Aplicações na indústria e manufatura

Em ambientes industriais, a visão computacional tem se consolidado como uma tecnologia essencial para a automação de processos, contribuindo diretamente para o aumento da produtividade, redução de custos operacionais e minimização de falhas humanas. Ao permitir que sistemas computacionais "enxerguem" e tomem decisões com base em dados visuais em tempo real, a indústria alcança novos patamares de eficiência e precisão.

Dentre suas principais aplicações, destaca-se a inspeção automatizada de qualidade em linhas de montagem, na qual câmeras e algoritmos verificam dimensões, cores, texturas ou falhas estruturais em produtos acabados, substituindo inspeções manuais demoradas e sujeitas a erro. A detecção precoce de defeitos em peças permite intervenções imediatas no processo produtivo, evitando desperdícios e retrabalhos. Além disso, a leitura automática de códigos de barras e QR codes agiliza o rastreamento logístico e o controle de estoque, enquanto sistemas de classificação inteligente de objetos em esteiras otimizam o fluxo e a separação de materiais por tipo, cor ou tamanho.

O impacto direto dessas aplicações inclui redução significativa de desperdícios, padronização da qualidade dos produtos, aumento da velocidade na linha de produção e maior competitividade no setor industrial. A visão computacional, nesse cenário, transforma o controle de qualidade de uma tarefa subjetiva em um processo objetivo, rápido e confiável, alinhado aos princípios da Indústria 4.0.

Aplicações na segurança e vigilância

A visão computacional tem sido amplamente aplicada em sistemas de monitoramento inteligente, oferecendo avanços significativos na segurança pública e privada, bem como na gestão eficiente de espaços urbanos e corporativos. Ao permitir a análise automatizada de imagens em tempo real, essa tecnologia proporciona maior precisão na detecção de eventos relevantes e contribui para tomadas de decisão mais rápidas e eficazes.

Dentre as principais aplicações, destaca-se o reconhecimento facial integrado a câmeras de vigilância, utilizado para identificar indivíduos em áreas restritas ou com mandado judicial. Sistemas de detecção de comportamentos suspeitos analisam padrões de movimento ou aglomeração, emitindo alertas automáticos para prevenir incidentes. A contagem e o rastreamento de pessoas em tempo real são amplamente empregados no controle de fluxo em espaços públicos, estações, shoppings e eventos. Já a leitura automática de placas veiculares (LPR, do inglês license plate recognition) permite o monitoramento de entradas e saídas em estacionamentos, condomínios, rodovias e barreiras policiais, integrando-se a bancos de dados de segurança.

O impacto dessa tecnologia é amplo: automação de processos de controle de acesso, aumento da eficácia do policiamento e da vigilância, além da implementação de sistemas de alerta em tempo real, que ampliam a capacidade preventiva e reativa das equipes de segurança. Ao aliar visão computacional e inteligência artificial, o monitoramento torna-se mais proativo, preciso e eficiente.

Aplicações em transporte e mobilidade

A visão computacional desempenha um papel central no desenvolvimento de veículos autônomos e na implementação de sistemas inteligentes de transporte, sendo fundamental para a percepção visual em tempo real e para a tomada de decisões automatizadas. Essa tecnologia permite que veículos e sistemas urbanos compreendam o ambiente ao redor com alta precisão, promovendo segurança, eficiência e mobilidade sustentável.

Dentre suas principais aplicações, destacam-se a detecção de faixas de pedestres, semáforos, placas de trânsito e obstáculos, garantindo que o veículo reaja de forma adequada a diferentes situações de tráfego. O controle automatizado de velocidade e frenagem é possível graças à análise contínua do ambiente, contribuindo para uma direção mais segura. Além disso, o reconhecimento automático de sinais e placas de trânsito permite que veículos obedeçam às normas viárias sem intervenção humana. Nos centros urbanos, a visão computacional também é utilizada no monitoramento de tráfego por meio de câmeras e drones, fornecendo dados em tempo real para otimização de rotas e resposta a incidentes.

O impacto dessa tecnologia é significativo: aumento da segurança nas vias, redução de acidentes causados por erro humano e melhoria da fluidez do trânsito, apoiando a construção de uma mobilidade urbana mais inteligente, conectada e sustentável.

Aplicações na agricultura (Agro 4.0)

Na agricultura moderna, a visão computacional tem se consolidado como uma ferramenta essencial para o monitoramento preciso das plantações e para o gerenciamento inteligente de recursos agrícolas. Integrada a sistemas automatizados e ao uso de drones e sensores, essa tecnologia permite uma análise visual detalhada do ambiente rural, contribuindo para práticas mais eficientes, sustentáveis e produtivas.

Dentre suas aplicações mais relevantes, destaca-se a identificação precoce de pragas e doenças em plantas, possibilitando ações corretivas mais ágeis e eficazes. A contagem e a medição automatizada de frutas, legumes ou vegetais por imagem auxiliam no controle da produção e na previsão de safras. Drones equipados com câmeras de alta resolução são amplamente utilizados para o monitoramento do crescimento das culturas, detectando falhas no plantio, áreas com deficiência hídrica ou problemas de desenvolvimento. Além disso, sistemas baseados em visão computacional permitem a classificação automatizada de sementes e grãos, assegurando maior uniformidade e qualidade no processo de seleção.

O impacto dessa tecnologia no campo é significativo: aumento da produtividade, redução de perdas, uso mais racional de insumos como água e defensivos agrícolas, além de decisões mais embasadas e precisas, que contribuem para a consolidação da agricultura de precisão e o avanço da transformação digital no agronegócio.

Aplicações no varejo e comércio eletrônico

A experiência do consumidor tem sido significativamente aprimorada com a aplicação de recursos visuais inteligentes baseados em visão computacional. Essa tecnologia permite que empresas do setor varejista e de e-commerce ofereçam interações mais personalizadas, eficientes e envolventes, elevando o nível de satisfação do cliente e otimizando os resultados comerciais.

Dentre as principais aplicações, destaca-se o reconhecimento automático de produtos por imagem em aplicativos de compras, que permite ao usuário buscar itens com base em fotos tiradas diretamente pelo celular. Nas lojas físicas, a análise do comportamento do cliente por meio de mapas de calor possibilita a identificação das áreas mais visitadas, auxiliando na disposição estratégica de produtos e campanhas. Espelhos inteligentes com realidade aumentada oferecem experiências imersivas, permitindo que os consumidores visualizem roupas ou acessórios em tempo real, sem a necessidade de provadores. Além disso, sistemas de recomendação visual utilizam comparação de imagens para sugerir produtos semelhantes, alinhando as preferências estéticas do cliente ao catálogo disponível.

O impacto dessas soluções é expressivo: maior personalização no atendimento, otimização da jornada de compra e aumento nas taxas de conversão, promovendo uma experiência de consumo mais fluida, interativa e eficiente.

Aplicações em educação e acessibilidade

A visão computacional também desempenha um papel fundamental na promoção da inclusão social e na ampliação do acesso ao conhecimento, contribuindo para uma sociedade mais equitativa e tecnologicamente assistida. Ao integrar recursos visuais inteligentes em contextos educacionais e de acessibilidade, essa tecnologia tem possibilitado o desenvolvimento de soluções inovadoras que atendem às necessidades de diversos públicos.

Dentre as aplicações de maior impacto, destacam-se os leitores de tela para pessoas com deficiência visual, que combinam OCR com síntese de voz para transformar textos impressos ou digitais em áudio, facilitando o acesso à informação. O reconhecimento automatizado da linguagem de sinais permite a tradução em tempo real para o formato textual ou falado, promovendo a inclusão de pessoas surdas em ambientes educacionais e profissionais. Outro exemplo relevante é a correção automática de provas manuscritas, que utiliza algoritmos de reconhecimento de escrita para agilizar a avaliação de atividades, reduzindo o esforço docente. Além disso, ferramentas que analisam níveis de atenção e engajamento de estudantes em aulas on-line, por meio de expressões faciais e postura, oferecem insights importantes para a melhoria do processo de ensino-aprendizagem.

O impacto dessas inovações se reflete em uma educação mais acessível e inclusiva, no suporte efetivo a pessoas com deficiência e na automação de tarefas rotineiras no contexto educacional, promovendo ambientes de aprendizagem mais eficientes, interativos e humanos.

Aplicações em entretenimento e mídia

A criatividade e a interatividade têm sido profundamente ampliadas com o uso de recursos visuais inteligentes, impulsionando novas formas de expressão, entretenimento e produção de conteúdo. Por meio da visão computacional, tecnologias capazes de interpretar e manipular imagens e vídeos em tempo real vêm transformando a maneira como usuários interagem com plataformas digitais, jogos e mídias audiovisuais.

Dentre as aplicações mais populares, destacam-se os filtros de realidade aumentada em redes sociais como Snapchat e Instagram, que sobrepõem elementos gráficos ao rosto do usuário com precisão, criando efeitos visuais envolventes e personalizados. Na área esportiva, algoritmos de análise automática de vídeos e reconhecimento de jogadas são utilizados para destacar momentos-chave e gerar estatísticas em tempo real. Em jogos digitais, o reconhecimento facial permite personalizar personagens com base nas feições do jogador, promovendo experiências mais imersivas e únicas. Além disso, a edição automática de vídeos com base na detecção de cenas ou eventos visuais tem revolucionado o trabalho de criadores de conteúdo, reduzindo o tempo de produção e aumentando a eficiência criativa.

O impacto dessas tecnologias é amplo, visto que promovem experiências digitais mais imersivas e personalizadas, estimulam a participação ativa do usuário e possibilitam a automação inteligente de processos criativos, abrindo caminho para inovações em diversas indústrias, como mídia, entretenimento, publicidade e comunicação digital.

As aplicações da visão computacional estão presentes em quase todos os setores da sociedade moderna, impactando positivamente a saúde, a segurança, a agricultura, o varejo, o transporte e a educação. Ao permitir que máquinas compreendam imagens e vídeos de maneira semelhante à visão humana, essa tecnologia promove inovação, automação e inteligência aplicada. Para profissionais de tecnologia, dominar as ferramentas e os algoritmos dessa área é abrir as portas para soluções visuais avançadas, cada vez mais presentes na vida cotidiana.

6.2.1 Reconhecimento facial e segmentação de imagens

O reconhecimento facial e a segmentação de imagens são dois dos processos mais avançados utilizados em visão computacional. Eles representam diferentes formas de interpretar imagens: enquanto o reconhecimento facial busca identificar indivíduos com base em suas características faciais, a segmentação visa dividir uma imagem em regiões significativas, como objetos, pessoas ou áreas específicas.

Essas técnicas são essenciais em áreas como segurança pública, biometria, análise médica, mobilidade urbana, agricultura de precisão e realidade aumentada.

Reconhecimento facial

É uma técnica de identificação biométrica que utiliza a análise das características únicas do rosto de uma pessoa para reconhecer ou verificar sua identidade a partir de imagens ou vídeos. Trata-se de uma aplicação avançada da visão computacional e da inteligência artificial, que tem sido amplamente adotada em setores como segurança, mobilidade digital, varejo e serviços financeiros.

O processo de reconhecimento facial envolve etapas sequenciais e estruturadas. Primeiramente, ocorre a detecção do rosto, quando o sistema localiza a face em uma imagem ou em um frame de vídeo. Em seguida, realiza-se o alinhamento, ajustando a posição, o tamanho e a orientação do rosto para garantir consistência na análise. A etapa seguinte é a extração de características, na qual o rosto é transformado em um vetor numérico, chamado de embedding facial, que representa suas particularidades. Por fim, a comparação desses vetores com os armazenados em uma base de dados permite identificar ou autenticar o indivíduo com base na similaridade vetorial.

Diversos modelos e tecnologias são empregados para essas tarefas. Dentre os métodos clássicos, destaca-se o Haar Cascade, da biblioteca OpenCV, eficaz para a detecção básica de rostos. Técnicas como HOG combinadas a SVMs também são utilizadas em implementações menos complexas. Para aplicações mais robustas e precisas, redes neurais profundas como FaceNet, DeepFace, Dlib e bibliotecas como face_recognition oferecem detecção e reconhecimento com embeddings altamente representativos, sendo capazes de operar inclusive em tempo real.

As aplicações práticas do reconhecimento facial são vastas. Na segurança pública, é usado para a identificação de suspeitos em imagens de câmeras. Em smartphones, viabiliza o desbloqueio facial e a autenticação segura de usuários. No varejo, pode auxiliar na contagem de clientes e no reconhecimento de consumidores VIP. Em eventos, serve para controle de acesso e experiências personalizadas. Já no setor

financeiro, permite autenticação biométrica em aplicativos bancários, substituindo senhas tradicionais por validação facial.

Apesar de seu potencial, o reconhecimento facial enfrenta desafios técnicos e éticos. Questões como privacidade, consentimento no uso de imagens e a presença de viés algorítmico – com desempenho desigual entre diferentes etnias ou gêneros – são preocupações recorrentes. Além disso, fatores como iluminação inadequada, mudanças de pose, envelhecimento facial e oclusões (ex.: óculos, máscaras etc.) podem afetar significativamente a precisão do sistema, exigindo abordagens mais robustas e justas.

Segmentação de imagens

A segmentação de imagens é uma técnica fundamental da visão computacional, que consiste em dividir uma imagem em regiões distintas e significativas com o objetivo de isolar e analisar objetos ou estruturas específicas presentes na cena. Ao identificar contornos e agrupar pixels semelhantes, a segmentação facilita etapas subsequentes como reconhecimento, classificação e interpretação automática de imagens.

Existem diferentes tipos de segmentação, cada um adequado a uma necessidade específica. A segmentação semântica associa rótulos a cada pixel com base na classe do objeto (por exemplo, céu, estrada e vegetação), sem diferenciar instâncias distintas de um mesmo tipo. Já a segmentação de instância vai além, identificando separadamente cada objeto individual – por exemplo, dois carros distintos serão rotulados de forma independente. A segmentação panóptica combina os dois enfoques, permitindo tanto a identificação da classe quanto da instância de cada objeto na imagem, oferecendo uma visão abrangente da cena.

Diversas técnicas são empregadas para alcançar a segmentação com eficiência. Métodos clássicos como o thresholding utilizam o nível de intensidade de cor para separar regiões, enquanto o algoritmo watershed explora propriedades topológicas de cor e gradiente. Técnicas baseadas em clustering, como o k-means, agrupam pixels com características semelhantes. Com o avanço do aprendizado profundo, as CNNs se tornaram o padrão para segmentação de alto desempenho. Modelos como U-Net são amplamente utilizados na segmentação médica por sua capacidade de preservar detalhes finos, enquanto Mask R-CNN realiza segmentação de instâncias com alta precisão em tempo real. Já o DeepLab é conhecido por sua eficácia na segmentação semântica, utilizando dilated convolutions e camadas profundas para capturar contextos mais amplos.

As aplicações práticas da segmentação de imagens abrangem diversas áreas. Na medicina, é utilizada para delimitar tumores, órgãos e tecidos em exames de imagem, contribuindo para diagnósticos mais precisos. Na agricultura, permite identificar áreas afetadas por pragas ou doenças. No setor de transporte, auxilia na detecção de faixas de rodagem e obstáculos. No varejo, é empregada para identificar produtos em prateleiras ou monitorar disposição de mercadorias. Já em realidade aumentada, contribui para o ajuste preciso de filtros e sobreposições visuais, como efeitos aplicados ao rosto em tempo real.

A segmentação de imagens é, portanto, uma etapa essencial para a compreensão visual automatizada, viabilizando soluções robustas e inteligentes em diferentes contextos tecnológicos.

Tanto o reconhecimento facial quanto a segmentação de imagens são pilares da visão computacional moderna. O primeiro fornece identificação e verificação biométrica com precisão, enquanto a segunda possibilita análises visuais detalhadas e estruturadas em diversas áreas. Com o avanço das redes neurais profundas, essas técnicas se tornaram mais robustas, rápidas e aplicáveis em tempo real, ampliando as possibilidades da IA em aplicações práticas e inovadoras.

6.2.2 Uso de IA em sistemas de vigilância e segurança

A aplicação de IA em sistemas de vigilância e segurança tem revolucionado o modo como ambientes são monitorados, tornando a atuação mais eficiente, proativa e autônoma. Integrando visão computacional, redes neurais, aprendizado de máquina e análise preditiva, esses sistemas oferecem monitoramento inteligente em tempo real, com capacidade de detectar comportamentos suspeitos, reconhecer rostos e prever riscos antes mesmo que eles ocorram.

Como a IA é integrada à vigilância?

A integração da IA aos sistemas de vigilância tem transformado profundamente o modo como ambientes públicos e privados são monitorados. Enquanto os sistemas tradicionais atuam de forma passiva – exigindo que operadores humanos acompanhem continuamente as imagens para identificar incidentes –, os sistemas baseados em IA operam de maneira ativa e autônoma, oferecendo análise contínua, detecção inteligente e respostas em tempo real.

Com o apoio de algoritmos avançados, os sistemas de segurança modernos são capazes de realizar análise automática de vídeos, reconhecer padrões e anomalias comportamentais e gerar alertas instantâneos diante de situações suspeitas. Além disso, a IA permite o registro inteligente de eventos relevantes, reduzindo a sobrecarga de dados irrelevantes e priorizando informações críticas para a tomada de decisão.

Um sistema de segurança inteligente é composto por diversos componentes integrados. As câmeras e os sensores são responsáveis pela captura contínua de vídeo, áudio e movimento. As imagens capturadas são processadas por algoritmos de visão computacional, geralmente baseados em CNNs, que realizam a interpretação visual da cena em tempo real. Em paralelo, modelos de reconhecimento identificam rostos, placas de veículos, objetos específicos e até gestos corporais. A análise comportamental, por sua vez, detecta desvios em padrões de movimento, como aglomerações incomuns, perseguições ou invasões de áreas restritas. Com base nesses dados, o sistema de resposta automática pode emitir alertas instantâneos, acionar dispositivos de segurança, como sirenes ou travas, ou registrar os eventos em um histórico de incidentes priorizados.

A combinação desses elementos cria um ecossistema de vigilância inteligente, capaz de aumentar a eficiência operacional, reduzir o tempo de resposta a eventos críticos e melhorar a segurança em larga escala, com aplicações que vão desde o monitoramento urbano até a proteção de instalações industriais, centros comerciais e residências inteligentes.

Aplicações práticas da IA em vigilância

A seguir, apresentaremos algumas aplicações práticas da IA em vigilância

- **Reconhecimento facial:** a tecnologia de reconhecimento facial permite a identificação e o rastreamento de indivíduos em tempo real, oferecendo uma camada adicional de segurança em locais como aeroportos, edifícios corporativos, eventos públicos e áreas restritas. O sistema verifica a identidade dos indivíduos ao compará-los com bases de dados previamente cadastradas, como registros administrativos, cadastros institucionais ou até listas de procurados em sistemas policiais. Sua integração com sensores e câmeras inteligentes possibilita respostas rápidas e automatizadas, como liberação de acessos ou emissão de alertas.
- **Deteção de comportamentos suspeitos:** a análise de vídeo assistida por IA também é capaz de identificar comportamentos anômalos, como corridas abruptas, quedas, invasões de áreas restritas ou posturas corporais agressivas. Esses sistemas são treinados com algoritmos de machine learning, que aprendem os padrões normais de movimento e postura e sinalizam desvios que indicam possíveis situações de risco. Isso permite uma atuação proativa das equipes de segurança, mesmo antes da ocorrência de incidentes.
- **Leitura de placas veiculares (LPR):** o reconhecimento automático de placas de veículos é amplamente utilizado em controle de acesso a estacionamentos, portarias, pedágios e zonas urbanas monitoradas. Essa tecnologia permite a identificação precisa de veículos, facilitando ações como liberação automática de cancelas, registro de entradas e saídas, rastreamento de veículos roubados ou monitoramento de tráfego em tempo real.
- **Rastreamento de objetos e pessoas:** sistemas inteligentes possibilitam o acompanhamento contínuo de indivíduos e objetos em movimento, mesmo entre diferentes câmeras e ambientes. Essa funcionalidade é útil para prever rotas, identificar comportamentos suspeitos com base no histórico e fornecer uma visão abrangente de áreas monitoradas. O rastreamento multicâmera aumenta a cobertura e permite reconstruções precisas de trajetos.
- **Deteção de objetos específicos:** a identificação automática dos itens potencialmente perigosos ou proibidos, como armas, mochilas abandonadas, pacotes suspeitos ou ferramentas não autorizadas, é essencial em ambientes sensíveis como aeroportos, instituições de ensino, eventos e empresas. Os sistemas podem ser integrados a protocolos de segurança automatizados, acionando alarmes, bloqueando acessos ou notificando agentes de vigilância em tempo real.

A integração da IA à segurança amplia significativamente a eficiência e a eficácia dos sistemas de monitoramento e resposta. Dentre os principais benefícios, destacam-se:

- **Monitoramento contínuo e preciso:** a automação com IA garante vigilância ininterrupta e com menor margem de erro, superando as limitações humanas em longos turnos ou cenários complexos.

- **Resposta rápida a incidentes:** sistemas inteligentes podem gerar alertas automáticos e acionar protocolos de segurança em tempo real, permitindo uma atuação mais ágil e eficaz diante de ameaças.
- **Redução de custos operacionais:** a automação de tarefas rotineiras e a diminuição da necessidade de supervisão constante reduzem significativamente os custos com pessoal e infraestrutura.
- **Análise preditiva:** a IA permite antecipar comportamentos suspeitos ou padrões de risco, possibilitando a prevenção proativa de crimes e incidentes.
- **Armazenamento inteligente:** os sistemas modernos conseguem registrar apenas eventos relevantes, otimizando o uso de espaço em servidores e facilitando a recuperação de informações importantes.

Apesar dos benefícios, o uso de IA na área de segurança exige atenção a questões técnicas, éticas e legais fundamentais, como:

- **Privacidade dos cidadãos:** o reconhecimento facial e o monitoramento em espaços públicos devem seguir as legislações de proteção de dados, como a Lei Geral de Proteção de Dados (LGPD) no Brasil, garantindo consentimento e transparência no uso das informações.
- **Viés algorítmico:** modelos de IA podem reproduzir preconceitos presentes nos dados de treinamento, levando a disparidades de desempenho entre diferentes grupos sociais, étnicos ou de gênero.
- **Responsabilidade e transparência:** as decisões automatizadas devem ser auditáveis e justificáveis, especialmente em casos que envolvem sanções ou restrições de acesso, promovendo a explicabilidade dos algoritmos.
- **Segurança da informação:** é essencial proteger os dados sensíveis capturados e armazenados, prevenindo vazamentos, acessos não autorizados ou usos indevidos.

O uso da IA em sistemas de vigilância e segurança representa um avanço significativo no monitoramento de espaços públicos e privados. Com capacidade de analisar, interpretar e agir com base em dados visuais e comportamentais, esses sistemas oferecem mais agilidade, precisão e prevenção. No entanto, é fundamental que seu uso seja acompanhado de responsabilidade ética e respeito à privacidade, para garantir a segurança sem comprometer os direitos individuais.



Resumo

Nesta unidade, exploramos as principais técnicas e modelos aplicados ao entendimento computacional da linguagem humana. Inicialmente, foram abordados os fundamentos do pré-processamento textual, incluindo tokenização, stemming e lematização, que preparam os dados textuais para análises mais avançadas. Em seguida, discutimos a classificação de textos e a análise de sentimentos, fundamentais em tarefas como filtragem de spam, triagem de mensagens e avaliação de opiniões.

No tocante aos modelos de linguagem, a unidade apresentou desde abordagens baseadas em n-gramas até redes neurais profundas, como RNNs, LSTMs e GRUs. Um destaque especial foi dado aos modelos transformer, notadamente o BERT, que revolucionaram o campo ao permitir interpretações contextuais mais precisas. Também foram discutidos seus mecanismos internos, como self-attention, e suas aplicações práticas em tarefas, como resposta a perguntas, análise semântica e extração de entidades nomeadas.

A unidade introduziu os conceitos centrais da visão computacional, capacitando os sistemas computacionais a interpretar informações visuais com precisão. Iniciamos com a detecção de bordas e o reconhecimento de padrões, utilizando técnicas como Sobel, Canny e template matching. A seguir, apresentamos a arquitetura e o funcionamento das CNNs, fundamentais para o reconhecimento visual automatizado.

A segunda parte da unidade se concentrou nas aplicações práticas da visão computacional, abordando o reconhecimento facial e a segmentação de imagens, essenciais em áreas como medicina, indústria e mobilidade urbana. Também foi discutido o uso da IA em sistemas inteligentes de vigilância e segurança, com destaque para reconhecimento de placas, análise de comportamento suspeito, rastreamento em tempo real e emissão de alertas automáticos, demonstrando o impacto dessa tecnologia na prevenção de incidentes e na eficiência operacional.



Exercícios

Questão 1. (FGV 2024, adaptada) O PLN é uma subárea da inteligência artificial focada em permitir que máquinas compreendam, interpretem, gerem e respondam à linguagem humana de maneira natural e significativa. O objetivo do PLN é fazer com que sistemas computacionais realizem tarefas que envolvem a linguagem humana, como leitura, escrita e interpretação de forma semelhante à forma como os humanos processam o idioma.

Em PLN, a tokenização:

- A) É a técnica que remove todas as palavras de um texto que não são substantivos, para focar apenas em entidades.
- B) Consiste em dividir o texto em unidades menores, como palavras ou subpalavras, para facilitar o processamento do texto por modelos de PLN.
- C) É o processo de sintetizar novas palavras com base em um modelo probabilístico, permitindo a expansão do vocabulário.
- D) É a técnica que converte palavras em números aleatórios para evitar vieses durante a análise textual.
- E) É o processo de combinar palavras em frases inteiras para entender o contexto completo de um texto.

Resposta correta: alternativa B.

Análise da questão

A tokenização é uma das tarefas realizadas no campo do PLN. Ela consiste na divisão de um texto em unidades menores, e cada uma dessas unidades é chamada de token. Um token pode ser uma palavra, uma frase ou uma sílaba, a depender da situação.

Questão 2. (UFSM 2022, adaptada) Uma CNN representa um tipo de arquitetura de uma rede neural profunda que é particularmente adequada para conjuntos de dados de imagem. Em adição, devido ao seu bom desempenho quando comparadas às abordagens tradicionais, as CNNs estão sendo utilizadas no desenvolvimento de várias aplicações que envolvem visão computacional.

Considerando as redes neurais convolucionais e suas aplicações, avalie as afirmativas a seguir e a relação proposta entre elas.

I – As camadas de pooling são o elemento central das CNNs e são responsáveis por extrair características das imagens.

porque

II – Uma das principais vantagens das CNNs é a sua capacidade de aprender características hierárquicas automaticamente.

Assinale a alternativa correta.

A) Ambas as afirmativas são verdadeiras, e a segunda justifica a primeira.

B) Ambas as afirmativas são verdadeiras, mas a segunda não justifica a primeira.

C) A primeira afirmativa é verdadeira, e a segunda é falsa.

D) A primeira afirmativa é falsa, e a segunda é verdadeira.

E) Ambas as afirmativas são falsas.

Resposta correta: alternativa D.

Análise da questão

I – Afirmativa falsa.

Justificativa: o elemento central das CNNs, responsável por extrair características das imagens, corresponde às camadas de convolução. As camadas de pooling reduzem a dimensionalidade da imagem, preservando as características mais importantes.

II – Afirmativa verdadeira.

Justificativa: à medida que os dados de entrada passam pelas camadas, a rede neural aprende representações progressivamente mais abstratas das características das imagens. Ou seja, as camadas iniciais capturam detalhes de baixo nível, enquanto as camadas posteriores combinam essas características para formar representações mais abstratas.