



UNIDADE III

Inteligência Artificial

Profa. Dra. Vanessa Lessa

O que é Processamento de Linguagem Natural?

- O Processamento de Linguagem Natural está revolucionando a forma como as máquinas compreendem e interagem com humanos.
- PLN é um ramo da inteligência artificial que permite que computadores entendam, interpretem e respondam à linguagem humana de forma natural.
- Combinando ciência da computação e linguística, o PLN preenche a lacuna entre a comunicação humana e a interpretação das máquinas.

Por que o PLN é tão importante hoje?

Volume massivo de dados

- Diariamente são gerados bilhões de textos em redes sociais, e-mails e documentos que precisam ser processados e analisados.

Análise em escala

- Máquinas podem analisar dados textuais em escala e velocidade impossíveis para humanos, sem fadiga ou perda de qualidade.

Automação inteligente

- Automatiza tarefas como atendimento ao cliente, análise de feedback e moderação de conteúdo com eficiência e precisão.
- A capacidade de extrair valor de dados não estruturados tornou o PLN uma tecnologia estratégica para organizações modernas.

Tokenização: O primeiro passo para entender o texto

- Processo fundamental que divide o texto em unidades menores chamadas tokens (palavras, símbolos, frases), transformando o texto bruto em dados estruturados para processamento.

Exemplo:

- "Eu amo PLN!" → ["Eu", "amo", "PLN", "!"]

Stemming e Lematização: Simplificando as palavras

Stemming

- Reduz palavras às suas raízes cortando sufixos.
- Ex.: "correndo", "corredor", "correu" → "corr".
- Rápido, mas impreciso.

Lematização

- Transforma palavras em sua forma base, considerando contexto linguístico.
 - Ex.: "correndo", "corredor", "correu" → "correr".
 - Mais preciso, mas computacionalmente intensivo.
- Ambas as técnicas reduzem a dimensionalidade dos dados e melhoram a eficiência de algoritmos de PLN ao unificar variações de palavras.

Análise de Sentimentos: Capturando emoções no texto

Técnica que identifica o tom emocional de um texto, classificando-o como:

- Positivo 😊
 - Negativo 😡
 - Neutro 😐
-
- Empresas utilizam para monitorar a satisfação dos clientes em redes sociais, avaliações e feedback.

Classificação de Texto: Organizando informações automaticamente

O que é

- Algoritmos que categorizam textos em classes predefinidas com base em seu conteúdo e características.

Aplicações

- Filtros de spam em e-mails.
- Moderação de conteúdo online.
- Categorização de notícias.
- Recomendação personalizada.

Benefícios

- Facilita buscas, filtragem e organização de grandes volumes de dados textuais de forma automática e eficiente.

Técnicas complementares no PLN

POS Tagging

- Identifica a função gramatical das palavras (substantivos, verbos, adjetivos).

Reconhecimento de Entidade (NER)

- Detecta nomes de pessoas, lugares, organizações e outras entidades.

Desambiguação de Sentido

- Interpreta palavras com múltiplos significados com base no contexto.
- Estas técnicas trabalham em conjunto para criar sistemas de PLN mais completos e precisos.

Avanços recentes e modelos de linguagem

Modelos Transformers

- GPT e BERT revolucionaram o PLN com capacidade de compreensão contextual profunda e geração de texto natural.

Tradução Neural

- Sistemas modernos que entendem nuances culturais e contextuais, superando limitações das traduções literais.

Sistemas de Diálogo

- Chatbots e assistentes capazes de manter conversas naturais e resolver problemas complexos em tempo real.

Aplicações reais e impacto do PLN

Principais aplicações

- Assistentes virtuais e chatbots.
- Análise de opinião pública.
- Tradução automática.
- Sistemas de recomendação.

Impacto nas empresas

- O PLN tem transformado a eficiência operacional e a experiência do cliente em diversos setores, desde o atendimento automatizado até análises preditivas baseadas em texto.

Interatividade

Analise as afirmações:

- I. O PLN é um campo da Inteligência Artificial que permite que máquinas compreendam, interpretem e gerem linguagem humana.
- II. A tokenização consiste em dividir um texto em unidades menores, como palavras ou sentenças, sendo um passo fundamental em várias tarefas de PLN.
- III. Stemming e lematização são técnicas que buscam reduzir palavras à sua forma base; o stemming utiliza regras simples de corte, enquanto a lematização considera a gramática e o vocabulário da língua.
- IV. Análise de sentimentos e classificação de texto são aplicações de PLN que utilizam exclusivamente algoritmos não supervisionados.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) III, apenas.
- c) I, II e III, apenas.
- d) II e IV, apenas.
- e) I, II, III e IV.

Resposta

Analise as afirmações:

- I. O PLN é um campo da Inteligência Artificial que permite que máquinas compreendam, interpretem e gerem linguagem humana.
- II. A tokenização consiste em dividir um texto em unidades menores, como palavras ou sentenças, sendo um passo fundamental em várias tarefas de PLN.
- III. Stemming e lematização são técnicas que buscam reduzir palavras à sua forma base; o stemming utiliza regras simples de corte, enquanto a lematização considera a gramática e o vocabulário da língua.
- IV. Análise de sentimentos e classificação de texto são aplicações de PLN que utilizam exclusivamente algoritmos não supervisionados.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) III, apenas.
- c) I, II e III, apenas.
- d) II e IV, apenas.
- e) I, II, III e IV.

O que são Modelos de Linguagem?

- A revolução da inteligência artificial no processamento de linguagem natural transformou nossa capacidade de interagir com máquinas.

Modelos de linguagem são algoritmos sofisticados projetados para prever e representar texto, permitindo às máquinas compreender nuances da linguagem humana. Estes modelos formam a base tecnológica para aplicações como:

- Tradução automática em tempo real;
- Chatbots com compreensão contextual;
- Sistemas de busca com entendimento semântico;
- Assistentes virtuais inteligentes.
 - A evolução destes modelos percorreu um caminho impressionante: dos simples modelos estatísticos baseados em frequência de palavras até as complexas redes neurais profundas que processam bilhões de parâmetros para entender contexto e significado.

Redes Neurais no Processamento de Texto

Identificação de Padrões

- Redes neurais conseguem identificar padrões complexos em dados textuais, aprendendo representações semânticas ricas que capturam significado contextual.

RNNs e LSTMs

- Redes Neurais Recorrentes e Long Short-Term Memory dominaram o PLN antes dos Transformers, processando texto sequencialmente.

Limitações

- Dificuldade em capturar dependências de longo alcance e paralelização ineficiente restringiram o potencial destas arquiteturas iniciais.
 - Embora revolucionárias em seu tempo, as arquiteturas recorrentes sofriam com problemas fundamentais como o desvanecimento do gradiente e processamento sequencial, limitando sua capacidade de compreender texto em contextos amplos.

A Revolução do Transformer (2017)

- A arquitetura Transformer, introduzida no artigo "Attention is All You Need" pelo Google, revolucionou o processamento de linguagem natural ao eliminar a necessidade de recorrência e convoluções.
- O mecanismo de self-attention permite que cada palavra "preste atenção" a todas as outras palavras da sequência simultaneamente, criando representações contextuais riquíssimas.

Vantagens Principais:

- Captura contexto global, em vez de apenas local.
- Paralelização massiva no treinamento.
- Escalabilidade para bilhões de parâmetros.
- Base para BERT, GPT e outros modelos avançados.

BERT: Bidirectional Encoder Representations from Transformers

- Desenvolvido pelo Google AI em 2018, o BERT representou um marco histórico ao introduzir um modelo de linguagem verdadeiramente bidirecional, que entende o contexto completo de uma palavra em ambas as direções.
- O treinamento inovador do BERT inclui dois objetivos principais: prever palavras aleatoriamente mascaradas (Masked LM) e prever se uma sentença segue outra logicamente (Next Sentence Prediction).

Como o BERT funciona?

Tokenização WordPiece

- O texto é dividido em subpalavras usando o algoritmo WordPiece, permitindo melhor cobertura vocabular e tratamento eficiente de palavras raras ou desconhecidas.
- Exemplo: "inacreditável" → "in" + "##acreditá" + "##vel".

Embeddings Compostos

Cada token recebe três tipos de embeddings combinados:

- Token Embedding: representa o significado da palavra.
- Position Embedding: indica a posição na sequência.
- Segment Embedding: distingue diferentes segmentos de texto.

Processamento Bidirecional

- O encoder Transformer processa todos os tokens simultaneamente, permitindo que cada palavra seja contextualizada por todas as outras em ambas as direções.

Treinamento e Fine-tuning do BERT

Pré-treinamento em Grande Escala

O BERT foi pré-treinado em um corpus massivo contendo:

- Toda a Wikipedia em inglês.
- BookCorpus.

Utilizando duas tarefas não supervisionadas:

- Predição de palavras mascaradas;
- Predição da próxima sentença.

Aplicações práticas do BERT e Transformers

Motores de Busca Avançados

- O Google Search utiliza BERT para compreender melhor as consultas dos usuários, capturando nuances e intenções. Isso permite responder a perguntas complexas e entender preposições importantes como "para" e "sem".

Assistentes Virtuais Inteligentes

- Chatbots baseados em Transformers oferecem compreensão contextual avançada, mantendo o histórico da conversa e entendendo referências a elementos mencionados anteriormente.

Análise Textual Sofisticada

- Empresas utilizam modelos baseados em BERT para análise de sentimentos em redes sociais, resumo automático de documentos, tradução com preservação de contexto e extração de informações.

Impacto e futuro dos modelos Transformer

- O BERT abriu caminho para uma nova geração de modelos de linguagem cada vez mais poderosos e versáteis, expandindo os limites do que é possível em processamento de linguagem natural.

Evolução de Escala

- Dos milhões de parâmetros do BERT LARGE para os trilhões de parâmetros em modelos como GPT-4 e PaLM, demonstrando que "bigger is better" em muitos casos.

Multilinguismo

- Modelos como o BERT Multilíngue e XLM-RoBERTa expandiram as capacidades para dezenas de idiomas, incluindo o português brasileiro.

Especialização por Domínio

- Surgimento de BERTs especializados para medicina (BioBERT), finanças (FinBERT) e outras áreas específicas.

Impacto e futuro dos modelos Transformer

Desafios Persistentes

- Custo computacional crescente e sustentabilidade.
- Vieses sociais e preconceitos nos dados de treinamento.
- Dificuldade de interpretabilidade dos modelos.
- Limitações em raciocínio lógico e conhecimento factual.

Interatividade

Analise as afirmações:

- I. Um modelo de linguagem é treinado para prever a próxima palavra em uma sequência, capturando padrões estatísticos da língua.
- II. As redes neurais recorrentes (RNNs) foram muito utilizadas no processamento de texto, mas apresentam limitações em lidar com dependências longas em sequências.
- III. O Transformer introduziu o mecanismo de atenção, permitindo processamento paralelo de sequências e superando limitações das RNNs.
- IV. O BERT é um modelo baseado em Transformer, treinado de forma bidirecional, sendo utilizado em tarefas como análise de sentimentos, tradução e resposta a perguntas.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e III, apenas.
- c) I, III e IV, apenas.
- d) I, II, III e IV.
- e) IV, apenas.

Resposta

Analise as afirmações:

- I. Um modelo de linguagem é treinado para prever a próxima palavra em uma sequência, capturando padrões estatísticos da língua.
- II. As redes neurais recorrentes (RNNs) foram muito utilizadas no processamento de texto, mas apresentam limitações em lidar com dependências longas em sequências.
- III. O Transformer introduziu o mecanismo de atenção, permitindo processamento paralelo de sequências e superando limitações das RNNs.
- IV. O BERT é um modelo baseado em Transformer, treinado de forma bidirecional, sendo utilizado em tarefas como análise de sentimentos, tradução e resposta a perguntas.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e III, apenas.
- c) I, III e IV, apenas.
- d) I, II, III e IV.
- e) IV, apenas.

O que é Visão Computacional?

- A visão computacional é uma tecnologia revolucionária que permite aos computadores interpretar e compreender o mundo visual assim como nós humanos.
- A visão computacional é um campo da inteligência artificial que capacita computadores a extrair, analisar e compreender informações úteis a partir de imagens e vídeos digitais. Diferente do simples processamento de imagens, esta disciplina busca atribuir significado ao conteúdo visual.
- Os sistemas de visão computacional tentam replicar a complexidade da visão humana, permitindo que máquinas identifiquem objetos, reconheçam padrões, meçam distâncias e tomem decisões baseadas em informações visuais.

Aplicações incluem:

- Reconhecimento facial e de gestos.
- Veículos autônomos.
- Diagnóstico médico por imagem.
- Inspeção industrial automatizada.

Detecção de Bordas: O primeiro passo para entender imagens

O que são bordas?

- Bordas representam descontinuidades na intensidade ou cor da imagem, geralmente indicando limites entre objetos ou regiões distintas.

Técnicas Clássicas


- Filtro Sobel: detecta bordas horizontais e verticais.
- Operador Canny: algoritmo multiestágio para bordas precisas.
- Laplaciano: detecta mudanças de segunda ordem na intensidade.

Importância Fundamental

- A detecção de bordas simplifica a representação da imagem, reduzindo significativamente a quantidade de dados a serem processados enquanto preserva as características estruturais essenciais para análises posteriores.
- Essas técnicas transformam imagens complexas em representações mais simples, facilitando a análise e interpretação pelos algoritmos de visão computacional.

Visualizando a Detecção de Bordas

- Nas figuras abaixo, podemos ver o resultado da aplicação do algoritmo Canny de detecção de bordas. À esquerda, vemos a imagem original com todos os seus detalhes e complexidade. À direita, observamos apenas as bordas detectadas, que representam as transições significativas de intensidade na imagem.
- Esta simplificação é crucial para sistemas de visão computacional, pois reduz a quantidade de informação a ser processada enquanto mantém as características estruturais mais importantes da cena. Os contornos detectados são frequentemente usados como entrada para algoritmos de nível superior como reconhecimento de objetos e análise de cenas.



À esquerda imagem original.
À direita imagem com o filtro de Canny.
Fonte: Autoria própria.

Reconhecimento de padrões na Visão Computacional

O reconhecimento de padrões constitui o núcleo da visão computacional, permitindo que sistemas identifiquem e classifiquem características visuais como:

- Formas geométricas e silhuetas;
 - Texturas e gradientes;
 - Objetos complexos em diferentes contextos;
 - Rostos e expressões faciais.
-
- Esta capacidade é fundamental para aplicações como reconhecimento de dígitos manuscritos em documentos, detecção facial em sistemas de segurança e classificação automatizada de produtos em linhas de produção.

Redes Neurais Convolucionais (CNN): Revolução no Reconhecimento Visual

As CNNs representam o estado da arte em visão computacional, inspiradas diretamente na organização do córtex visual humano. Sua arquitetura única permite que extraiam características hierárquicas de imagens:

Características de Baixo Nível

- Bordas, cantos e gradientes simples.

Características de Médio Nível

- Texturas, formas e partes de objetos.

Características de Alto Nível

- Objetos completos, cenas e contextos.

Como funcionam as CNNs?

Camada de Entrada

- Recebe a imagem bruta como matriz de valores de pixels (RGB ou escala de cinza).

Camadas Convolucionais

- Aplicam filtros deslizantes para extrair características locais como bordas, texturas e formas.

Camadas de Pooling

- Reduzem a dimensionalidade espacial, tornando a detecção invariante a pequenas translações.

Camadas Totalmente Conectadas

- Integram todas as características extraídas para realizar a classificação final.
- O grande diferencial das CNNs é sua capacidade de aprender automaticamente os filtros ideais para cada tipo de tarefa, sem necessidade de programação manual de extratores de características.

Arquitetura de uma Rede Neural Convolutacional

O fluxo de processamento em uma CNN típica:

- A imagem de entrada é processada por múltiplas camadas convolucionais que aplicam filtros para detectar características.
 - Camadas de pooling reduzem progressivamente a dimensionalidade espacial, preservando informações importantes.
 - Os mapas de características resultantes são "achatados" em um vetor unidimensional.
 - Camadas totalmente conectadas combinam estas características para classificação final.
-
- Este design permite que a rede aprenda hierarquias complexas de características, desde simples bordas até objetos inteiros.

Aplicações práticas das CNNs em Visão Computacional

Medicina

- Detecção precoce de tumores em mamografias;
- Análise de tomografias para identificação de hemorragias cerebrais;
- Diagnóstico automatizado de retinopatia diabética.

Veículos Autônomos

- Reconhecimento em tempo real de pedestres e ciclistas;
- Identificação de sinais de trânsito e semáforos;
- Mapeamento 3D do ambiente para navegação segura.

Segurança

- Sistemas de vigilância com detecção de comportamentos suspeitos;
- Controle de acesso baseado em reconhecimento facial;
- Monitoramento de multidões em espaços públicos.

Desafios e futuro da Visão Computacional

Desafios Atuais

- Necessidade de grandes conjuntos de dados anotados para treinamento.
- Sensibilidade a variações de iluminação, ângulo e oclusão parcial.
- Alto custo computacional para treinamento de modelos complexos.
- Questões éticas relacionadas à privacidade e viés algorítmico.

Interatividade

Analise as afirmações:

- I. A visão computacional busca permitir que computadores interpretem e analisem imagens e vídeos de forma semelhante ao olho humano.
- II. A detecção de bordas é uma técnica fundamental utilizada para identificar descontinuidades em imagens, auxiliando no reconhecimento de formas e objetos.
- III. O reconhecimento de padrões em visão computacional está restrito apenas ao uso de algoritmos estatísticos, não sendo aplicável com métodos baseados em redes neurais.
- IV. As Redes Neurais Convolucionais (CNNs) são modelos especializados para processamento de imagens, utilizando camadas de convolução para extrair características visuais relevantes.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e III, apenas.
- c) I, II e IV, apenas.
- d) I, III e IV, apenas.
- e) I, II, III e IV.

Resposta

Analise as afirmações:

- I. A visão computacional busca permitir que computadores interpretem e analisem imagens e vídeos de forma semelhante ao olho humano.
- II. A detecção de bordas é uma técnica fundamental utilizada para identificar descontinuidades em imagens, auxiliando no reconhecimento de formas e objetos.
- III. O reconhecimento de padrões em visão computacional está restrito apenas ao uso de algoritmos estatísticos, não sendo aplicável com métodos baseados em redes neurais.
- IV. As Redes Neurais Convolucionais (CNNs) são modelos especializados para processamento de imagens, utilizando camadas de convolução para extrair características visuais relevantes.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e III, apenas.
- c) I, II e IV, apenas.
- d) I, III e IV, apenas.
- e) I, II, III e IV.

O que é Visão Computacional?

- A visão computacional está revolucionando os sistemas de segurança modernos, permitindo análise automatizada de imagens e vídeos em tempo real. Esta tecnologia transforma câmeras comuns em sensores inteligentes capazes de reconhecer pessoas, objetos e comportamentos, elevando significativamente os níveis de proteção em diversos ambientes.
- A visão computacional é uma tecnologia que permite que máquinas reconheçam e interpretem imagens automaticamente com alta precisão. Ela simula a capacidade humana de enxergar e compreender o mundo visual, mas com a vantagem de processar milhares de imagens simultaneamente.
 - Essa tecnologia forma a base para sistemas inteligentes que analisam vídeos em tempo real, detectando objetos, pessoas e comportamentos suspeitos, transformando câmeras passivas em sensores ativos de segurança.

Reconhecimento Facial em Sistemas de Vigilância

Identificação em Tempo Real

- Utilizado para identificar pessoas em ambientes públicos e privados, aumentando significativamente os níveis de segurança em locais de alto risco.

Aplicações Práticas

- Sistemas de vigilância com câmeras que reconhecem rostos em tempo real para detectar intrusos ou pessoas em listas de alerta, permitindo resposta imediata.

Desafios Técnicos

- Variações de iluminação, ângulo, oclusão parcial do rosto e qualidade das imagens impactam diretamente a precisão do reconhecimento.

Técnicas avançadas de Reconhecimento Facial

- Os sistemas modernos utilizam Deep Learning com redes neurais convolucionais (CNNs) como FaceNet e MTCNN, que melhoram significativamente a acurácia do reconhecimento facial mesmo em condições desafiadoras.

Essas tecnologias estão sendo aplicadas em cenários reais de alta complexidade, como:

- Aeroportos internacionais para controle de fronteiras;
- Estações de metrô para identificação de suspeitos;
- Grandes eventos públicos para proteção contra ameaças.

Apesar dos avanços, estes sistemas ainda enfrentam desafios em ambientes não controlados, como:

- Variações extremas de iluminação;
- Reconhecimento de perfis parciais;
- Distinção entre gêmeos idênticos.
- No entanto, os algoritmos mais recentes já conseguem reduzir a taxa de falsos positivos para menos de 0,1% em condições ideais.

Segmentação de Imagens: O que é e para que serve?

- A segmentação de imagens é um processo sofisticado que divide uma imagem em regiões ou objetos distintos para análise detalhada. Esta técnica é fundamental para sistemas de segurança avançados.

Este processo permite:

- Identificar e isolar elementos como pessoas, veículos ou objetos suspeitos em vídeos de vigilância.
 - Acompanhar o movimento de objetos específicos em uma cena.
 - Gerar alertas imediatos para comportamentos predefinidos.
-
- A segmentação precisa permite ações automatizadas e respostas em tempo real, elevando a eficácia dos sistemas de segurança modernos.

Uso da IA para Detecção e Análise de Comportamentos

- Captura de Vídeo: câmeras de alta resolução capturam imagens continuamente.
- Processamento por IA: algoritmos de aprendizado profundo analisam o comportamento humano em tempo real.
- Detecção de Anomalias: sistema identifica comportamentos suspeitos ou não autorizados.
- Resposta Automática: alertas são enviados para equipes de segurança para intervenção imediata.
 - Esses sistemas inteligentes podem detectar ações como invasão de áreas restritas, abandono de objetos suspeitos, aglomerações anormais e até mesmo brigas ou quedas, reduzindo significativamente a necessidade de monitoramento humano constante e aumentando a eficiência operacional.

Sistemas de Vigilância Inteligentes: Casos reais

- **Segurança Pública:** A Inglaterra possui mais de 4 milhões de câmeras CCTV, muitas agora equipadas com IA para reconhecimento facial e detecção de objetos proibidos. Este sistema já contribuiu para a redução de crimes em áreas monitoradas e para a rápida identificação de suspeitos.
- **Segurança Industrial:** Empresas brasileiras utilizam visão computacional para monitorar o uso correto de equipamentos de proteção individual (EPIs) e verificar o cumprimento de protocolos de segurança, reduzindo acidentes de trabalho em até 35%.
- **Cidades Inteligentes:** Cidades como Rio de Janeiro e São Paulo estão adotando sistemas integrados de monitoramento para segurança pública e controle de tráfego, usando visão computacional para detectar acidentes, congestionamentos e situações de emergência.
 - Esses casos demonstram como a tecnologia está transformando a abordagem tradicional de vigilância em sistemas proativos e preditivos.

Benefícios da Visão Computacional em Segurança

- Resposta Rápida: alertas automáticos permitem reação imediata a situações de risco, reduzindo o tempo de resposta em até 60% comparado a sistemas tradicionais.
- Redução de Custos: a automação do monitoramento diminui a necessidade de equipes grandes, reduzindo custos operacionais em até 40% a longo prazo.
- Precisão Aprimorada: sistemas de IA identificam ameaças com acurácia superior a 95% em condições ideais, superando significativamente a capacidade humana.
 - Integração Completa: conexão perfeita com sistemas de controle de acesso, alarmes e outras tecnologias de segurança, criando um ecossistema protetor abrangente.

Desafios e Considerações Éticas

- Privacidade: o uso responsável dos dados coletados é crucial. A Lei Geral de Proteção de Dados (LGPD) no Brasil exige transparência sobre quais informações são armazenadas e como são utilizadas.
- Regulamentação: há necessidade urgente de marcos regulatórios específicos para evitar abusos na utilização de tecnologias de reconhecimento facial e análise comportamental.
- Equilíbrio: encontrar o ponto ideal entre segurança pública e direitos civis continua sendo um dos maiores desafios para a implementação ética dessas tecnologias.

O futuro da Visão Computacional em Segurança

- Presente: sistemas reativos que detectam eventos em tempo real e geram alertas para intervenção humana.
- Curto Prazo: expansão do uso de IA para análise preditiva, identificando padrões que precedem incidentes de segurança antes que ocorram.
- Médio Prazo: integração completa com outras tecnologias como IoT, drones autônomos e sistemas robóticos para resposta coordenada a ameaças.
 - Longo Prazo: democratização do acesso a sistemas avançados para pequenas e médias empresas através de soluções em nuvem e hardware mais acessível.

Interatividade

Analise as afirmações:

- I. O reconhecimento facial é utilizado em sistemas de vigilância para identificar indivíduos em tempo real, mas sua precisão pode ser afetada por fatores como iluminação.
- II. A segmentação de imagens consiste em dividir uma imagem em regiões distintas, permitindo isolar elementos como pessoas, veículos ou objetos suspeitos para análise.
- III. O uso de IA em sistemas de vigilância possibilita a detecção automática de comportamentos suspeitos, reduzindo a necessidade de monitoramento humano constante.
- IV. A visão computacional aplicada à segurança é restrita apenas a ambientes controlados, não sendo utilizada em espaços públicos como aeroportos, estádios e cidades inteligentes.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e III, apenas.
- c) I, II e III, apenas.
- d) I, III e IV, apenas.
- e) I, II, III e IV.

Resposta

Analise as afirmações:

- I. O reconhecimento facial é utilizado em sistemas de vigilância para identificar indivíduos em tempo real, mas sua precisão pode ser afetada por fatores como iluminação.
- II. A segmentação de imagens consiste em dividir uma imagem em regiões distintas, permitindo isolar elementos como pessoas, veículos ou objetos suspeitos para análise.
- III. O uso de IA em sistemas de vigilância possibilita a detecção automática de comportamentos suspeitos, reduzindo a necessidade de monitoramento humano constante.
- IV. A visão computacional aplicada à segurança é restrita apenas a ambientes controlados, não sendo utilizada em espaços públicos como aeroportos, estádios e cidades inteligentes.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e III, apenas.
- c) I, II e III, apenas.
- d) I, III e IV, apenas.
- e) I, II, III e IV.

ATÉ A PRÓXIMA!