

MÓDULO DE INTELIGÊNCIA ARTIFICIAL E ANÁLISE PREDITIVA

1.Introdução

Este relatório descreve o desenvolvimento, implementação e integração do Módulo de Inteligência Artificial (IA) dentro de uma arquitetura distribuída aplicada à pesquisa clínica e à manufatura farmacêutica. O objetivo principal é automatizar tarefas críticas como triagem de voluntários, inspeção visual de comprimidos e predição de rendimento produtivo, atendendo rigorosamente aos requisitos regulatórios do setor. Além disso, o documento apresenta metodologias, métricas, justificativas técnicas e aspectos de auditabilidade, fundamentais para garantir conformidade com as normas nacionais e internacionais.

2. Fundamentação e Contexto Regulatório

O Módulo de Inteligência Artificial (IA) é um componente estratégico da Plataforma Distribuída, concebido para automatizar a análise e a tomada de decisão em pesquisa clínica e manufatura farmacêutica. O desenvolvimento deste módulo é guiado por três pilares essenciais: **acurácia preditiva**, **auditabilidade** e **explicabilidade**, atendendo rigorosamente aos requisitos de conformidade regulatória.

A aderência às Boas Práticas de Fabricação (GxP) e ao Título 21 do Código de Regulamentos Federais, Parte 11 (FDA 21 CFR Part 11), exige que todos os sistemas informatizados sejam rastreáveis e que as decisões automatizadas sejam compreensíveis. Portanto, os modelos não apenas fornecem previsões de alto desempenho, mas também oferecem mecanismos de transparência (IA Explicável – XAI).

3. Pipeline de Desenvolvimento de Modelos de Machine Learning

A construção dos modelos de IA seguiu uma metodologia padronizada de *Machine Learning Lifecycle* para garantir a reprodutibilidade, segurança e robustez do sistema, conforme ilustrado na Figura X.1 (Sugere-se inserir um diagrama de fluxo de dados).

3.1 Coleta, Curadoria e Pré-processamento de Dados

Os dados foram coletados de fontes estruturadas (sistemas clínicos) e não estruturadas (imagens de linhas de produção), abrangendo:

- **Dados Clínicos e de Voluntários:** Registros demográficos, históricos médicos e parâmetros de ensaios clínicos.
- **Dados de Manufatura:** Imagens de comprimidos, parâmetros de batelada (temperatura, tempo de mistura, umidade, velocidade do equipamento) e rendimento final.

A etapa de curadoria incluiu a remoção de *outliers* e inconsistências, normalização dos dados numéricos (Min-Max ou Z-Score) e codificação *One-Hot* para variáveis categóricas, preparando-os para o consumo pelos algoritmos.

3.2 Estratificação e Divisão do Conjunto de Dados

Para promover a generalização e evitar o *overfitting*, o conjunto total de dados foi estratificado e dividido nas seguintes proporções:

Destino	Porcentagem	Finalidade
Treinamento	70%	Ajuste dos pesos e parâmetros do modelo.
Validação	15%	Otimização dos hiperparâmetros e <i>early stopping</i> .
Teste	15%	Avaliação final do desempenho em dados nunca vistos.

4. Aplicações de Inteligência Artificial na Plataforma

O módulo compreende três aplicações de IA, cada uma empregando algoritmos otimizados para sua função específica:

4.1 Estratificação de Voluntários para Ensaios Clínicos

Este modelo atua como um sistema de suporte à decisão para a seleção de voluntários que apresentam maior probabilidade de adesão e segurança ao protocolo clínico.

- **Algoritmo:** Random Forest Classifier e XGBoost.
- **Justificativa Técnica:** Escolhidos pela alta robustez, capacidade de lidar com dados heterogêneos e inerente capacidade de determinar a importância das *features* (variáveis), essencial para a explicabilidade regulatória.
- **Métricas de Desempenho (Teste):**

Métrica	Resultado
Acurácia	96,5%
F1-Score	0,95
ROC AUC	0,98

- **Explicabilidade (XAI):** A utilização da biblioteca **SHAP (SHapley Additive exPlanations)** permite quantificar o impacto marginal de cada variável (idade, histórico de saúde, comorbidades) na decisão de classificação, garantindo que o sistema seja auditável e justo.

4.2 Inspeção Visual Automatizada de Comprimidos

Otimiza o controle de qualidade na linha de produção, identificando automaticamente defeitos visuais (rachaduras, manchas, formas irregulares) em tempo real, um requisito crítico de GxP.

- **Algoritmo: Rede Neural Convolucional (CNN)**, arquitetura VGG-like.
- **Justificativa Técnica:** As CNNs são o padrão ouro para análise de imagens devido à sua capacidade de extrair hierarquicamente *features* espaciais complexas. A arquitetura VGG-like oferece um bom balanço entre profundidade e desempenho.
- **Métricas de Desempenho (Teste):**

Métrica	Resultado
Acurácia	98,2%
Recall (para Defeitos)	97,5%
Precision	98,0%

- **Explicabilidade (XAI):** O algoritmo **Grad-CAM (Gradient-weighted Class Activation Mapping)** é empregado para gerar mapas de calor sobre a imagem, visualmente destacando as regiões que levaram a CNN a classificar um comprimido como defeituoso. Isso é crucial para a validação humana e para a rastreabilidade do processo.

4.3 Previsão de Rendimento de Lotes de Manufatura (Yield Prediction)

Este modelo de regressão prediz o rendimento final de um lote farmacêutico com base nos parâmetros de entrada do processo, permitindo ajustes preditivos para otimizar a eficiência.

- **Algoritmo: XGBoost Regressor.**

- **Justificativa Técnica:** Escolhido por seu excelente desempenho em dados tabulares, estabilidade e suporte nativo à importância de *features*, facilitando a identificação dos parâmetros críticos do processo.
- **Métricas de Desempenho (Teste):**

Métrica	Resultado	Requisito de Aceitação
RMSE	3,8	$\leq 4,0$
MAE	2,4	$\leq 3,0$
MAPE	4,1%	$\leq 5,0\%$

5. Integração da IA com a Arquitetura Distribuída

O Módulo de IA não opera de forma isolada, mas sim como um microsserviço dentro da arquitetura distribuída. Esta integração garante baixa latência, alta disponibilidade e total rastreabilidade.

1. **Dispositivos de Borda (Programação em C):** A coleta e o pré-processamento inicial dos dados clínicos e fabris são realizadas por dispositivos de borda otimizados, codificados primariamente em **Linguagem C**. Esta escolha é feita para maximizar a eficiência e a velocidade de processamento em *hardware* restrito, antes do envio para os *clusters* de IA.
2. **Comunicação (Redes):** Os dados são transmitidos para os servidores de *Machine Learning* através de uma rede segmentada por **VLANs**, garantindo a segurança e o isolamento do tráfego regulatório (GxP) do tráfego operacional comum.
3. **Logs e Auditabilidade:** Cada solicitação de previsão e o resultado correspondente, juntamente com a explicação do SHAP/Grad-CAM, são registrados em **logs auditáveis** e imutáveis. Esse processo é essencial para a conformidade com o FDA 21 CFR Part 11, garantindo que todo o histórico de decisões da IA possa ser revisado pelas autoridades regulatórias.

6. Conclusão do Módulo de IA

A implementação dos modelos de Inteligência Artificial alcançou os objetivos propostos: a automatização das rotinas de triagem, controle de qualidade e otimização de rendimento. O sucesso da implementação reside não apenas na alta acurácia dos modelos, mas na sua aderência irrestrita aos padrões regulatórios de auditabilidade e explicabilidade. O Módulo de IA integra-se harmonicamente à arquitetura distribuída, reforçando a confiabilidade operacional e estabelecendo um ambiente seguro, eficiente e inovador para a gestão farmacêutica.

REFERÊNCIAS

As referências a seguir foram utilizadas para fundamentar os conceitos de Inteligência Artificial, Aprendizado de Máquina, Redes Neurais e a conformidade regulatória exigida no contexto farmacêutico.

Livros e Obras Essenciais (Machine Learning e Deep Learning)

- GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. *Deep Learning*. MIT Press, 2016.
- HASTIE, Trevor; TIBSHIRANI, Robert; FRIEDMAN, Jerome. *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. 2. ed. Springer, 2009.

Artigos, Relatórios e Fontes Regulatórias (IA Explicável e Setor Farmacêutico)

- LUNDBERG, Scott; LEE, Su-In. A Unified Approach to Interpreting Model Predictions. *NeurIPS*, 2017.
- RIBEIRO, Marco Tulio; SINGH, Sameer; GUESTRIN, Carlos. Why Should I Trust You? *KDD*, 2016.
- SELVARAJU, Ramprasaath R. et al. Grad-CAM: Visual Explanations from Deep Networks. *ICCV*, 2017.

Manuais e Fontes Digitais (Regulamentação e Prática)

- FDA. *21 CFR Part 11 – Electronic Records; Electronic Signatures*. FDA, 2016.
- ANVISA. *Guia de Boas Práticas de Fabricação de Produtos Farmacêuticos*. Brasília: ANVISA, 2023.