



UNIDADE I

Machine Learning e Análise de Dados

Profa. Dra. Vanessa Lessa

O que é Machine Learning?

- Machine learning é a área da **inteligência artificial (IA)** dedicada ao desenvolvimento de métodos que possibilitam a um sistema computacional **identificar padrões em dados** e utilizá-los para realizar previsões, classificações ou tomadas de decisão – sem que todas as regras precisem ser explicitamente programadas.
- O foco desloca-se da codificação manual de regras para a **construção de modelos capazes de aprender com exemplos**. O desenvolvedor fornece dados representativos e permite que o algoritmo extraia, de forma automática, as relações relevantes.
- Machine learning não substitui completamente a programação tradicional. Na prática, muitos sistemas utilizam abordagens híbridas, combinando regras explícitas com modelos de aprendizado de máquina.

Programação Tradicional vs. Machine Learning

- A diferença fundamental está em **como o comportamento do sistema é determinado**. Na programação convencional, o código define rigidamente cada ação. No aprendizado de máquina, o comportamento **emerge do processo de treinamento**, no qual o algoritmo ajusta seus parâmetros internos com base nos dados disponíveis.

Programação Tradicional

- Regras fixas escritas pelo programador.
- Comportamento rígido e determinístico.
- Exige manutenção constante para acompanhar mudanças.

Machine Learning

- Modelos que aprendem com dados.
- Comportamento adaptativo e autônomo.
- Capacidade de **generalização** para situações novas, nunca observadas.
- Essa capacidade de generalização – aplicar conhecimento adquirido a situações novas – é um dos principais fatores que explicam a ampla adoção do ML em aplicações do mundo real.

ML no Ecossistema da Inteligência Artificial

- O aprendizado de máquina não é uma tecnologia isolada, mas parte de um **ecossistema mais amplo** que envolve IA, análise de dados e ciência de dados.

Inteligência Artificial

- Campo mais abrangente, voltado à construção de sistemas inteligentes.

Machine Learning

- Pilar central da IA, fornecendo mecanismos para que máquinas aprendam com dados.

Ciência de Dados

- Bases metodológicas para coleta, preparação e interpretação das informações.

Big Data

- Crescimento exponencial dos dados que impulsionou a necessidade de ferramentas inteligentes.

John McCarthy e a Origem da IA

- O termo **inteligência artificial** foi cunhado após a Segunda Guerra Mundial, na **Conferência de Dartmouth, em 1956**, por John McCarthy.
- McCarthy, renomado cientista da computação, destacou-se pelos seus estudos na área de IA, pela criação da linguagem de programação **Lisp**, além de receber o **Prêmio Turing em 1972** e a **Medalha Nacional de Ciências dos Estados Unidos em 1991**.
- Um sistema aprende quando seu desempenho em determinada tarefa melhora à medida que é exposto a mais dados ou exemplos.



John McCarthy

Fonte: <https://x.gd/x8avN>

Tipos de Aprendizado: Aprendizado Supervisionado

- Caracterizado pelo uso de **dados rotulados** – conjuntos nos quais cada instância possui uma resposta previamente conhecida. Os rótulos funcionam como referência, permitindo que o modelo aprenda a associar entradas a saídas corretas.

Como Funciona

- O algoritmo compara previsões com valores reais, ajustando parâmetros internos para reduzir erros de forma iterativa.

Avaliação Objetiva

- Métricas como taxa de acerto e erro médio permitem verificar se o modelo está evoluindo adequadamente.

Limitações

- Depende da disponibilidade e qualidade dos rótulos. Dados enviesados podem comprometer a imparcialidade do modelo.
- Em aprendizado supervisionado, os rótulos são tão importantes quanto os dados de entrada. Rótulos incorretos comprometem todo o processo de aprendizado.

Generalização e Sobreajuste

Generalização

- Um modelo eficaz não deve apenas memorizar exemplos do treinamento, mas ser capaz de **aplicar o conhecimento a novos dados**.

Sobreajuste (Overfitting)

- Quando o modelo se ajusta excessivamente aos dados disponíveis, capturando inclusive **ruídos e variações irrelevantes**, seu desempenho se degrada em situações reais.
- O equilíbrio entre complexidade e generalização é essencial.
- A forma como os dados são apresentados ao algoritmo influencia diretamente o aprendizado. A **seleção de variáveis**, a **codificação das informações** e a **qualidade dos rótulos** desempenham papel central no desempenho do modelo.

Tipos de Aprendizado: Aprendizado Não Supervisionado

- Trabalha com **dados não rotulados**, sem respostas predefinidas. O algoritmo identifica padrões, estruturas ou regularidades de forma autônoma. O foco passa a ser a **descoberta de informações ocultas** e a organização significativa dos dados.

Exploração Inicial

- Particularmente útil quando o analista não possui hipóteses claras ou deseja compreender a estrutura interna dos dados.

Organização de Dados

- Agrupa instâncias semelhantes e reduz a dimensionalidade, tornando dados complexos mais compreensíveis e manejáveis.

Avaliação Qualitativa

- Sem rótulos para validação direta, a qualidade depende de coerência interna, interpretabilidade e utilidade prática dos padrões.

Supervisionado vs. Não Supervisionado

- A distinção não implica superioridade, mas **adequação a diferentes tipos de problemas**.

Não Supervisionado

- Explora dados e descobre padrões.

Supervisionado

- Constrói modelos preditivos com rótulos.

Híbrido

- Combina ambos para aplicações robustas.
- Métodos não supervisionados podem ser empregados inicialmente para explorar os dados e identificar segmentações naturais, enquanto modelos supervisionados são aplicados posteriormente para previsões mais específicas e direcionadas.

Responsabilidade e Visão Crítica

- Modelos de ML podem influenciar decisões com impacto significativo sobre indivíduos e organizações. O aprendizado supervisionado reflete as escolhas e interpretações humanas presentes no processo de rotulagem – os rótulos carregam pressupostos, critérios e, em alguns casos, vieses que podem ser incorporados pelo modelo.
- Não basta implementar algoritmos: é necessário compreender o problema, selecionar dados relevantes, avaliar a qualidade das informações e interpretar criticamente os resultados. Um modelo com elevado desempenho estatístico pode ser inadequado do ponto de vista prático ou ético.
- Resultados aparentemente objetivos podem refletir limitações, vieses ou lacunas presentes nos dados.

Aplicações Práticas: ML como Apoio à Tomada de Decisão

- Em ambientes organizacionais, o machine learning permite que sistemas analisem dados históricos, identifiquem padrões recorrentes e antecipem comportamentos futuros. Essa capacidade preditiva é valiosa quando decisões precisam ser rápidas e fundamentadas.

Análise de Comportamento

- Plataformas de e-commerce e streaming identificam preferências e padrões de uso para personalizar recomendações, adaptando a experiência de cada usuário.

Detecção de Anomalias

- Em segurança da informação e operações financeiras, modelos diferenciam situações legítimas de suspeitas, automatizando processos críticos de monitoramento.

Previsão de Valores

- Modelos de regressão estimam vendas, consumo ou utilização de recursos, auxiliando gestores no planejamento estratégico e alocação de recursos.

Aplicações Práticas: Segmentação e Organização de Dados

- Quando o volume de informações cresce de forma acelerada, o aprendizado não supervisionado oferece mecanismos para agrupar dados semelhantes, facilitando compreensão e análise.

Segmentação de Clientes

- Identifica grupos com características semelhantes sem categorias predefinidas, revelando padrões inesperados de comportamento.

Análise Educacional

- Em ambientes virtuais de aprendizagem, agrupa estudantes com trajetórias semelhantes para apoiar intervenções pedagógicas personalizadas.

Detecção de Padrões Atípicos

- Sistemas de monitoramento identificam comportamentos fora do padrão sem necessidade de definições prévias rígidas.

Aplicações Práticas: Sistemas que Aprendem Continuamente

- Diferentemente de soluções estáticas, modelos de ML podem ser atualizados à medida que novos dados são incorporados, adaptando-se a mudanças no ambiente ou no comportamento dos usuários.

Adaptação Dinâmica

- Padrões antigos podem deixar de ser válidos – o sistema evolui de forma autônoma com dados atualizados.

Novo Ciclo de Vida

- Inclui monitoramento contínuo de desempenho, revisão periódica dos dados e reentrenamento dos modelos.

Interpretabilidade

- Em decisões sensíveis, é fundamental compreender como o sistema chegou a determinado resultado.

O Papel do Profissional de ML

- O machine learning não elimina a necessidade de conhecimento humano, mas redefine seu papel. O profissional passa a atuar como mediador entre dados, modelos e decisões.

Compreender o Problema

- Avaliar quando o uso de ML é apropriado e quais tipos de aprendizado são mais adequados.

Selecionar e Preparar Dados

- Garantir qualidade, representatividade e ausência de vieses nos dados de treinamento.

Interpretar e Validar Resultados

- Analisar criticamente os resultados, considerando contexto, limitações e implicações éticas.

Monitorar e Evoluir

- Acompanhar o desempenho dos modelos ao longo do tempo e adaptá-los conforme necessário.

Interatividade

Analise as afirmações:

- I. Modelos de Machine Learning podem influenciar decisões com impacto significativo sobre indivíduos e organizações, sendo necessárias análise crítica e responsabilidade ética na sua aplicação.
- II. O alto desempenho estatístico de um modelo garante automaticamente sua adequação prática e ética em qualquer contexto de aplicação.
- III. Sistemas de Machine Learning podem ser atualizados à medida que novos dados são incorporados, exigindo monitoramento contínuo e eventual reentrenamento dos modelos.
- IV. O uso de Machine Learning elimina a necessidade de conhecimento humano, pois o sistema passa a tomar decisões de forma totalmente autônoma e independente de supervisão.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e IV, apenas.
- c) I e III, apenas.
- d) III e IV, apenas.
- e) I, II e III, apenas.

Resposta

Analise as afirmações:

- I. Modelos de Machine Learning podem influenciar decisões com impacto significativo sobre indivíduos e organizações, sendo necessárias análise crítica e responsabilidade ética na sua aplicação.
- II. O alto desempenho estatístico de um modelo garante automaticamente sua adequação prática e ética em qualquer contexto de aplicação.
- III. Sistemas de Machine Learning podem ser atualizados à medida que novos dados são incorporados, exigindo monitoramento contínuo e eventual reentrenamento dos modelos.
- IV. O uso de Machine Learning elimina a necessidade de conhecimento humano, pois o sistema passa a tomar decisões de forma totalmente autônoma e independente de supervisão.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e IV, apenas.
- c) I e III, apenas.
- d) III e IV, apenas.
- e) I, II e III, apenas.

Fundamentos de Análise de Dados

O Que é Análise de Dados?

A análise de dados pode ser compreendida como o **conjunto de processos, métodos e técnicas** utilizados para examinar dados com o objetivo de:

- Extrair significado de grandes volumes de informação.
 - Identificar padrões e compreender comportamentos.
 - Subsidiar a tomada de decisão com evidências.
-
- Diferentemente de abordagens puramente descritivas, a análise moderna integra conceitos **estatísticos, computacionais e analíticos**, permitindo lidar com dados heterogêneos e complexos.

O Conceito de Big Data

- O crescimento exponencial da produção de dados está diretamente relacionado ao conceito de **big data** – conjuntos de dados cuja escala, complexidade e diversidade ultrapassam a capacidade das ferramentas tradicionais de processamento.
- O big data não se define apenas pelo volume armazenado, mas por um conjunto de características que impactam diretamente a forma como os dados são coletados, analisados e utilizados. Essas características representam uma **mudança significativa** na maneira como a informação é tratada em ambientes computacionais modernos.

Os Pilares do Big Data

- **Volume** - Quantidades massivas de informações de múltiplas fontes: transações, redes sociais, sensores e dispositivos conectados. Sem métodos adequados, grandes volumes resultam apenas em sobrecarga informativa.
- **Velocidade** - Dados produzidos em tempo quase real exigem análises rápidas. Sistemas de monitoramento e plataformas financeiras exemplificam cenários em que a utilidade depende da atualização constante.
- **Variedade** - Textos, imagens, áudios, vídeos e registros semiestruturados coexistem no mesmo ambiente analítico, ampliando o potencial, mas aumentando a complexidade do processo.
- **Veracidade** - Grandes volumes podem conter inconsistências, ruídos, duplicidades e informações incompletas. Dados imprecisos ou enviesados comprometem análises e decisões, independentemente da sofisticação das ferramentas.
- **Valor** - Dados, por si só, não possuem utilidade intrínseca. Seu valor emerge quando são analisados e interpretados de forma adequada. A análise de dados assume o papel de transformar informações em conhecimento acionável.

O que é Ciência de Dados?

- A ciência de dados surge como um **campo interdisciplinar** voltado à extração de conhecimento a partir de dados, integrando estatística, computação, matemática e conhecimento de domínio.

Orientada a Problemas

- O foco está na formulação de perguntas relevantes e na busca por respostas fundamentadas.

Ciclo Completo

- Envolve todo o ciclo de vida dos dados: desde a coleta até a comunicação dos resultados.

Interdisciplinar

- Combina rigor técnico e visão contextual, exigindo trânsito entre diferentes domínios de conhecimento.

Análise de Dados vs. Ciência de Dados

- A relação entre ciência de dados e análise de dados é **estreita e complementar**.

Análise de Dados

- Fornece os fundamentos conceituais e metodológicos para compreender e preparar os dados. Tradicionalmente, focava em conjuntos relativamente pequenos e estruturados.

Ciência de Dados

- Estrutura o processo de forma mais ampla, integrando técnicas avançadas e abordagens computacionais. Representa um campo mais abrangente, no qual a análise de dados é um pilar central.

Decisões Baseadas em Dados

- Em ambientes organizacionais, decisões tomadas com base apenas em intuição tendem a ser menos consistentes em cenários complexos. A análise de dados permite **fundamentar decisões em evidências**, reduzindo incertezas e aumentando a confiabilidade dos resultados.
- **Atenção:** A disponibilidade de grandes volumes de dados pode criar a ilusão de que todas as decisões podem ser automatizadas. A ciência de dados reconhece que **dados não falam por si mesmos** – sua interpretação depende do contexto e do conhecimento humano.

Big Data + Ciência de Dados: Uma Interdependência

Big Data

- Fornece o contexto e os desafios de escala.

Ciência de Dados

- Oferece métodos e abordagens analíticas.

Conhecimento

- Transforma dados massivos em informações úteis.

Decisão

- Apoia ações estratégicas fundamentadas.
- O big data, por si só, não gera conhecimento. É a ciência de dados que transforma dados massivos em informações compreensíveis. A análise de dados assume um papel central como **elo entre a infraestrutura tecnológica e a tomada de decisão**.

Dados como Ativos Estratégicos

- Ao compreender os fundamentos da análise de dados, big data e ciência de dados, desenvolvemos uma **visão mais ampla** sobre o papel dos dados na sociedade contemporânea.
- Dados deixam de ser apenas registros operacionais e passam a ser vistos como **ativos estratégicos**, capazes de orientar decisões e impulsionar inovações. Essa mudança de perspectiva é fundamental para a atuação profissional.
- A ciência de dados, ao articular análise de dados, big data e aprendizado de máquina, representa uma **síntese das transformações** ocorridas na área de tecnologia da informação nas últimas décadas.

Preparação de Dados: A Coleta de Dados

- A coleta representa o **ponto de partida** do processo analítico – a obtenção de informações a partir de diferentes fontes, internas ou externas.

Fontes Diversas

- Aplicações, sensores, dispositivos IoT, logs, transações eletrônicas, bases públicas e repositórios institucionais.

Etapas Estratégicas

- Não é meramente técnica – exige clareza quanto aos objetivos da análise e às perguntas que se deseja responder.

Equilíbrio Essencial

- Coleta excessiva aumenta complexidade e custos; coleta insuficiente limita a identificação de padrões significativos.

Preparação de Dados: A Etapa de Limpeza

- Após a coleta, os dados geralmente apresentam problemas que impedem sua utilização direta. A limpeza tem como objetivo identificar e tratar essas imperfeições, assegurando que os dados representem de forma mais fiel o fenômeno analisado.

Valores Ausentes

- Falhas na coleta, erros de sensores ou omissões. A simples exclusão pode introduzir viés.

Inconsistências

- Datas inválidas, números fora de faixa ou categorias incorretas que comprometem a qualidade.

Duplicidades

- Registros duplicados distorcem estatísticas e comprometem análises preditivas.

Outliers

- Valores extremos que podem ser erros ou eventos raros relevantes. Exigem tratamento criterioso.

Por que a Limpeza é tão Importante?

O Investimento Essencial

- A limpeza é frequentemente apontada como uma das etapas **mais trabalhosas e demoradas** da análise de dados. No entanto, sua importância não pode ser subestimada.
- Dados mal limpos geram análises imprecisas e modelos pouco confiáveis, **independentemente da sofisticação** das técnicas utilizadas posteriormente.

Além da Técnica

- A limpeza não consiste apenas em remover dados problemáticos, mas em **compreender sua origem e impacto** sobre a análise.
- A distinção entre erro e variação legítima nem sempre é evidente – exige conhecimento sobre o domínio do problema e decisões criteriosas e bem fundamentadas.

Preparação de dados: O Pré-processamento de Dados

- Após a limpeza, o pré-processamento prepara os dados para análise e modelagem, funcionando como uma **ponte entre os dados brutos e os métodos analíticos**. Muitos algoritmos operam sob pressupostos específicos quanto ao formato, escala e distribuição dos dados.

Transformação

- Harmonizar representações heterogêneas em formatos compatíveis.

Escala

- Ajustar variáveis para escalas comparáveis e equilibradas.

Seleção

- Identificar atributos mais informativos e eliminar redundâncias.

Desafios do Pré-processamento

Adequação de Escala

- Variáveis com ordens de magnitude muito diferentes podem influenciar negativamente os métodos analíticos. Sem ajuste, variáveis com valores mais elevados exercem maior influência nos resultados, **independentemente de sua relevância conceitual**.

Dados Categóricos

- Categorias ou rótulos textuais precisam ser convertidos em formatos interpretáveis por algoritmos. A escolha inadequada da representação pode **induzir interpretações equivocadas** por parte dos modelos.

Redução de Complexidade

- Conjuntos extensos com muitas variáveis dificultam a análise. A eliminação de atributos redundantes e a combinação de informações correlacionadas favorecem **modelos mais interpretáveis e eficientes**.

Documentação, Ética e Responsabilidade

Documentação

- Registrar fontes de dados, critérios de limpeza e transformações aplicadas garante **reprodutibilidade** das análises e facilita a manutenção dos sistemas e a comunicação entre equipes.

Ética

- Decisões aparentemente técnicas – como exclusão de registros ou tratamento de valores ausentes – podem **introduzir vieses ou reforçar desigualdades**. A preparação dos dados exige consciência crítica.

Qualidade

- Modelos construídos a partir de dados mal preparados apresentam **desempenho instável e baixa generalização**. O sucesso depende sobretudo da qualidade da preparação dos dados.

Interatividade

Analise as afirmações:

- I. A coleta de dados é uma etapa estratégica do processo analítico, pois exige definição clara dos objetivos e equilíbrio entre quantidade de dados coletados e relevância das informações.
- II. O pré-processamento de dados atua como uma ponte entre os dados brutos e os métodos analíticos, incluindo transformação, ajuste de escala e seleção de atributos.
- III. A limpeza de dados consiste apenas na remoção automática de valores ausentes e duplicados, não exigindo análise do contexto ou do domínio do problema.
- IV. A preparação dos dados é uma etapa secundária, tendo pouca influência na qualidade dos modelos e podendo ser compensada por algoritmos mais sofisticados.

Está correto o que se afirma em:

- a) I e III, apenas.
- b) I e II, apenas.
- c) II e IV, apenas.
- d) III e IV, apenas.
- e) I, II e III, apenas.

Resposta

Analise as afirmações:

- I. A coleta de dados é uma etapa estratégica do processo analítico, pois exige definição clara dos objetivos e equilíbrio entre quantidade de dados coletados e relevância das informações.
- II. O pré-processamento de dados atua como uma ponte entre os dados brutos e os métodos analíticos, incluindo transformação, ajuste de escala e seleção de atributos.
- III. A limpeza de dados consiste apenas na remoção automática de valores ausentes e duplicados, não exigindo análise do contexto ou do domínio do problema.
- IV. A preparação dos dados é uma etapa secundária, tendo pouca influência na qualidade dos modelos e podendo ser compensada por algoritmos mais sofisticados.

Está correto o que se afirma em:

- a) I e III, apenas.
- b) I e II, apenas.**
- c) II e IV, apenas.
- d) III e IV, apenas.
- e) I, II e III, apenas.

Por que o Pré-Processamento é Fundamental?

- Dados brutos coletados em sistemas reais **raramente estão prontos** para uso analítico imediato. Apresentam inconsistências, valores ausentes, escalas distintas e formatos variados. O pré-processamento transforma dados dispersos e heterogêneos em um conjunto estruturado, coerente e adequado à extração de conhecimento, reduzindo ruídos e minimizando distorções que comprometeriam os resultados.

Dados Brutos

- Inconsistentes e heterogêneos.

Pré-Processamento

- Limpeza e transformação.

Dados Preparados

- Estruturados e confiáveis.

Limpeza e Transformação de Dados

- A preparação adequada dos dados é um dos pilares fundamentais da análise de dados e do machine learning. Remoção de valores ausentes, normalização e padronização possuem implicações conceituais profundas – influenciam diretamente a qualidade das análises, a interpretação dos resultados e o desempenho dos modelos.
- Antes de aplicar qualquer técnica de análise ou modelagem, verifique se os dados representam corretamente o problema que se deseja estudar.

Valores Ausentes: Mais Que um Problema Técnico

- Valores ausentes surgem por falhas na coleta, erros de sensores, omissões em formulários ou limitações dos sistemas de registro. Sua presença é um **desafio significativo**, pois muitos algoritmos pressupõem informações completas.

Não é trivial

- Excluir registros pode resultar em perda de informações relevantes e introdução de viés.

Contexto importa

- A ausência pode estar associada a características específicas do fenômeno analisado.

Análise prévia

- Exige compreensão da origem, frequência e impacto sobre o conjunto de dados.

Tratamento de Valores Ausentes

- Quando a proporção de valores ausentes é pequena, a remoção pode ser justificada. Porém, quando é significativa, são necessárias **estratégias alternativas** de substituição ou estimativa, preservando o máximo de informação possível.

Variáveis **numéricas** e **categóricas** apresentam desafios distintos:

- Em numéricas, estimativas podem alterar distribuição e medidas estatísticas.
- Em categóricas, a ausência pode indicar uma categoria específica ou simplesmente falta de informação.

Sinal de Qualidade

- Dados com grande quantidade de valores ausentes podem indicar **problemas estruturais** no processo de coleta, exigindo revisões nos sistemas utilizados.
- A análise da ausência fornece informações valiosas sobre a qualidade do processo de geração dos dados.

Normalização e Padronização

- Após o tratamento de valores ausentes, essas técnicas ajustam a **escala e a distribuição** das variáveis. Em dados reais, variáveis expressas em diferentes unidades e ordens de grandeza influenciam significativamente métodos sensíveis à escala.

Normalização

- Transforma valores para um intervalo específico (geralmente limitado), preservando proporções relativas. **Não altera a forma da distribuição**, apenas ajusta a escala.

Padronização

- Transforma dados para características estatísticas específicas (centralização e dispersão). Torna variáveis comparáveis, **independentemente de suas unidades originais**.
- A escolha entre elas é **conceitual, não apenas técnica** – influencia como os dados são interpretados e como padrões são identificados. Muitos algoritmos de ML são sensíveis à escala, e a ausência dessas transformações pode resultar em convergência lenta, instabilidade ou desempenho inferior.

A Natureza Sistêmica do Pré-Processamento

- Remoção de valores ausentes, normalização e padronização **não ocorrem de forma isolada**. Decisões tomadas em uma etapa influenciam as demais – por exemplo, a substituição de valores ausentes pode alterar distribuições, afetando como a normalização deve ser aplicada.
 - Tratamento de ausentes.
 - Normalização.
 - Padronização.
 - Validação.
- A documentação das transformações aplicadas é fundamental para garantir **transparência, reprodutibilidade** e facilitar a interpretação dos resultados. Do ponto de vista ético, decisões sobre exclusão ou substituição podem influenciar a representação de grupos nos resultados finais.

Normalização Min-Max

- Ajusta os valores para um intervalo entre **0 e 1**. Útil quando os dados possuem limites bem definidos e não são sensíveis a outliers. Preserva a distribuição e as relações proporcionais.

$$x_{norm} = \frac{x - \min(x)}{\max(x) - \min(x)}$$

- Em que x é o valor original, **min(x)** é o menor valor e **max(x)** é o maior valor dos dados.

Exemplo Prático: Notas de Alunos

Aluno	Nota Original	Cálculo	Normalizado
A	75	$(75-60)/(90-60)$	0.5
B	90	$(90-60)/(90-60)$	1.0
C	60	$(60-60)/(90-60)$	0.0
D	85	$(85-60)/(90-60)$	0.8

- Ideal para algoritmos sensíveis à escala, como **redes neurais** e **algoritmos de otimização**.

Normalização Z-Score (Padronização)

- Ajusta os dados para **média zero** e **desvio-padrão um**. Útil para comparar dados com diferentes médias e desvios-padrão. Sensível a outliers.

$$x_{norm} = \frac{x - mean(x)}{std(x)}$$

Cálculos Intermediários

mean(x) = 77.5
std(x) = 11.4

Resultados

Aluno	Nota	Z-Score
A	75	-0.2
B	90	1.1
C	60	-1.5
D	85	0.6

- Transforma os dados para uma **distribuição normal**. Quanto mais próximo de 0 o desvio-padrão, mais homogêneos são os dados.

Normalização por Escala Logarítmica

- Aplicada quando dados apresentam **distribuição assimétrica** ou amplitude muito grande. Reduz a influência de valores extremos e amplia a capacidade de distinguir diferenças nos valores menores.

Resultados do Exemplo

- Aluno A: $\log(75) \approx 4.317$
- Aluno B: $\log(90) \approx 4.499$
- Aluno C: $\log(60) \approx 4.094$
- Aluno D: $\log(85) \approx 4.442$

Quando Usar?

- Dados com ampla variação em ordens de magnitude.
- Distribuição assimétrica.
- Diferenças relativas menos importantes que absolutas.
- A escolha da técnica depende do tipo de dados, da distribuição e dos requisitos do problema. A normalização deve ser aplicada separadamente em conjuntos de treinamento e teste para evitar vazamento de informações.

Abordagens para Dados Ausentes

Exclusão de Casos

- Viável se a proporção for pequena. Pode levar à **perda de informações** e introduzir viés se os dados ausentes não forem aleatórios.

Valor Fixo

- Preencher com média, mediana ou moda. Simples de implementar, mas pode **distorcer propriedades estatísticas**.

Valor Estimado

- Imputação por regressão, médias condicionais ou múltiplas imputações. Considera relações entre variáveis para **estimativas mais precisas**.

Modelagem Especializada

- Modelos de ML que consideram explicitamente a presença de dados ausentes, fornecendo **previsões mais precisas**.
- Não existe uma única estratégia correta para limpeza de dados. As decisões devem considerar o contexto do problema, o impacto nos resultados e os objetivos da análise. Documente e relate o tratamento adotado para garantir transparência e reprodutibilidade.

Transformação de Dados Categóricos e Numéricos

Dados Categóricos

- Atributos qualitativos: gênero, estado civil, tipo de produto, nível educacional. Possuem significado semântico próprio, mas **não carregam relação numérica implícita**. Precisam ser transformados sem introduzir relações artificiais.

Dados Numéricos

- Valores quantitativos contínuos ou discretos. Podem apresentar **escalas distintas, distribuições assimétricas** ou concentrações em intervalos. Exigem ajustes de distribuição, comparabilidade e interpretabilidade.

Desafios na Transformação de Categóricos

- A simples atribuição de números inteiros a categorias pode criar **ordens ou distâncias inexistentes**, levando modelos a inferir relações irrealistas.

Nominais

- Apenas rótulos distintos, sem hierarquia.

Ordinais

- Ordem natural entre valores (ex.: satisfação).

Alta Cardinalidade

- Grande variedade de rótulos aumenta complexidade.
- Categorias raras ou pouco representadas podem introduzir **ruídos ou instabilidades** no aprendizado. A análise de frequência e relevância é componente essencial do processo.

Transformação de Dados Numéricos

- Dados numéricos podem apresentar distribuições assimétricas, valores extremos ou concentrações em intervalos. A transformação busca **mitigar esses problemas** e atender a pressupostos dos métodos estatísticos.

Distribuição

- Muitos métodos assumem distribuição aproximadamente simétrica ou variância controlada.

Comparabilidade

- Diferenças de escala levam a interpretações enviesadas em análises multivariadas.

Interpretação

- Transformações podem tornar valores menos intuitivos – comunicação clara é essencial.

Impacto no ML e Responsabilidade Ética

- No contexto do machine learning, modelos treinados com dados mal transformados apresentam **desempenho instável**, dificuldade de convergência e resultados pouco interpretáveis. Dados bem transformados favorecem modelos mais robustos e confiáveis.

Eficiência do Aprendizado

- Dados transformados de forma coerente facilitam convergência dos algoritmos e melhoram a qualidade dos modelos resultantes.

Documentação

- Registrar critérios, transformações e justificativas garante reprodutibilidade e facilita manutenção de sistemas analíticos ao longo do tempo.

Dimensão Ética

- Decisões sobre representação de categorias ou ajuste de valores podem influenciar como grupos são retratados. Transformações inadequadas podem **reforçar vieses** ou mascarar desigualdades.

Padronização Organizacional

- Conjuntos preparados sistematicamente permitem análises comparáveis ao longo do tempo e facilitam atualização de modelos.

Interatividade

Analise as afirmações:

- I. A transformação de dados numéricos é uma etapa opcional, pois algoritmos modernos são totalmente independentes de escala e distribuição das variáveis.
- II. A documentação das transformações aplicadas aos dados é desnecessária, desde que o modelo apresente bom desempenho estatístico.
- III. Diferenças de escala entre variáveis podem gerar interpretações enviesadas em análises multivariadas, sendo necessária transformação adequada para garantir comparabilidade.
- IV. Decisões sobre transformação e representação dos dados podem influenciar a forma como grupos são retratados, exigindo responsabilidade ética e registro das escolhas realizadas.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e IV, apenas.
- d) I, III e IV, apenas.
- e) III e IV, apenas.

Resposta

Analise as afirmações:

- I. A transformação de dados numéricos é uma etapa opcional, pois algoritmos modernos são totalmente independentes de escala e distribuição das variáveis.
- II. A documentação das transformações aplicadas aos dados é desnecessária, desde que o modelo apresente bom desempenho estatístico.
- III. Diferenças de escala entre variáveis podem gerar interpretações enviesadas em análises multivariadas, sendo necessária transformação adequada para garantir comparabilidade.
- IV. Decisões sobre transformação e representação dos dados podem influenciar a forma como grupos são retratados, exigindo responsabilidade ética e registro das escolhas realizadas.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e IV, apenas.
- d) I, III e IV, apenas.
- e) III e IV, apenas.

Análise Exploratória de Dados (EDA)

- A Análise Exploratória de Dados (EDA – Exploratory Data Analysis) é uma etapa fundamental no processo de análise de dados e no desenvolvimento de modelos de machine learning. Seu principal objetivo é permitir que o analista **compreenda profundamente os dados** antes da aplicação de técnicas estatísticas avançadas ou algoritmos preditivos.
- A EDA atua como um momento de investigação inicial, no qual os dados são examinados de forma sistemática para revelar **padrões, comportamentos, tendências, anomalias e relações** que não são imediatamente evidentes.

EDA: Postura Investigativa e Aberta

- Diferentemente de abordagens estritamente confirmatórias, nas quais hipóteses são testadas a partir de modelos previamente definidos, a EDA assume uma **postura investigativa e aberta**. O analista não parte de suposições rígidas, mas busca observar os dados sob diferentes perspectivas, permitindo que as próprias informações sugiram caminhos de análise.
- Dados reais raramente se comportam de forma ideal. Eles podem conter **valores extremos, assimetrias, lacunas, erros de registro e padrões inesperados**. A EDA oferece mecanismos para identificar essas características antes de avançar para etapas mais complexas.

Por que a EDA é essencial?

- Evita interpretações equivocadas.
- Avalia a qualidade dos dados.
- Orienta pré-processamento e seleção de atributos.
- Reduz o risco de modelos inadequados.
- Apoia escolhas informadas ao longo do processo analítico.

Papel Estratégico da EDA no Machine Learning

- No contexto da ciência de dados, a EDA orienta decisões sobre pré-processamento, seleção de atributos e escolha de modelos. Um conjunto de dados mal compreendido pode levar à aplicação de técnicas inadequadas.
 - **Explorar Dados** - Entender distribuição e qualidade.
 - **Identificar Padrões** - Detectar relações e outliers.
 - **Selecionar Atributos** - Escolher variáveis mais relevantes.
 - **Escolher Modelos** - Avaliar candidatos e ajustar.
- A EDA fornece uma visão clara da estrutura e do comportamento dos dados, apoiando escolhas mais informadas e reduzindo riscos ao longo de todo o ciclo analítico.

Estatísticas Descritivas: Pilar da EDA

Tendência Central

- Indicam valores típicos ou representativos. Em distribuições assimétricas, um valor central pode não refletir a maioria das observações.

Dispersão

- Revelam a variabilidade das observações. Baixa variabilidade indica homogeneidade; alta variabilidade indica diversidade significativa.

Forma da Distribuição

- Distribuições simétricas, assimétricas ou concentradas influenciam a escolha de técnicas analíticas e a interpretação dos resultados.
- Essas medidas permitem resumir grandes volumes de dados em informações compreensíveis, servindo como ponto de partida para análises mais aprofundadas. Não devem ser interpretadas isoladamente, mas como parte de um conjunto de evidências.

Valores Extremos e Comparação entre Subconjuntos

Valores Atípicos (Outliers)

- Podem resultar de erros de registro, falhas na coleta ou representar eventos raros, mas significativos. A EDA permite identificá-los e avaliar seu impacto potencial.

Comparação entre Grupos

- Ao segmentar os dados com base em critérios específicos, o analista pode observar diferenças de comportamento entre grupos, identificando padrões relevantes ou discrepâncias significativas. Essa comparação inicial auxilia na formulação de hipóteses e orienta análises mais aprofundadas.
- A decisão de manter ou tratar valores extremos deve ser fundamentada no contexto do problema, evitando tanto a exclusão indiscriminada quanto a aceitação acrítica.

Visualização: Elemento Central da EDA

- Gráficos permitem visualizar os dados de forma intuitiva, explorando padrões que podem passar despercebidos em análises puramente numéricas. A visualização facilita a identificação de **tendências, agrupamentos, assimetrias e valores atípicos**.

Papel Cognitivo

- Permite ao analista perceber relações e comportamentos de forma mais imediata, auxiliando na formulação de hipóteses.

Comunicação

- Facilita o diálogo entre profissionais de diferentes áreas, promovendo compreensão compartilhada dos dados.

Cuidado Necessário

- Representações inadequadas podem induzir interpretações equivocadas. A escolha do gráfico deve estar alinhada aos objetivos da análise.

Natureza Iterativa e Controle de Qualidade

- A EDA raramente ocorre em um único ciclo linear. À medida que padrões são identificados ou anomalias observadas, **novas perguntas surgem**, demandando análises adicionais e diferentes perspectivas. Esse processo iterativo fortalece a base conceitual para etapas subsequentes.

Qualidade dos Dados

- Valores inconsistentes, registros duplicados e distribuições inesperadas podem ser detectados pela EDA, permitindo ajustes na limpeza e pré-processamento.

Relações entre Variáveis

- A observação de correlações orienta a seleção de atributos, identifica redundâncias e dependências, e reduz a complexidade dos modelos.

Padrões Temporais

- Quando há dimensões temporais, a EDA permite observar tendências, ciclos e mudanças abruptas de comportamento ao longo do tempo.

EDA: Da Exploração à Modelagem

Explorar

- Compreender distribuições, relações e anomalias nos dados.

Validar

- Avaliar adequação dos dados aos pressupostos dos algoritmos.

Interpretar

- Verificar se resultados dos modelos são coerentes e plausíveis.

Comunicar

- Transmitir informações complexas de forma acessível.
- A EDA não se limita ao início do processo analítico – ela influencia todas as etapas subsequentes, contribuindo para modelos mais confiáveis e decisões mais responsáveis. Ao compreender previamente o comportamento dos dados, o analista está melhor preparado para avaliar a plausibilidade dos resultados obtidos.

Postura Analítica Crítica

- Dados não produzem conhecimento de forma automática; é a análise cuidadosa e contextualizada que transforma informação em entendimento.
- O estudo da EDA contribui para o desenvolvimento de uma postura analítica **crítica e investigativa**. O estudante aprende a questionar os dados, buscar evidências empíricas e evitar conclusões precipitadas. Essa postura é essencial em ambientes orientados a dados, nos quais decisões dependem da interpretação correta das informações.
- A EDA é um processo **humano-centrado**: embora ferramentas computacionais automatizem cálculos e visualizações, a compreensão dos padrões e a formulação de hipóteses dependem do raciocínio analítico do profissional.

Integração: Estatísticas + Gráficos

- **Estatísticas** - Fornecem resumos quantitativos que sintetizam o comportamento geral dos dados. Valores centrais, medidas de dispersão e indicadores de forma oferecem pistas sobre a estrutura dos dados.
- **Gráficos** - Permitem observar nuances, padrões e irregularidades que dificilmente seriam captados apenas por números. Tendências, agrupamentos e valores atípicos tornam-se mais evidentes.

Complementaridade Essencial

- A interpretação estatística exige sempre a **consideração do contexto e a verificação visual** dos dados, evitando conclusões precipitadas baseadas em resumos numéricos simplificados.
- Gráficos na EDA são **ferramentas de exploração**, não resultados finais. Permitem formular hipóteses e questionar suposições iniciais. Representações mal escolhidas podem enfatizar aspectos irrelevantes ou mascarar padrões importantes.
- A EDA não se resume à geração de gráficos, mas à análise consciente de como eles representam os dados e quais conclusões podem ser legitimamente extraídas.

O Papel da Visualização na Análise de Dados

- Em ambientes orientados a dados, a capacidade de representar informações de forma visual é essencial para a compreensão de padrões, tendências e anomalias. A visualização não é meramente estética – desempenha um **papel cognitivo fundamental** ao apoiar o raciocínio analítico.

Ponte Cognitiva

- Gráficos exploram a capacidade visual humana de identificar formas, variações e relações espaciais, transformando dados brutos em conhecimento.

Comunicação Eficaz

- Gráficos bem elaborados facilitam a compreensão por diferentes públicos, incluindo gestores, clientes e equipes multidisciplinares.

Reprodutibilidade

- Visualizações geradas por código podem ser reproduzidas, ajustadas e integradas a relatórios de forma sistemática e documentada.

Matplotlib: Flexibilidade e Controle

- O Matplotlib ocupa posição central no ecossistema Python. Sua importância decorre de sua concepção como ferramenta **flexível e de baixo nível**, capaz de oferecer controle detalhado sobre praticamente todos os elementos de uma visualização.

Construção Gradual

- O analista define e ajusta cada componente: eixos, escalas, rótulos, cores e estilos. Essa abordagem favorece a compreensão profunda do processo de visualização.

Personalização Total

- Permite investigar distribuições, tendências e comportamentos específicos. Particularmente útil quando os dados apresentam características atípicas.

Base do Ecossistema

- Funciona como infraestrutura para diversas ferramentas de nível mais alto, incluindo o Seaborn, permitindo ajustes e refinamentos quando necessário.

Seaborn: Foco Estatístico e Simplicidade

- O Seaborn foi desenvolvido com foco específico em **gráficos estatísticos** e na integração com estruturas de dados tabulares. Oferece abstrações de alto nível que simplificam a criação de visualizações informativas, permitindo que o analista concentre-se na interpretação.

Integração com Dados Tabulares

- Trabalha diretamente com DataFrames, facilitando a criação de gráficos que evidenciam distribuições, comparações entre grupos e associações entre variáveis.

Relações Estatísticas

- Incorpora conceitos estatísticos diretamente nas visualizações, favorecendo a interpretação analítica e a formulação de hipóteses durante a EDA.

Padrões Visuais Consistentes

- Oferece padrões visuais adequados à representação estatística, contribuindo para a clareza mesmo quando utilizado por analistas com menor experiência gráfica.

Matplotlib vs. Seaborn: Complementaridade

- A escolha entre as ferramentas não deve ser vista como excludente, mas como **complementar**. Em muitos projetos, ambas são utilizadas em conjunto.

Matplotlib

- Controle detalhado e flexibilidade máxima. Ideal para ajustes finos e personalizações específicas.

Seaborn

- Abstração, consistência visual e foco estatístico. Ideal para exploração inicial rápida e iterativa.
- A escolha deve considerar o **tipo de dado**, o **objetivo da análise**, o **público-alvo** e o **nível de personalização** desejado. Ambas ampliam a capacidade cognitiva do analista ao tornar os dados mais acessíveis e interpretáveis.

Considerações éticas:

- Gráficos podem influenciar significativamente a percepção dos dados. Representações inadequadas podem exagerar diferenças ou ocultar variações relevantes. O uso responsável exige atenção aos princípios de clareza, honestidade e proporcionalidade.

Interatividade

Analise as afirmações:

- I. A EDA é uma etapa exclusivamente confirmatória, voltada apenas à validação de hipóteses previamente definidas por modelos estatísticos formais.
- II. A EDA assume uma postura investigativa e aberta, permitindo identificar padrões, anomalias e relações antes da aplicação de modelos preditivos.
- III. A visualização de dados possui função meramente estética, não exercendo influência na interpretação ou na formulação de hipóteses analíticas.
- IV. Estatísticas descritivas e gráficos são abordagens complementares na EDA, pois os resumos numéricos devem ser analisados com a verificação visual dos dados.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e III, apenas.
- d) I, II e IV, apenas.
- e) II e IV, apenas

Resposta

Analise as afirmações:

- I. A EDA é uma etapa exclusivamente confirmatória, voltada apenas à validação de hipóteses previamente definidas por modelos estatísticos formais.
- II. A EDA assume uma postura investigativa e aberta, permitindo identificar padrões, anomalias e relações antes da aplicação de modelos preditivos.
- III. A visualização de dados possui função meramente estética, não exercendo influência na interpretação ou na formulação de hipóteses analíticas.
- IV. Estatísticas descritivas e gráficos são abordagens complementares na EDA, pois os resumos numéricos devem ser analisados com a verificação visual dos dados.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e III, apenas.
- d) I, II e IV, apenas.
- e) II e IV, apenas

Referências

- FERREIRA, Rafael Gastão Coimbra. *Preparação e análise exploratória de dados*. Porto Alegre: SAGAH, 2021.
- GOLDSCHMIDT, Ronaldo; PASSOA, Emmanuel; BEZERRA, Eduardo. *Data mining*. Rio de Janeiro: Elsevier, 2015.
- GRUS, Joel. *Data science do zero: noções fundamentais com Python*. Rio de Janeiro: Alta Books, 2021.
- LENZ, Maikon Lucian; NEUMANN, Fabiano Berlinck; SANTARELLI, Rodrigo; SALVADOR, Douglas. *Fundamentos de aprendizagem de máquina*. Porto Alegre: SAGAH, 2020.
- PADILHA, Juliana; SOARES, Juliane Adélia; ALVES, Nicolli Souza Rios; ABREU, Eduardo Melione; SILVA, Fernanda Rosa da; MORAIS, Myllena Silva de Freitas; LACERDA, Paulo Sérgio Pádua de; MAITINO NETO, Roque; MACHADO, Victor de Andrade. *Analytics para big data*. Porto Alegre: SAGAH, 2022.
- WAZLAWICK, Raul S. *Introdução a algoritmos e programação com Python: uma abordagem dirigida por testes*. Grupo GEN, 2018.

ATÉ A PRÓXIMA!