



UNIDADE II

Machine Learning e Análise de Dados

Profa. Dra. Vanessa Lessa

Algoritmos Supervisionados de Machine Learning

- Os algoritmos supervisionados de machine learning utilizam **conjuntos de dados rotulados**, nos quais as entradas estão associadas a saídas conhecidas. Essa classe de algoritmos aprende relações entre variáveis explicativas e uma variável alvo, possibilitando **previsões numéricas** (regressão) e **decisões categóricas** (classificação).
- São ferramentas essenciais para apoio à tomada de decisão em diferentes áreas, desempenhando papel central na análise de dados moderna.

Regressão Linear Simples

- A regressão linear simples busca estabelecer uma **relação linear entre duas variáveis**: uma dependente (alvo) e uma independente (entrada). O objetivo é encontrar a melhor reta que representa essa relação.

$$y = \beta_0 + \beta_1 x$$

Componentes da Equação

- y — variável dependente (a que queremos prever)
- x — variável independente (usada para previsão)
- β_0 — intercepto (valor de y quando $x = 0$)
- β_1 — inclinação (mudança em y por unidade de x)

Método dos Mínimos Quadrados

- O método mais utilizado para estimar β_0 e β_1 busca **minimizar a soma dos quadrados dos resíduos** – as diferenças entre valores reais e previstos. Uma vez treinado, o modelo prevê y para novos valores de x .

Coeficiente de Correlação e Pressupostos

- Além da previsão, a regressão linear simples avalia a **força e direção** da relação entre variáveis por meio do coeficiente de correlação (r), que varia de -1 a 1.

$r = -1$

- Relação negativa perfeita

$r = 0$

- Ausência de relação linear

$r = +1$

- Relação positiva perfeita

- Pressupostos importantes: linearidade da relação, independência dos erros, homoscedasticidade (variância constante dos erros) e normalidade dos erros. Violar essas suposições pode levar a resultados imprecisos ou inválidos.

Vantagens da Regressão Linear Simples

Interpretabilidade

- Os coeficientes β_0 e β_1 fornecem informações claras sobre intercepto e inclinação, permitindo entender direção e magnitude da relação.

Facilidade de Implementação

- Amplamente disponível em bibliotecas como scikit-learn, com muitos pacotes que facilitam a implementação em projetos de análise.

Eficiência Computacional

- Método computacionalmente leve, capaz de analisar grandes conjuntos de dados em tempo razoável.

Base para Modelos Complexos

- Serve como fundamento para regressão múltipla e modelos avançados de aprendizado de máquina.


Exemplo Prático: Horas de Estudo × Notas

Usando scikit-learn, treinamos um modelo para prever notas com base em horas de estudo. Os coeficientes obtidos foram:

- **Coef. Angular = 3.69** (Cada hora adicional de estudo aumenta a nota em ~3,69 pontos)
- **Coef. Linear = 58.4** (Nota estimada quando horas de estudo = 0)

Tabela de dados:

Horas de Estudo	Notas do Exame
2	65
4	75
6	80
7	82
8	90
10	95



Limitações da Regressão Linear Simples

Pressuposições Rígidas

- Assume relação linear e independência dos erros. Se não atendidas, os resultados podem ser inválidos ou imprecisos.

Sensibilidade a Outliers

- Valores atípicos podem influenciar significativamente a estimativa dos coeficientes e distorcer a reta de regressão.

Complexidade Limitada

- Incapaz de capturar relações não lineares entre variáveis. Se a relação não for linear, os resultados serão inadequados.

Dependência da Qualidade dos Dados

- Dados ausentes, erros de medição ou inconsistências comprometem a precisão das previsões.

Princípios Avançados da Regressão Linear

- A regressão linear vai além da simples previsão. Ela é a **base conceitual** para métodos mais complexos de machine learning, introduzindo conceitos como função de custo, erro, ajuste de parâmetros e generalização.

Regressão Múltipla

- Quando a complexidade aumenta, múltiplas variáveis explicativas são incorporadas simultaneamente, ampliando o poder explicativo mas introduzindo desafios como a **multicolinearidade** – quando variáveis independentes apresentam forte relação entre si.

Modelo como Baseline

- No machine learning, a regressão linear serve como **referência**. Se modelos avançados não a superam significativamente, a relação pode ser simples ou os dados insuficientes.

Ajuste, Erro e Análise de Resíduos

- O processo de ajuste busca parâmetros que minimizem os desvios entre valores observados e estimados. A **análise dos resíduos** é fundamental para avaliar a adequação do modelo.

Ajuste do Modelo

- Minimizar a soma dos quadrados dos erros de forma sistemática.

Análise de Resíduos

- Padrões nos resíduos indicam se a estrutura linear é adequada.

Validação

- Integrar critérios estatísticos com conhecimento do domínio.

Lembrete:

- Um bom desempenho no conjunto de treinamento não garante que o modelo funcionará bem em dados novos. Avaliar a **capacidade de generalização** é essencial para evitar modelos que apenas memorizaram os dados históricos.

Aplicações Práticas da Regressão Linear

Economia e Finanças

- Análise da influência de fatores sobre custos, receitas e indicadores de desempenho para apoio ao planejamento estratégico.

Engenharia e Tecnologia

- Modelagem de processos, estimativa de parâmetros e avaliação de desempenho de sistemas operacionais.

Séries Temporais

- Identificação de tendências ao longo do tempo como ferramenta exploratória e preliminar.
- A regressão linear é aplicada em estatística, ciências sociais, administração e tecnologia da informação – sua versatilidade decorre da combinação entre **simplicidade**, **interpretabilidade** e **capacidade preditiva**.

Cuidados Essenciais na Aplicação

- **Associação $\neq$ Causalidade**

- A regressão quantifica relações, mas não implica que uma variável cause a outra. Inferência causal exige contexto e desenho de estudo adequados.

Qualidade dos Dados

- Dados ruidosos, inconsistentes ou mal preparados comprometem o modelo. A integração com EDA e limpeza é fundamental.

Processo Iterativo

- A regressão linear não deve ser aplicada isoladamente, mas como parte de um ciclo analítico que inclui exploração, modelagem e validação.

Conceito e Função Sigmoid

- Apesar do nome “regressão”, a regressão logística é um **modelo de classificação**. Ela estima a probabilidade de um evento pertencer a uma de duas categorias, utilizando a **função sigmoide** para mapear valores no intervalo $[0,1]$.

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_n X_n)}}$$

Componentes

- p — probabilidade do evento ocorrer
- $\beta_0 \dots \beta_n$ — coeficientes (pesos) estimados por máxima verossimilhança
- $X_1 \dots X_n$ — variáveis independentes

Interpretação

- Os coeficientes mostram a razão de chances (**odds ratio**): quanto à chance de um evento acontecer, aumenta ou diminui quando uma variável cresce uma unidade, mantendo todas as outras constantes.

Limiar de Decisão e Tipos de Erro

- A tomada de decisão envolve definir um **limiar de probabilidade** que transforma a estimativa contínua em classificação categórica. A escolha desse limiar influencia diretamente o equilíbrio entre tipos de erro.

Limiar Baixo

- Mais sensível — identifica mais positivos, mas aumenta falsos positivos.

Limiar Alto

- Mais específico — reduz falsos positivos, mas pode perder positivos reais.
- Essa flexibilidade torna a regressão logística adequada para aplicações sensíveis como **diagnóstico médico, detecção de fraudes e concessão de crédito**, onde os custos de diferentes erros são assimétricos.

Aplicações Reais da Regressão Logística

Saúde

- Estimativa de probabilidade de doenças, avaliação de fatores de risco e apoio ao diagnóstico clínico.

Finanças

- Concessão de crédito, detecção de fraudes e avaliação de risco de inadimplência.

Marketing

- Modelagem de comportamento do cliente: propensão de compra, cancelamento e resposta a campanhas.

Tecnologia da Informação

- Filtragem de conteúdo, detecção de spam e classificação automática em sistemas dinâmicos.

Interatividade

Analise as afirmações:

- I. A regressão linear simples é capaz de modelar adequadamente todo tipo de relação entre variáveis, inclusive relações não lineares complexas, sem precisar de ajustes adicionais.
- II. Na regressão logística, os coeficientes são interpretados diretamente como probabilidades finais do evento ocorrer.
- III. A regressão linear utiliza o método dos mínimos quadrados para minimizar a soma dos quadrados dos resíduos, buscando a melhor reta de ajuste aos dados.
- IV. A regressão logística é um modelo de classificação que utiliza a função sigmoide para estimar probabilidades no intervalo entre 0 e 1, sendo adequada para problemas binários.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e IV, apenas.
- d) I, III e IV, apenas.
- e) III e IV, apenas.

Resposta

Analise as afirmações:

- I. A regressão linear simples é capaz de modelar adequadamente todo tipo de relação entre variáveis, inclusive relações não lineares complexas, sem precisar de ajustes adicionais.
- II. Na regressão logística, os coeficientes são interpretados diretamente como probabilidades finais do evento ocorrer.
- III. A regressão linear utiliza o método dos mínimos quadrados para minimizar a soma dos quadrados dos resíduos, buscando a melhor reta de ajuste aos dados.
- IV. A regressão logística é um modelo de classificação que utiliza a função sigmoide para estimar probabilidades no intervalo entre 0 e 1, sendo adequada para problemas binários.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e IV, apenas.
- d) I, III e IV, apenas.
- e) III e IV, apenas.

O que é uma Árvore de Decisão?

- A árvore de decisão é um modelo de aprendizado de máquina que representa uma **estrutura hierárquica de decisões** e suas possíveis consequências. É utilizada para problemas de **classificação e regressão**, em que o objetivo é tomar decisões ou prever valores com base em atributos dos dados.

Nós

- Representam as características dos dados avaliadas em cada etapa.

Arestas


- Representam as decisões tomadas com base nas características.

Folhas

- Representam as classes ou valores de saída finais.

Exemplo: Árvore de "Adivinhação" de Animais

A construção da árvore envolve a seleção de características relevantes e a definição de regras de decisão que dividem os dados em subconjuntos mais puros. Veja um exemplo lúdico de árvore de decisão para adivinhar animais:



Fonte:
Adaptado de:
Grus (2016,
p. 231)

Algoritmos e Critérios de Construção

- A construção de uma árvore de decisão é baseada em algoritmos que buscam encontrar a **melhor divisão dos dados** em cada nó, considerando critérios de pureza e homogeneidade.

Algoritmos Principais

- ID3 — Iterative Dichotomiser 3
- C4.5 — Evolução do ID3
- CART — Classification and Regression Trees
- Random Forest — Conjunto de árvores

Critérios de Divisão

- **Ganho de informação** – mede a redução de entropia
- **Índice de Gini** – mede a impureza dos subconjunto
- **Erro quadrático médio** – usado em problemas de regressão
- Quanto mais homogêneo o subconjunto resultante, mais adequada é a divisão.

Vantagens e Limitações

Vantagens

- Interpretabilidade – regras facilmente compreensíveis
- Lida com dados numéricos e categóricos
- Aplicável a problemas com várias classes
- Fornece insights sobre padrões nos dados

Limitações

- Overfitting – sensível a variações nos dados de treinamento
 - Alta variância – pequenas mudanças geram árvores diferentes
 - Complexidade excessiva – muitos nós reduzem generalização
 - Pode capturar ruídos em vez de padrões reais
-
- Para mitigar esses problemas, aplicam-se técnicas como **poda da árvore (pruning)** e a combinação de várias árvores em conjuntos, como no **Random Forest**.

Exemplo Prático: Dataset Iris com Scikit-learn

- Utilizando o conjunto de dados de flores Iris, podemos criar uma árvore de decisão para prever a classe das flores com base em quatro características: comprimento e largura da sépala, comprimento e largura da pétala. As classes são: **Iris setosa**, **Iris versicolor** e **Iris virginica**.

Base de dados das Flores de Íris

Iris flower dataset

Setosa



Versicolor



Virginica



Fonte: <https://x.gd/welJ5>

Construção de Árvores de Decisão

- As árvores de decisão são um dos modelos mais intuitivos do aprendizado de máquina supervisionado. Sua popularidade decorre da **facilidade de interpretação** e da proximidade com o processo humano de tomada de decisão. Diferentemente de métodos "caixa-preta", as árvores permitem **visualizar explicitamente** as regras utilizadas para dividir o espaço de dados.

O Processo de Particionamento

- A construção ocorre de maneira **iterativa e recursiva**. O algoritmo busca, a cada etapa, a divisão que melhor separa os dados segundo um critério de pureza.
 - Repetição
 - Particionar
 - Avaliar Divisões
 - Nó Raiz
- Quanto mais homogêneo for um subconjunto em relação à variável alvo, mais adequada é considerada a divisão. Em **classificação**, busca-se folhas com predominância de uma classe; em **regressão**, valores semelhantes da variável dependente.

Interpretação: Regras "Se-Então"

Cada caminho da raiz até uma folha pode ser interpretado como uma **regra do tipo "se-então"**, em que condições sobre os atributos conduzem a uma decisão final. Essa representação:

- Facilita a compreensão do modelo por não especialistas.
- Permite que especialistas validem a coerência das regras.
- Complementa a avaliação quantitativa com validação qualitativa.
- Atributos utilizados próximos à **raiz** exercem mais influência, pois afetam um grande número de observações.

O Desafio do Sobreajuste (Overfitting)

- Árvores muito profundas podem se ajustar excessivamente aos dados de treinamento, capturando ruídos em vez de padrões reais. Esse fenômeno compromete a capacidade de generalização.

Modelo Muito Simples

- Não captura padrões importantes (underfitting).

Modelo Equilibrado

- Captura padrões relevantes sem memorizar ruídos.

Modelo Muito Complexo

- Memoriza dados de treinamento, falha em novos dados (overfitting).
- A Análise Exploratória de Dados (EDA) é essencial para definir a complexidade adequada, compreendendo distribuição de atributos, ruídos e equilíbrio entre classes.

Limitações e Uso Responsável

Instabilidade

- Pequenas alterações nos dados podem gerar árvores significativamente diferentes.

Vieses

- Decisões automatizadas podem reproduzir ou amplificar vieses dos dados históricos.

Regras Frágeis

- Regras baseadas em subconjuntos muito pequenos podem não ser representativas.

Qualidade dos Dados

- Dados ruidosos ou mal preparados geram regras pouco robustas.
- A transparência do modelo facilita a identificação de vieses, mas não elimina a necessidade de uma análise cuidadosa dos dados e das decisões.

Random Forest: Combinando Múltiplas Árvores

- O **Random Forest** representa um avanço significativo ao introduzir uma abordagem baseada em **métodos de ensemble**: a combinação de múltiplas árvores de decisão para superar limitações de modelos individuais, como sobreajuste e instabilidade, obtendo previsões mais robustas e com maior capacidade de generalização.
- O princípio fundamental consiste na construção de um conjunto de árvores de decisão, cada uma treinada a partir de amostras e atributos diferentes, gerando diversidade.

Amostragem aleatória

- Cada árvore é treinada com uma amostra diferente dos dados originais.

Seleção de atributos

- Em cada divisão, apenas um subconjunto aleatório de atributos é considerado.

Agregação

- Classificação: votação majoritária. Regressão: média das estimativas.
- Essa **dupla fonte de aleatoriedade** reduz a correlação entre as árvores, aumentando a diversidade e a eficácia da agregação. Quando os erros de diferentes árvores não estão correlacionados, a agregação tende a compensá-los.

Por que o Random Forest é Mais Preciso?

Redução de variância

- Árvores individuais têm alta variância. Ao combinar múltiplas árvores, o Random Forest suaviza flutuações, pois erros de uma árvore são compensados por outras.

Diversidade dos modelos

- A aleatoriedade na amostragem e na seleção de atributos garante que as árvores capturem aspectos distintos dos dados, ampliando a representação de relações complexas.

Robustez a ruídos

- O mecanismo de agregação reduz o impacto de observações extremas que afetam apenas algumas árvores, contribuindo para previsões mais estáveis.

Generalização

- Evita que o aprendizado seja excessivamente influenciado por particularidades dos dados de treinamento, apresentando desempenho consistente em novos dados.

Importância dos Atributos

Embora o Random Forest como um todo seja menos transparente que uma árvore individual, é possível analisar a relevância dos atributos utilizados nas divisões:

- A frequência de uso e a posição na árvore indicam relevância.
- Atributos próximos à raiz exercem maior influência.
- Pode ser usado como ferramenta exploratória complementar à EDA.
- **Atenção:** Atributos correlacionados podem compartilhar importância. A interpretação deve ser integrada ao conhecimento do domínio, evitando conclusões simplistas.

Limitações e Considerações Éticas

Interpretabilidade reduzida

- A estrutura completa do modelo não pode ser representada de forma simples como uma árvore individual

Custo computacional

- Construção de muitas árvores demanda recursos significativos, especialmente em grandes conjuntos de dados

Vieses nos dados

- Melhorar a precisão não garante decisões justas – o modelo pode reproduzir ou amplificar vieses históricos

Correlação de atributos

- A importância de variáveis pode ser afetada por correlações, exigindo interpretação cuidadosa e integrada ao domínio

Interatividade

Analise as afirmações:

- I. As árvores de decisão realizam particionamentos recursivos dos dados com base em critérios de pureza, como ganho de informação ou índice de Gini, buscando formar subconjuntos mais homogêneos em relação à variável alvo.
- II. O Random Forest reduz a variância do modelo ao combinar múltiplas árvores treinadas com amostras e subconjuntos de atributos diferentes, utilizando agregação por votação majoritária (classificação) ou média (regressão).
- III. O Random Forest elimina completamente o risco de overfitting, garantindo sempre desempenho perfeito em novos dados, independentemente da qualidade do conjunto de treinamento.
- IV. A principal vantagem das árvores de decisão é sua alta estabilidade, pois pequenas alterações nos dados de treinamento não impactam significativamente a estrutura da árvore gerada.

Está correto o que se afirma em:

- a) I e III, apenas.
- b) II e IV, apenas.
- c) I, II e III, apenas.
- d) III e IV, apenas.
- e) I e II, apenas.

Resposta

Analise as afirmações:

- I. As árvores de decisão realizam particionamentos recursivos dos dados com base em critérios de pureza, como ganho de informação ou índice de Gini, buscando formar subconjuntos mais homogêneos em relação à variável alvo.
- II. O Random Forest reduz a variância do modelo ao combinar múltiplas árvores treinadas com amostras e subconjuntos de atributos diferentes, utilizando agregação por votação majoritária (classificação) ou média (regressão).
- III. O Random Forest elimina completamente o risco de overfitting, garantindo sempre desempenho perfeito em novos dados, independentemente da qualidade do conjunto de treinamento.
- IV. A principal vantagem das árvores de decisão é sua alta estabilidade, pois pequenas alterações nos dados de treinamento não impactam significativamente a estrutura da árvore gerada.

Está correto o que se afirma em:

- a) I e III, apenas.
- b) II e IV, apenas.
- c) I, II e III, apenas.
- d) III e IV, apenas.
- e) I e II, apenas.

O Que São Algoritmos Não Supervisionados?

- Os algoritmos não supervisionados constituem uma abordagem fundamental para a análise de dados em cenários sem rótulos previamente definidos. Diferentemente dos métodos supervisionados, eles buscam identificar padrões, agrupamentos e relações internas a partir das características dos próprios dados, revelando informações ocultas e comportamentos emergentes.

Exploração

- Tarefas exploratórias sem conhecimento prévio de classes.

Segmentação

- Divisão de dados em grupos homogêneos.

Descoberta

- Compreensão da complexidade de grandes conjuntos de dados.

Fundamentos do Clustering

- O clustering, ou agrupamento de dados, é uma das abordagens centrais do aprendizado não supervisionado. Ele organiza dados com base em similaridade interna, revelando agrupamentos naturais que emergem das características observadas – sem a necessidade de rótulos prévios.

Por que usar Clustering?

- Exploração inicial de grandes volumes de informação.
- Identificação de padrões recorrentes e geração de hipóteses.
- Interpretação de conjuntos de dados complexos e heterogêneos.
- Redução da complexidade para análises subsequentes.

Conceito Central

- Observações que compartilham características semelhantes são agrupadas, enquanto observações diferentes são separadas. A escolha das métricas de similaridade influencia diretamente os resultados.

O Algoritmo K-Means

- O K-Means é um dos métodos mais populares para segmentação de dados. Sua popularidade decorre da simplicidade conceitual, da eficiência computacional e da facilidade de implementação. Ele representa cada grupo por um ponto central – o centroide – e busca minimizar a distância entre as observações e seus respectivos centroides.

Como o K-Means Funciona

1. Definir K

- Escolha o número de clusters desejados – quantos grupos os dados serão divididos.

2. Inicializar Centroides

- Selecione aleatoriamente K pontos iniciais como centros dos clusters.

3. Atribuir Amostras

- Cada amostra é atribuída ao cluster cujo centroide está mais próximo (distância Euclidiana).

4. Recalcular

- Os centroides são recalculados com base nas amostras atribuídas a cada cluster.

5. Convergir

- Repita os passos 3 e 4 até que não ocorram mais mudanças nas atribuições.


Inércia e Objetivo do K-Means

Minimizando a Inércia

- O objetivo do K-Means é minimizar a soma dos quadrados das distâncias entre as amostras e seus centroides correspondentes. Essa métrica é chamada de inércia e representa a coesão dentro de cada cluster.
- Quanto menor a inércia, mais compactos e bem-definidos são os clusters. É comum executar o algoritmo várias vezes com diferentes inicializações e selecionar a solução com a menor inércia.

Resultado: K-Means Clustering – Base Iris

- Utilizando a biblioteca Scikit-learn, aplicamos o K-Means na base de dados Iris com 3 clusters (correspondendo às 3 classes de flores). O algoritmo agrupa os dados sem conhecimento dos rótulos reais.
- Gráfico K-Means clustering. As amostras são plotadas de acordo com os rótulos dos clusters encontrados (roxo, amarelo e verde-azulado). Os centros dos clusters são marcados com X vermelho. Embora haja boa separação, a correspondência com as classes reais pode não ser perfeita, já que o K-Means não tem conhecimento dos rótulos originais.



Características e Pressupostos do K-Means

Rápido e Escalável

- Adequado para grandes conjuntos de dados. Agrupamento rígido: cada amostra pertence exclusivamente a um cluster.

Clusters Esféricos

- Pressupõe clusters de formato aproximadamente esférico e tamanho semelhante. Pode não ser eficaz com formas irregulares.

Sensível à Inicialização

- O resultado pode variar conforme a posição inicial dos centroides. Recomenda-se executar múltiplas vezes.

Escolha de K

- O número de clusters deve ser fornecido pelo usuário, exigindo conhecimento do domínio e análise cuidadosa dos dados.

K-Means para Segmentação de Dados

Distância, Similaridade e Formação de Grupos

- A compreensão do K-Means exige reflexão sobre os conceitos de distância, similaridade e formação de grupos no espaço de dados. Observações próximas são consideradas semelhantes e tendem a ser agrupadas no mesmo cluster.

Espaço Multidimensional

- Cada dimensão corresponde a um atributo do conjunto de dados.

Dispersão Interna

- O algoritmo minimiza a dispersão dentro de cada cluster.

Convergência

- Ocorre quando não há mais mudanças significativas nas atribuições.
- Preparação essencial: a normalização e padronização dos atributos são necessárias para que todas as variáveis contribuam de forma equilibrada para o cálculo das distâncias. Sem isso, atributos com escalas maiores podem dominar o agrupamento.

K-Means como Ferramenta Exploratória

- Na análise exploratória de dados, o K-Means é frequentemente utilizado como ferramenta inicial para identificar padrões e estruturas. Ao aplicar o algoritmo com diferentes números de clusters, o analista observa como os dados se organizam e avalia a coerência dos agrupamentos.
 - Revela estruturas ocultas não identificáveis por análises tradicionais.
 - Orienta a formulação de hipóteses para investigações posteriores.
 - Reduz a complexidade em cenários de big data.
 - Pode servir como etapa preparatória para métodos supervisionados.

Integração com Análise Exploratória de Dados (EDA)

- A EDA orienta a aplicação do clustering, enquanto os resultados do K-Means retroalimentam a exploração e a preparação dos dados. Essa interação evidencia a natureza iterativa do processo analítico.

Aplicações de Clustering em Análise de Dados

- O clustering é utilizado em diversos domínios para revelar estruturas latentes, identificar padrões recorrentes e apoiar processos decisórios baseados em dados.

Marketing e Clientes

- Segmentação de consumidores por comportamento de compra, frequência e preferências para campanhas mais eficazes.

Ciência e Pesquisa

- Agrupamento de amostras em biologia, química e ciências ambientais para descoberta de padrões naturais.

Tecnologia da Informação

- Análise de logs, segmentação de usuários e detecção de comportamentos anômalos em sistemas.

Segurança e Fraudes

- Detecção de anomalias e outliers em dados financeiros, monitoramento de sistemas críticos.

Clustering no Mundo dos Negócios

Segmentação de Clientes

- Identificação de perfis distintos de comportamento, consumo e preferência para personalização de ofertas e otimização de recursos.

Análise de Desempenho

- Agrupamento de unidades e processos com comportamentos semelhantes para identificar áreas de excelência e pontos de melhoria.

Gestão de Produtos

- Identificação de grupos com características semelhantes em desempenho e aceitação, orientando desenvolvimento e portfólio.

Clustering em Ciência e Tecnologia

Dados Biológicos

- Agrupamento de amostras para compreensão de estruturas genéticas, padrões de expressão e comportamentos celulares.

Estudos Ambientais

- Agrupamento de regiões com características climáticas, ecológicas ou demográficas semelhantes para políticas públicas.

Detecção de Anomalias

- Identificação de padrões normais para detectar desvios significativos em segurança, finanças e monitoramento de sistemas.

Limitações e Cuidados com o K-Means

Formato dos Clusters

- Assume clusters esféricos e de tamanho semelhante – pode falhar com formas irregulares.

Valores Extremos

- Outliers influenciam significativamente a posição dos centroides, distorcendo os resultados.

Avaliação Difícil

- Sem rótulos de referência, a avaliação depende de coerência interna e utilidade prática.

Ética e Viés

- A segmentação de indivíduos pode gerar estigmatizações. Transparência e reflexão crítica são essenciais.
- **Lembrete:** Algoritmos não supervisionados ajudam a explorar os dados, mas não fornecem respostas prontas. A interpretação dos resultados depende do contexto e da análise humana. Os agrupamentos não possuem significado automático.

Integração: Clustering + Aprendizado Supervisionado

- O K-Means não é uma técnica isolada – ele se integra ao ciclo completo de análise de dados, ampliando o potencial analítico quando combinado com métodos supervisionados.

EDA e Preparação

- Exploração inicial orienta atributos e transformações.

Clustering

- Segmentação revela grupos homogêneos nos dados.

Modelos Específicos

- Modelos preditivos refinados para cada segmento.

Decisão Informada

- Soluções mais eficazes e adaptadas ao contexto.

Interatividade

Analise as afirmações:

- I. O K-Means é um algoritmo supervisionado que depende de rótulos previamente definidos para ajustar os centroides e minimizar o erro de classificação.
- II. O clustering garante automaticamente que agrupamentos encontrados correspondam exatamente às categorias reais existentes nos dados, mesmo sem rótulos disponíveis.
- III. O K-Means busca minimizar a soma dos quadrados das distâncias entre as amostras e seus centroides, métrica conhecida como inércia, formando clusters mais compactos.
- IV. A aplicação do K-Means exige atenção à normalização dos dados, pois atributos em escalas diferentes podem influenciar desproporcionalmente o cálculo das distâncias.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e IV, apenas.
- d) III e IV, apenas.
- e) I, III e IV, apenas.

Resposta

Analise as afirmações:

- I. O K-Means é um algoritmo supervisionado que depende de rótulos previamente definidos para ajustar os centroides e minimizar o erro de classificação.
- II. O clustering garante automaticamente que agrupamentos encontrados correspondam exatamente às categorias reais existentes nos dados, mesmo sem rótulos disponíveis.
- III. O K-Means busca minimizar a soma dos quadrados das distâncias entre as amostras e seus centroides, métrica conhecida como inércia, formando clusters mais compactos.
- IV. A aplicação do K-Means exige atenção à normalização dos dados, pois atributos em escalas diferentes podem influenciar desproporcionalmente o cálculo das distâncias.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) I e III, apenas.
- c) II e IV, apenas.
- d) III e IV, apenas.
- e) I, III e IV, apenas.

O que é a Análise de Componentes Principais?

- A PCA (Principal Component Analysis) é uma das técnicas mais importantes na análise de dados multivariados. Seu principal objetivo é reduzir a dimensionalidade de conjuntos de dados complexos, preservando o máximo possível da informação original.
- A técnica transforma variáveis originais em um novo conjunto de variáveis – os componentes principais – construídos para capturar a maior variabilidade presente nos dados. Em vez de analisar variáveis correlacionadas diretamente, a PCA cria combinações lineares que revelam padrões globais de variação.

Por que Reduzir Dimensionalidade?

- Com o avanço de sistemas, sensores e aplicações digitais, é cada vez mais comum trabalhar com bases contendo dezenas, centenas ou milhares de atributos. Essa alta dimensionalidade dificulta a análise, a visualização e a modelagem dos dados.

Excesso de variáveis

- Bases com centenas de atributos tornam a análise complexa e custosa.

Dificuldade de visualização

- Dados em alta dimensão não podem ser representados graficamente de forma direta.

Risco de sobreajuste

- Modelos com muitos atributos tendem a capturar ruído em vez de padrões reais.

Variância como Medida de Informação

- A motivação conceitual da PCA está diretamente associada à ideia de que **dimensões com maior variabilidade carregam mais informação relevante**. A técnica identifica direções no espaço dos dados ao longo das quais a variância é maximizada.
- Essas direções correspondem aos componentes principais, que fornecem uma nova base para representar os dados de maneira mais compacta e informativa. O primeiro componente explica a maior parte da variância total; o segundo, ortogonal ao primeiro, explica a maior parte da variância residual – e assim sucessivamente.

Pilares estatísticos: Variância, Covariância e Correlação

A compreensão da PCA exige domínio de três conceitos fundamentais da estatística multivariada:

Variância

- Mede a dispersão dos valores de uma variável em relação à sua média. Na PCA, direções com maior variância são priorizadas por carregarem mais informação.

Covariância

- Expressa como duas variáveis variam em conjunto. Covariância positiva indica comportamento conjunto; negativa, comportamentos opostos; próxima de zero, ausência de relação linear.

Correlação

- Forma padronizada da covariância, permitindo comparar relações entre variáveis independentemente de suas escalas. Essencial quando atributos possuem unidades diferentes.

Matriz de Covariância vs. Correlação

Matriz de Covariância

- Apropriada quando as variáveis são medidas em unidades comparáveis e apresentam variâncias semelhantes.
- Preserva a escala original dos dados.

Matriz de Correlação

- Recomendada quando as escalas diferem significativamente. Associada à padronização dos dados, produz resultados mais equilibrados e interpretáveis.
- Garante que cada atributo contribua de forma equitativa para a análise.
- A padronização é essencial: atributos com maior variância podem dominar a construção dos componentes, independentemente de sua relevância conceitual.

Construção dos Componentes Principais

- A construção dos componentes pode ser compreendida como a identificação de novos eixos de referência no espaço dos dados, orientados pela variabilidade máxima.

Matriz

- Calcular covariância ou correlação.

Selecionar

- Escolher componentes principais.

Padronizar

- Centralizar e escalar os dados.

Extrair

- Obter autovalores e autovetores.
- Cada componente é definido como ortogonal aos demais, garantindo independência estatística e ausência de redundância entre as novas variáveis criadas.

Variância Explicada e Seleção de Componentes

- A **variância explicada** por cada componente é o principal critério para avaliar a eficácia da redução. Componentes que explicam grande parte da variância capturam padrões globais e dominantes; componentes posteriores geralmente refletem variações sutis ou ruídos.
- A decisão sobre quantos componentes reter envolve um compromisso entre **simplicidade e fidelidade**: poucos componentes simplificam a análise, mas podem resultar em perda de informação relevante. Essa escolha deve ser orientada pelos objetivos específicos da análise.

Além da Redução: PCA como Ferramenta Exploratória

- A PCA não se restringe à redução de dimensionalidade. É também uma poderosa ferramenta exploratória para compreender a estrutura interna dos dados.

Identificação de padrões

- Revela padrões globais de variabilidade e correlação, auxiliando na detecção de redundâncias e relações entre variáveis.

Visualização multidimensional

- Projeta dados em 2D ou 3D, facilitando a identificação de agrupamentos, tendências e anomalias.

Detecção de anomalias

- Observações que se desviam dos padrões dominantes tornam-se mais evidentes no espaço reduzido.

Seleção de atributos

- Análise das cargas dos componentes orienta quais variáveis são mais relevantes para o problema.

PCA no Aprendizado de Máquina

Pré-processamento essencial

- No contexto do ML, a PCA é fundamental como técnica de pré-processamento. Muitos algoritmos apresentam desempenho sensível à dimensionalidade, seja por limitações computacionais, seja por dificuldades em generalizar com muitos atributos.
- A redução via PCA contribui para modelos mais **eficientes, estáveis e com melhor generalização**, especialmente em conjuntos de alta dimensão.

Classificação

- Reduz sobreajuste e melhora a estabilidade

Clustering

- Agrupamentos mais coerentes e interpretáveis

Regressão

- Mitiga multicolinearidade entre variáveis

Redução de Dimensionalidade para Melhorar a Eficiência dos Modelos

- Em um cenário onde a quantidade de variáveis cresce aceleradamente, a redução de dimensionalidade é uma estratégia metodológica central para simplificar a representação dos dados, preservando informações relevantes e eliminando excessos que comprometem a eficiência analítica.

A maldição da dimensionalidade

- À medida que o número de atributos aumenta, o espaço de dados torna-se progressivamente mais esparsos, dificultando a identificação de padrões consistentes. A quantidade de dados necessária para cobrir adequadamente o espaço cresce de forma exponencial.
- **Mais atributos** - Espaço de dados se expande exponencialmente.
- **Dados esparsos** - Distância entre padrões e ruídos se torna indistinguível.
- **Sobreajuste** - Modelo captura ruídos em vez de padrões generalizáveis.
- **Desempenho degradado** - Previsões pouco confiáveis em dados novos.

Seleção vs. Transformação de Atributos

A redução de dimensionalidade pode ser compreendida a partir de duas abordagens conceituais principais:

Seleção de atributos

- Escolhe um subconjunto das variáveis originais com base em critérios de relevância.
- Preserva a interpretação direta das variáveis, sendo ideal quando a explicabilidade é requisito.

Transformação de atributos

- Cria novas variáveis como combinações lineares das originais (ex: PCA). Oferece vantagens em eficiência computacional, mas pode dificultar a interpretação direta.

Benefícios da Redução de Dimensionalidade

Variância preservada

- Poucos componentes frequentemente capturam a maior parte da informação.

Redução de custo

- Ganhos expressivos em tempo de processamento e consumo de memória.

Menos sobreajuste

- Modelos mais simples generalizam melhor para dados não vistos.
- Modelos treinados com menos atributos demandam menos recursos, tornando-se viáveis para aplicações em larga escala, sistemas embarcados, aplicações móveis e ambientes de processamento em tempo real.

Limitações e Cuidados na Aplicação

Linearidade

- A PCA captura apenas relações lineares. Estruturas não lineares podem não ser adequadamente representadas, exigindo métodos complementares.

Interpretabilidade

- Componentes principais nem sempre correspondem a fatores conceituais claros. Atribuir significado exige análise das cargas e conhecimento do domínio.

Perda de informação

- Reter poucos componentes pode comprometer a capacidade do modelo de capturar padrões relevantes. O impacto deve ser avaliado cuidadosamente.

Eficiência vs. Transparência

- A redução pode melhorar eficiência computacional, mas dificultar a interpretação dos coeficientes e decisões do modelo.

PCA em Diferentes Contextos

A PCA é aplicada em ampla variedade de domínios, contribuindo para a redução da complexidade e extração de informação relevante:

Processamento de sinais

- Compressão e filtragem de sinais complexos em representações mais compactas.

Análise de imagens

- Redução da dimensionalidade de representações visuais para reconhecimento de padrões.

Análises financeiras

- Mitigação de multicolinearidade em modelos econômicos e regressões com variáveis correlacionadas.

Controle de qualidade

- Detecção de anomalias e monitoramento de processos em ambientes industriais.

Interatividade

Analise as afirmações:

- I. A PCA transforma variáveis originais em componentes principais ortogonais entre si, organizados de forma que os primeiros componentes explicam a maior parte da variância dos dados.
- II. A PCA é capaz de capturar automaticamente relações não lineares complexas entre variáveis, sendo eficaz independentemente da estrutura dos dados.
- III. A escolha entre as matrizes de covariância e de correlação depende das escalas das variáveis, sendo recomendada a padronização quando os atributos têm unidades diferentes.
- IV. A redução de dimensionalidade por PCA sempre melhora a interpretabilidade do modelo, pois os componentes principais mantêm significado conceitual direto das variáveis originais.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e IV, apenas.
- c) I e III, apenas.
- d) I, III e IV, apenas.
- e) III e IV, apenas.

Resposta

Analise as afirmações:

- I. A PCA transforma variáveis originais em componentes principais ortogonais entre si, organizados de forma que os primeiros componentes explicam a maior parte da variância dos dados.
- II. A PCA é capaz de capturar automaticamente relações não lineares complexas entre variáveis, sendo eficaz independentemente da estrutura dos dados.
- III. A escolha entre as matrizes de covariância e de correlação depende das escalas das variáveis, sendo recomendada a padronização quando os atributos têm unidades diferentes.
- IV. A redução de dimensionalidade por PCA sempre melhora a interpretabilidade do modelo, pois os componentes principais mantêm significado conceitual direto das variáveis originais.

Está correto o que se afirma em:

- a) I e II, apenas.
- b) II e IV, apenas.
- c) I e III, apenas.
- d) I, III e IV, apenas.
- e) III e IV, apenas.

Referências

- Wazlawick, Raul S. *Introdução a algoritmos e programação com Python: uma abordagem dirigida por testes*. Disponível em: Minha Biblioteca, Grupo GEN, 2018.
- GRUS, Joel. *Data science do zero: noções fundamentais com Python*. Rio de Janeiro: Alta Books, 2021
- LENZ, Maikon Lucian; NEUMANN, Fabiano Berlinck; SANTARELLI, Rodrigo; SALVADOR, Douglas. *Fundamentos de aprendizagem de máquina*. Porto Alegre: SAGAH, 2020.
- FERREIRA, Rafael Gastão Coimbra. *Preparação e análise exploratória de dados*. Porto Alegre: SAGAH, 2021.
- GOLDSCHMIDT, Ronaldo; PASSOA, Emmanuel; BEZERRA, Eduardo. *Data mining*. Rio de Janeiro: Elsevier, 2015.
- PADILHA, Juliana; SOARES, Juliane Adélia; ALVES, Nicolli Souza Rios; ABREU, Eduardo Melione; SILVA, Fernanda Rosa da; MORAIS, Myllena Silva de Freitas; LACERDA, Paulo Sérgio Pádua de; MAITINO NETO, Roque; MACHADO, Victor de Andrade. *Analytics para Big Data*. Porto Alegre: SAGAH, 2022.

ATÉ A PRÓXIMA!